

Aula 00: Revisão

Inferência Estatística - FGV EMAp

Marcus L. Nascimento

1 de setembro de 2026

Definição. Seja $\mathcal{X}$ um conjunto não-vazio. Dizemos que uma coleção $\mathcal{A}$ de subconjuntos de $\mathcal{X}$ é uma σ -álgebra em $\mathcal{X}$ quando as seguintes propriedades são satisfeitas:

A1. $\emptyset \in \mathcal{A}$;

A2. Se $A \in \mathcal{A}$, então $A^c \in \mathcal{A}$;

A3. Se $A_1, A_2, \dots \in \mathcal{A}$, então $\bigcup_{i=1}^{\infty} A_i \in \mathcal{A}$.

- Se $\mathcal{X}$ é um conjunto não-vazio e $\mathcal{A}$ é σ -álgebra em $\mathcal{X}$, dizemos que o par $(\mathcal{X}, \mathcal{A})$ é um espaço mensurável.

- Se $A \in \mathcal{A}$, dizemos que A é um conjunto mensurável.

Seja $\mathcal{X}$ um conjunto não-vazio e considere uma classe $\mathcal{C}$ de subconjuntos de $\mathcal{X}$. Defina $\sigma(\mathcal{C})$ como sendo a intersecção de todas as σ -álgebras que contêm $\mathcal{C}$, isto é,

$$\sigma(\mathcal{C}) := \bigcap \{ \mathcal{A} : \mathcal{A} \text{ é } \sigma\text{-álgebra em } \mathcal{X} \wedge \mathcal{C} \subset \mathcal{A} \}.$$

Assim, $\sigma(\mathcal{C})$ é caracterizada pelas propriedades:

- (i) $\sigma(\mathcal{C})$ é σ -álgebra em $\mathcal{X}$;
- (ii) $\mathcal{C} \subset \sigma(\mathcal{C})$;
- (iii) Se $\mathcal{A}$ é qualquer outra σ -álgebra em $\mathcal{X}$ tal que $\mathcal{C} \subset \mathcal{A}$, então $\sigma(\mathcal{C}) \subset \mathcal{A}$.

OBSERVAÇÃO: Dizemos que $\sigma(\mathcal{C})$ é a menor σ -álgebra em $\mathcal{X}$ contendo a classe $\mathcal{C}$, ou então que $\sigma(\mathcal{C})$ é a σ -álgebra gerada pela classe $\mathcal{C}$.

EXEMPLO: Sejam $\mathcal{X} = \mathbb{R}^d$ e $\mathcal{U}$ a classe de subconjuntos de $\mathcal{X}$ formada pelos conjuntos do tipo $A_1 \times \dots \times A_d$, onde cada A_j é um intervalo aberto da reta. A σ -álgebra $\sigma(\mathcal{U})$ é chamada a σ -álgebra de Borel em $\mathbb{R}^d$.

- $\mathcal{B}(\mathbb{R}^d) = \sigma(\mathcal{U})$.
- Um conjunto pertencente a $\mathcal{B}(\mathbb{R}^d)$ é dito um Boreliano de $\mathbb{R}^d$;
- Em probabilidade,
 - O conjunto $\mathcal{X}$ é denominado espaço amostral.
 - Se $(\mathcal{X}, \mathcal{A})$ é um espaço mensurável e $A \in \mathcal{A}$, então A é dito evento aleatório em $\mathcal{X}$.
 - Como $\mathcal{X} \in \mathcal{A}$, ele representa o evento certo.

Definição. Seja $(\mathcal{X}, \mathcal{A})$ um espaço mensurável. Dizemos que uma função $\mu : \mathcal{A} \rightarrow \mathbb{R} \cup \{\infty\}$ é uma medida em $(\mathcal{X}, \mathcal{A})$ se satisfizer as seguintes condições:

M1. $\mu(\emptyset) = 0$;

M2. $\mu(A) \geq 0, \forall A \in \mathcal{A}$;

M3. Se $A_1, A_2, \dots \in \mathcal{A}$ são disjuntos¹, então $\mu(\bigcup_{i=1}^{\infty} A_i) = \sum_{i=1}^{\infty} \mu(A_i)$

OBSERVAÇÕES:

(1) Se $\mu(\mathcal{X}) < \infty$, diz-se que μ é medida finita.

(2) Se existem conjuntos mensuráveis $A_n \in \mathcal{A}$, $n \in \mathbb{N}$, tais que $\mathcal{X} = \bigcup_{n=1}^{\infty} A_n$ e $\mu(A_n) < \infty$ para todo n , então dizemos que μ é σ -finita.

• Seja $\mathcal{X}$ um conjunto, $\mathcal{A}$ uma σ -álgebra em $\mathcal{X}$, e μ uma medida definida em $\mathcal{A}$. Dizemos que a tripla $(\mathcal{X}, \mathcal{A}, \mu)$ é um espaço de medida.

¹Uma sequência $A_1, A_2, \dots \in \mathcal{A}$ é dita disjunta se $A_i \cap A_j = \emptyset$ sempre que $i \neq j$.

Medida de Probabilidade

- Uma medida μ é dita uma medida de probabilidade, ou simplesmente uma probabilidade, em $(\mathcal{X}, \mathcal{A})$ se $\mu(\mathcal{X}) = 1$.
 - Usualmente, uma medida de probabilidade é denotada por P .
- Seja $\mathcal{X}$ um conjunto, $\mathcal{A}$ uma σ -álgebra em $\mathcal{X}$, e P uma medida de probabilidade definida em $\mathcal{A}$. Dizemos que a tripla $(\mathcal{X}, \mathcal{A}, P)$ é um espaço de probabilidade.

OBSERVAÇÃO: Os axiomas de Kolmogorov consistem em:

Axioma 1. $P(A) \geq 0$ para todo $A \in \mathcal{A}$.

Axioma 2. $P(\mathcal{X}) = 1$.

Axioma 3. Se $A_1, A_2, \dots \in \mathcal{A}$ são disjuntos, então $P(\bigcup_{i=1}^{\infty} A_i) = \sum_{i=1}^{\infty} P(A_i)$.

PROPRIEDADES:

$$P1. P(A^c) = 1 - P(A);$$

$$P2. 0 \leq P(A) \leq 1;$$

$$P3. A_1 \subset A_2 \Rightarrow P(A_1) \leq P(A_2);$$

$$P4. P(\bigcup_{i=1}^n A_i) \leq \sum_{i=1}^n P(A_i);$$

$$P5. P(\bigcup_{i=1}^{\infty} A_i) \leq \sum_{i=1}^{\infty} P(A_i);$$

$$P6. \text{ Se } A_n \uparrow A, \text{ então } P(A_n) \uparrow P(A). \text{ Se } A_n \downarrow A, \text{ então } P(A_n) \downarrow P(A).$$

Função Mensurável e Variável Aleatória

Definição. Sejam $(\mathcal{X}, \mathcal{A})$ e $(\mathcal{Y}, \mathcal{B})$ dois espaços mensuráveis. Uma função $f : \mathcal{X} \rightarrow \mathcal{Y}$ é dita $\mathcal{A}/\mathcal{B}$ -mensurável se satisfizer a seguinte condição:

$$f^{-1}(B) = \{\omega \in \mathcal{X} : f(\omega) \in B\} \in \mathcal{A}, \quad \forall B \in \mathcal{B}.$$

OBSERVAÇÃO: A definição utiliza a imagem inversa, pois ela preserva naturalmente as operações de união, interseção e complemento.

- Seja $(\mathcal{X}, \mathcal{A}, P)$ um espaço de probabilidade. Uma variável aleatória é uma função mensurável $X : \mathcal{X} \rightarrow \mathbb{R}$. Ou seja,

$$X^{-1}(B) = \{\omega \in \mathcal{X} : X(\omega) \in B\} \in \mathcal{A}, \quad \forall B \in \mathcal{B}(\mathbb{R}).$$

Distribuição de uma Variável Aleatória

- Se X é uma variável aleatória, então ela induz uma medida de probabilidade sobre $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$, definida por

$$P_X(B) = P(X^{-1}(B)) = P(\{\omega \in \mathcal{X} : X(\omega) \in B\}), \quad B \in \mathcal{B}(\mathbb{R}).$$

- P_X é uma medida chamada de distribuição de X (ou lei de X).
- A função de distribuição (acumulada) F_X é definida por

$$F_X(x) = P_X((-\infty, x]) = P(\{\omega \in \mathcal{X} : X(\omega) \in (-\infty, x]\}).$$

OBSERVAÇÃO: Como $\mathcal{B}(\mathbb{R}) = \sigma(\{(-\infty, x] : x \in \mathbb{R}\})$, a função de distribuição determina completamente a medida de distribuição P_X .

Função de Distribuição

PROPRIEDADES:

F1. $x \leq y \Rightarrow F_X(x) \leq F_X(y)$.

F2. Se $x_n \downarrow y$, então $F_X(x_n) \downarrow F_X(y)$.

F3. Se $x_n \downarrow -\infty$, então $F_X(x_n) \downarrow 0$. Se $x_n \uparrow +\infty$, então $F_X(x_n) \uparrow 1$.

OBSERVAÇÕES:

- (1) Reciprocamente, toda função $F : \mathbb{R} \rightarrow [0, 1]$ que satisfaz F1–F3 é a função de distribuição de alguma variável aleatória.
- (2) Uma mesma função de distribuição pode corresponder a diferentes variáveis aleatórias definidas no mesmo espaço de probabilidade.

Uma vez definida a distribuição de X , surge a seguinte questão:

Como representar a medida P_X sobre $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$?

Definição. Sejam P_X e μ medidas definidas em $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$. Dizemos que P_X é absolutamente contínua em relação a μ se $P_X(B) = 0$ sempre que $\mu(B) = 0$. Nesse caso, escrevemos que $P_X \ll \mu$.

Teorema de Radon-Nikodym

Teorema. Seja μ uma medida σ -finita. Se $P_X \ll \mu$, então existe uma função mensurável $f : \mathbb{R} \rightarrow [0, \infty)$ tal que

$$P_X(B) = \int_B f \, d\mu, \quad B \in \mathcal{B}(\mathbb{R}).$$

Essa função é única μ -q.c., denotada por

$$f = \frac{dP_X}{d\mu},$$

e denominada derivada de Radon-Nikodym de P_X em relação a μ .

Medida de Lebesgue (λ). Definida sobre $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$, é a medida que associa a cada intervalo seu comprimento, isto é,

$$\lambda((a, b)) = b - a, \quad a < b.$$

Em particular, $\lambda(\{x\}) = 0, \forall x \in \mathbb{R}$.

Medida de contagem (N). Seja $B \in \mathcal{B}(\mathbb{R})$, temos

$$N(B) = \begin{cases} |B|, & \text{se } B \text{ é finito,} \\ \infty, & \text{se } B \text{ é infinito.} \end{cases}$$

Em particular, $N(\{x\}) = 1, \forall x \in \mathbb{R}$.

Distribuições Contínuas

Se $P_X \ll \lambda$, pelo Teorema de Radon–Nikodym, existe uma função mensurável não negativa

$$f = \frac{dP_X}{d\lambda}$$

tal que $P_X(B) = \int_B f \, d\lambda$, $B \in \mathcal{B}(\mathbb{R})$.

OBSERVAÇÕES:

- (1) A função f é chamada de **densidade** de X .
- (2) $F_X(x) = P_X((-\infty, x]) = \int_{(-\infty, x]} f \, d\lambda = \int_{-\infty}^x f(t) \, dt$.
- (3) Para toda função mensurável g ,

$$\mathbb{E}[g(X)] = \int_{\mathbb{R}} g \, dP_X = \int_{\mathbb{R}} g(x) f(x) \, d\lambda(x) = \int_{\mathbb{R}} g(x) f(x) \, dx.$$

Se $P_X \ll N$, pelo Teorema de Radon–Nikodym, existe uma função mensurável não negativa

$$p = \frac{dP_X}{dN}$$

tal que $P_X(B) = \int_B p \, dN$, $B \in \mathcal{B}(\mathbb{R})$.

OBSERVAÇÕES:

(1) A função p é chamada de **função de probabilidade** de X .

(2) $F_X(x) = P_X((-\infty, x]) = \int_{(-\infty, x]} p \, dN = \sum_{t \leq x} p(t)$.

(3) Para toda função mensurável g ,

$$\mathbb{E}[g(X)] = \int_{\mathbb{R}} g \, dP_X = \int_{\mathbb{R}} g(x) p(x) \, dN(x) = \sum_{x \in \mathbb{R}} g(x) p(x).$$

Vetores Aleatórios

- Uma função $\mathbf{X} = (X_1, \dots, X_n) : \mathcal{X} \rightarrow \mathbb{R}^n$ mensurável é chamada de vetor aleatório.
- Se a distribuição de $\mathbf{X}$ satisfaz $\mathbb{P}_{\mathbf{X}} \ll \lambda_n$, onde λ_n é a medida de Lebesgue em $\mathbb{R}^n$, então existe uma função mensurável não negativa

$$f = \frac{d\mathbb{P}_{\mathbf{X}}}{d\lambda_n}$$

tal que $\mathbb{P}_{\mathbf{X}}(B) = \int_B f(\mathbf{x}) d\lambda_n(\mathbf{x})$, $B \in \mathcal{B}(\mathbb{R}^n)$.

OBSERVAÇÕES:

- (1) A medida de probabilidade $\mathbb{P}_{\mathbf{X}}$ é chamada **distribuição conjunta** (ou lei) do vetor aleatório $\mathbf{X}$.
- (2) $F_{\mathbf{X}}(\mathbf{x}) = \mathbb{P}_{\mathbf{X}}((-\infty, x_1] \times \dots \times (-\infty, x_n]) = \mathbb{P}(X_1 \leq x_1, \dots, X_n \leq x_n)$.

- Sejam $(\mathcal{X}, \mathcal{A}, \mu)$ e $(\mathcal{Y}, \mathcal{B}, \nu)$ espaços de medida. Então existe uma medida produto $\mu \otimes \nu$ em $(\mathcal{X} \times \mathcal{Y}, \mathcal{A} \otimes \mathcal{B})$ tal que

$$(\mu \otimes \nu)(A \times B) = \mu(A)\nu(B).$$

Teorema (Fubini–Tonelli). Se $(\mathcal{X}, \mathcal{A}, \mu)$ e $(\mathcal{Y}, \mathcal{B}, \nu)$ são espaços de medida σ -finitos, então:

- Se $g : X \times Y \rightarrow [0, \infty]$ é mensurável, então

$$\int g \, d(\mu \otimes \nu) = \int \left(\int g(x, y) \, d\nu(y) \right) d\mu(x) = \int \left(\int g(x, y) \, d\mu(x) \right) d\nu(y).$$

- Se g é integrável com respeito a $\mu \otimes \nu$, isto é, $\int |g| \, d(\mu \otimes \nu) < \infty$, então a mesma igualdade vale.

Distribuição Marginal

- $P_{X_i}(B) = P_{\mathbf{X}}(\mathbb{R} \times \cdots \times B \times \cdots \times \mathbb{R}), B \in \mathcal{B}(\mathbb{R}).$
- Seja $A_i = \mathbb{R} \times \cdots \times B \times \cdots \times \mathbb{R}$, se a distribuição de $\mathbf{X}$ satisfaz $\mathbb{P}_{\mathbf{X}} \ll \lambda_n$, então

$$\begin{aligned} P_{X_i}(B) &= \int_{A_i} f(\mathbf{x}) d\lambda_n(\mathbf{x}) \\ &= \int_B \left[\int_{\mathbb{R}^{n-1}} f(x_1, \dots, x_n) d\lambda_{n-1}(\mathbf{x}_{-i}) \right] d\lambda(x_i). \end{aligned} \quad (\text{Fubini-Tonelli})$$

Consequentemente, a densidade marginal de X_i é dada por

$$f_{X_i}(x_i) = \int_{\mathbb{R}^{n-1}} f(x_1, \dots, x_n) d\mathbf{x}_{-i}.$$

Definição. As variáveis aleatórias $X_1, \dots, X_n$ são independentes se a distribuição conjunta satisfaz $\mathbb{P}_{\mathbf{X}} = \mathbb{P}_{X_1} \otimes \dots \otimes \mathbb{P}_{X_n}$.

- Suponha que $\mathbb{P}_{X_i} \ll \lambda$, $i = 1, \dots, n$, com densidades marginais $f_{X_i} = \frac{d\mathbb{P}_{X_i}}{d\lambda}$. Como as variáveis são independentes, pela propriedade da derivada de Radon–Nikodym para medidas produto,

$$\begin{aligned} f_{\mathbf{X}}(x_1, \dots, x_n) &= \frac{d(\mathbb{P}_{X_1} \otimes \dots \otimes \mathbb{P}_{X_n})}{d(\lambda \otimes \dots \otimes \lambda)} \\ &= \prod_{i=1}^n \frac{d\mathbb{P}_{X_i}}{d\lambda}(x_i) \\ &= \prod_{i=1}^n f_{X_i}(x_i). \end{aligned}$$

Definição. Sejam $X, Y : \mathcal{X} \rightarrow \mathbb{R}$ variáveis aleatórias definidas no mesmo espaço de probabilidade. Uma família de medidas de probabilidade $\{Q_x : x \in \mathbb{R}\}$ é chamada distribuição condicional de Y dado $X = x$ se

C1. Para todo $x \in \mathbb{R}$, $Q_x(\cdot)$ é uma medida de probabilidade sobre $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$;

C2. Para todo $B \in \mathcal{B}(\mathbb{R})$, a função $x \mapsto Q_x(B)$ é mensurável;

C3. Para quaisquer $A, B \in \mathcal{B}(\mathbb{R})$,

$$P(X \in A, Y \in B) = \int_A Q_x(B) dP_X(x).$$

Distribuição Condicional com Densidade

Suponha que (X, Y) possua densidade conjunta $f_{X,Y}$ e que $f_X(x) > 0$. Então a distribuição condicional de Y dado $X = x$ possui densidade

$$f_{Y|X}(y|x) = \frac{f_{X,Y}(x,y)}{f_X(x)}.$$

Portanto, para todo $B \in \mathcal{B}(\mathbb{R})$,

$$P(Y \in B | X = x) = \int_B f_{Y|X}(y|x) dy.$$

Definição. Sejam X e $X_1, X_2, \dots$ variáveis aleatórias em um mesmo espaço de probabilidade $(\mathcal{X}, \mathcal{A}, P)$. Dizemos que X_n converge quase certamente para X se

$$P \left(\lim_{n \rightarrow \infty} |X_n - X| = 0 \right) = 1.$$

EXEMPLO: Considere $\mathcal{X}$ o intervalo fechado $[0, 1]$ como distribuição uniforme e defina as variáveis aleatórias $X_n(\omega) = \omega + \omega^n$ e $X(\omega) = \omega$.

Teorema (Lei Forte dos Grandes Números). Sejam $X_1, X_2, \dots$ variáveis aleatórias *i.i.d.* com $\mathbb{E}[X_i] = \mu$ e $\text{Var}(X_i) = \sigma^2 < \infty$. Definindo $\bar{X}_n = (1/n) \sum_{i=1}^n X_i$, então

$$P \left(\lim_{n \rightarrow \infty} |\bar{X}_n - \mu| = 0 \right) = 1.$$

Noções de convergência

Definição. Sejam X e $X_1, X_2, \dots$ variáveis aleatórias em um mesmo espaço de probabilidade $(\mathcal{X}, \mathcal{A}, P)$. Dizemos que X_n converge em probabilidade para X se

$$\lim_{n \rightarrow \infty} P(|X_n - X| \geq \epsilon) = 0, \quad \forall \epsilon > 0.$$

EXEMPLO: Considere $\mathcal{X}$ o intervalo fechado $[0, 1]$ com distribuição uniforme e defina as variáveis aleatórias $X(\omega) = \omega$ e $X_1, X_2, \dots$ como a seguir:

$$\begin{aligned} X_1(\omega) &= \omega + \mathbb{1}_{[0,1]}(\omega), X_2(\omega) = \omega + \mathbb{1}_{[0, \frac{1}{2}]}(\omega), X_3(\omega) = \omega + \mathbb{1}_{[\frac{1}{2}, 1]}(\omega) \\ X_4(\omega) &= \omega + \mathbb{1}_{[0, \frac{1}{3}]}(\omega), X_5(\omega) = \omega + \mathbb{1}_{[\frac{1}{3}, \frac{2}{3}]}(\omega), X_6(\omega) = \omega + \mathbb{1}_{[\frac{2}{3}, 1]}(\omega), \dots \end{aligned}$$

Teorema (Lei Fraca dos Grandes Números). Sejam $X_1, X_2, \dots$ variáveis aleatórias *i.i.d.* com $\mathbb{E}[X_i] = \mu$ e $\text{Var}(X_i) = \sigma^2 < \infty$. Definindo $\bar{X}_n = (1/n) \sum_{i=1}^n X_i$, então

$$\lim_{n \rightarrow \infty} P(|\bar{X}_n - \mu| \geq \epsilon) = 0, \quad \forall \epsilon > 0.$$

Noções de convergência

Definição. Sejam X e $X_1, X_2, \dots$ variáveis aleatórias em um mesmo espaço de probabilidade $(\mathcal{X}, \mathcal{A}, P)$. Dizemos que X_n converge em distribuição para X se

$$\lim_{n \rightarrow \infty} F_{X_n}(x) = F_X(x)$$

em todo ponto x no qual $F_X(x)$ é contínua.

EXEMPLO: Considere $X_1, X_2, \dots$ variáveis aleatórias *i.i.d* com distribuição Uniforme no intervalo $[0, 1]$ e $X_{(n)} = \max_{1 \leq i \leq n} X_i$.

Teorema (Teorema do Limite Central). Sejam $X_1, X_2, \dots$ variáveis aleatórias *i.i.d.* com $\mathbb{E}[X_i] = \mu$ e $\text{Var}(X_i) = \sigma^2 < \infty$. Defina $\bar{X}_n = (1/n) \sum_{i=1}^n X_i$ e considere $G_n(x)$ a função de distribuição acumulada de $\sqrt{n}(\bar{X}_n - \mu)/\sigma$. Então,

$$\lim_{n \rightarrow \infty} G_n(x) = \Phi(x).$$

$$X_n \xrightarrow{\text{q.c.}} X \implies X_n \xrightarrow{P} X \implies X_n \xrightarrow{d} X.$$