

1. INTRODUÇÃO

Suponha um modelo estatístico paramétrico $\mathcal{P} = \{\mathbb{P}_\theta : \theta \in \Theta\}$ e assuma que uma amostra aleatória $\mathbf{X} = (X_1, \dots, X_n)$ possui distribuição $\mathbb{P}_\theta$, para algum parâmetro desconhecido $\theta \in \Theta$. Neste contexto, o objetivo da inferência estatística é obter informações sobre θ a partir de $\mathbf{X}$.

Definição 1.1. Seja $\mathbf{X} = (X_1, \dots, X_n)$ um vetor aleatório no espaço $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n))$. Uma estatística é uma variável aleatória da forma $T(\mathbf{X})$, em que $T : (\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n)) \rightarrow (\mathcal{T}, \mathcal{A}_{\mathcal{T}})$ é uma função mensurável.

EXEMPLOS: $T_1(\mathbf{X}) = \sum_{i=1}^n X_i$, $T_2(\mathbf{X}) = \bar{X}$ e $T_3(\mathbf{X}) = \max_{1 \leq i \leq n} X_i = X_{(n)}$.

Nos casos em que $T(\mathbf{X})$ representa uma redução dos dados, a questão fundamental é saber se essa redução implica perda de informação sobre o parâmetro θ . Em particular, podemos perguntar se, uma vez conhecida $T(\mathbf{X})$, a informação adicional contida em $\mathbf{X}$ ainda é relevante para a inferência sobre θ .

PRINCÍPIO DA SUFICIÊNCIA: Se $T(\mathbf{X})$ é uma estatística suficiente para θ , então o processo de inferência sobre θ pode ser realizado a partir de $\mathbf{X}$ apenas por meio de $T(\mathbf{X})$.

Definição 1.2. Suponha que $\mathbf{X}$ possui distribuição na família $\mathcal{P} = \{\mathbb{P}_\theta : \theta \in \Theta\}$. Então, $T(\mathbf{X})$ é estatística suficiente para θ se, para todo t e θ , a distribuição condicional de $\mathbf{X}$ dado $T(\mathbf{X}) = t$, sob $\mathbb{P}_\theta$, não depende de θ .

No caso em que $\mathbf{X}$ possui distribuição discreta, podemos aferir suficiência verificando se $\mathbb{P}_\theta(\mathbf{X} = \mathbf{x} | T(\mathbf{X}) = T(\mathbf{x}))$ depende de θ .

$$\begin{aligned} \mathbb{P}_\theta(\mathbf{X} = \mathbf{x} | T(\mathbf{X}) = T(\mathbf{x})) &= \frac{\mathbb{P}_\theta(\mathbf{X} = \mathbf{x}, T(\mathbf{X}) = T(\mathbf{x}))}{\mathbb{P}_\theta(T(\mathbf{X}) = T(\mathbf{x}))} \\ &= \frac{\mathbb{P}_\theta(\mathbf{X} = \mathbf{x})}{\mathbb{P}_\theta(T(\mathbf{X}) = T(\mathbf{x}))} \\ &= \frac{p(\mathbf{x}; \theta)}{q(T(\mathbf{x}); \theta)}, \end{aligned}$$

onde $p(\mathbf{x}; \theta)$ é a função de massa de probabilidade (f.m.p.) conjunta de $\mathbf{X}$ e $q(T(\mathbf{x}); \theta)$ é a f.m.p. de $T(\mathbf{X})$. De maneira análoga, no caso contínuo, a condição de suficiência pode ser verificada por meio da função de densidade de probabilidade (f.d.p.) condicional de $\mathbf{X}$ dado $T(\mathbf{X})$.

Exemplo 1.1. Sejam $X_1, \dots, X_n$ variáveis aleatórias *i.i.d.* com distribuição $\text{Bern}(\theta)$, $\theta \in (0, 1)$. Desejamos verificar se $T(\mathbf{X}) = \sum_{i=1}^n X_i$ é estatística suficiente para θ .

$$\begin{aligned} \frac{p(\mathbf{x}; \theta)}{q(T(\mathbf{x}); \theta)} &= \frac{\prod_{i=1}^n \theta^{x_i} (1 - \theta)^{(1-x_i)}}{\binom{n}{\sum_{i=1}^n x_i} \theta^{\sum_{i=1}^n x_i} (1 - \theta)^{(n - \sum_{i=1}^n x_i)}} \\ &= \frac{\theta^{\sum_{i=1}^n x_i} (1 - \theta)^{(n - \sum_{i=1}^n x_i)}}{\binom{n}{\sum_{i=1}^n x_i} \theta^{\sum_{i=1}^n x_i} (1 - \theta)^{(n - \sum_{i=1}^n x_i)}} \\ &= \frac{1}{\binom{n}{\sum_{i=1}^n x_i}}. \end{aligned}$$

Exemplo 1.2. Sejam $X_1, \dots, X_n$ variáveis aleatórias *i.i.d.* com distribuição $N(\mu, \sigma^2)$, em que σ^2 é conhecido. Desejamos verificar se $T(\mathbf{X}) = \bar{X}$ é estatística suficiente para μ .
A f.d.p. conjunta de $\mathbf{X}$ é dada por

$$\begin{aligned} f(\mathbf{x}; \mu) &= \prod_{i=1}^n (2\pi\sigma^2)^{-1/2} \exp \left\{ -\frac{(x_i - \mu)^2}{2\sigma^2} \right\} \\ &= (2\pi\sigma^2)^{-n/2} \exp \left\{ -\frac{\sum_{i=1}^n (x_i - \mu)^2}{2\sigma^2} \right\} \\ &= (2\pi\sigma^2)^{-n/2} \exp \left\{ -\frac{\sum_{i=1}^n (x_i - \bar{x})^2 + n(\bar{x} - \mu)^2}{2\sigma^2} \right\}. \end{aligned}$$

Como $\bar{X}$ tem distribuição $N(\mu, \sigma^2/n)$, temos que

$$\begin{aligned} \frac{f(\mathbf{x}; \mu)}{g(T(\mathbf{x}); \mu)} &= \frac{(2\pi\sigma^2)^{-n/2} \exp \left\{ -\frac{\sum_{i=1}^n (x_i - \bar{x})^2 + n(\bar{x} - \mu)^2}{2\sigma^2} \right\}}{(2\pi\sigma^2/n)^{-1/2} \exp \left\{ -\frac{n(\bar{x} - \mu)^2}{2\sigma^2} \right\}} \\ &= n^{-1/2} (2\pi\sigma^2)^{-(n-1)/2} \exp \left\{ -\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{2\sigma^2} \right\}. \end{aligned}$$

Exemplo 1.3. Sejam $X_1, \dots, X_n$ variáveis aleatórias *i.i.d.* com distribuição $\text{Unif}(0, \theta)$, $\theta > 0$. Desejamos verificar se $T(\mathbf{X}) = X_{(n)} = \max_{1 \leq i \leq n} X_i$ é estatística suficiente para θ .

A f.d.p. conjunta de $\mathbf{X}$ é dada por

$$f(\mathbf{x}; \theta) = \prod_{i=1}^n \frac{1}{\theta} \mathbb{1}(0 < x_i < \theta) = \frac{1}{\theta^n} \mathbb{1}(0 < x_{(1)}) \mathbb{1}(x_{(n)} < \theta).$$

Por outro lado, temos que a densidade de $X_{(n)}$ é dada por

$$g(t; \theta) = \frac{nt^{n-1}}{\theta^n} \mathbb{1}(0 < t < \theta).$$

Logo,

$$\begin{aligned} \frac{f(\mathbf{x}; \theta)}{g(T(\mathbf{x}); \theta)} &= \frac{\theta^{-n} \mathbb{1}(0 < x_{(1)}) \mathbb{1}(x_{(n)} < \theta)}{nx_{(n)}^{n-1} \theta^{-n} \mathbb{1}(0 < x_{(n)} < \theta)} \\ &= \frac{1}{nx_{(n)}^{n-1}} \mathbb{1}(0 < x_{(1)}). \end{aligned}$$

2. CRITÉRIO DE FATORAÇÃO DE NEYMAN-FISHER

Aplicar diretamente a definição para verificar a suficiência de uma estatística em um modelo particular pode ser uma tarefa complicada. É necessário propor uma estatística candidata, obter a f.m.p. ou f.d.p. conjunta da amostra e a f.m.p. ou f.d.p. da estatística e, então, verificar se a distribuição condicional de $\mathbf{X}$ dado $T(\mathbf{X})$ depende do parâmetro.

Teorema 2.1. Suponha que cada $\mathbb{P}_\theta \in \mathcal{P}$ possua densidade $p(\mathbf{x}; \theta)$ em relação a uma medida σ -finita comum μ , isto é, $\frac{d\mathbb{P}_\theta}{d\mu}(\mathbf{x}) = p(\mathbf{x}; \theta)$. Então, $T(\mathbf{X})$ é suficiente para θ se, e somente se,

$$f(\mathbf{x}; \theta) = g_\theta(T(\mathbf{x}))h(\mathbf{x}),$$

para alguma função $g_\theta \geq 0$ e $h \geq 0$.

Exemplo 2.1. Considere novamente que as variáveis aleatórias $X_1, \dots, X_n$ sejam *i.i.d.* com distribuição $N(\mu, \sigma^2)$, porém agora μ e σ^2 são desconhecidos. Desejamos obter estatísticas suficientes para μ e σ^2 .

Vimos que a f.d.p. conjunta de $\mathbf{X}$ pode ser escrita da seguinte forma:

$$\begin{aligned} f(\mathbf{x}; \mu, \sigma^2) &= (2\pi\sigma^2)^{-n/2} \exp \left\{ -\frac{\sum_{i=1}^n (x_i - \bar{x})^2 + n(\bar{x} - \mu)^2}{2\sigma^2} \right\} \\ &= \underbrace{(2\pi\sigma^2)^{-n/2} \exp \left\{ -\frac{(n-1)s^2 + n(\bar{x} - \mu)^2}{2\sigma^2} \right\}}_{g_{\mu, \sigma^2}(T(\mathbf{x}))} \times \underbrace{1}_{h(\mathbf{x})}. \end{aligned}$$

Logo, pelo Teorema de Fatoração de Neyman–Fisher, $T(\mathbf{X}) = (T_1(\mathbf{X}), T_2(\mathbf{X})) = (\bar{X}, S^2)$ é estatística suficiente para (μ, σ^2) .

Exemplo 2.2. Retomando o exemplo em que $X_1, \dots, X_n$ são variáveis aleatórias *i.i.d.* com distribuição $\text{Unif}(0, \theta)$, $\theta > 0$. Desejamos aplicar o Teorema de Fatoração de Neyman–Fisher para verificar se $T(\mathbf{X}) = X_{(n)}$ é suficiente para θ .

A f.d.p. conjunta de $\mathbf{X}$ é dada por

$$\begin{aligned} f(\mathbf{x}; \theta) &= \prod_{i=1}^n \frac{1}{\theta} \mathbb{1}(0 < x_i < \theta) = \frac{1}{\theta^n} \mathbb{1}(0 < x_{(1)}) \mathbb{1}(x_{(n)} < \theta) \\ &= \underbrace{\frac{1}{\theta^n} \mathbb{1}(x_{(n)} < \theta)}_{g_{\theta}(x_{(n)})} \underbrace{\mathbb{1}(0 < x_{(1)})}_{h(\mathbf{x})}. \end{aligned}$$

Logo, pelo Teorema de Fatoração de Neyman–Fisher, $T(\mathbf{X}) = X_{(n)}$ é estatística suficiente para θ .

3. ESTATÍSTICA SUFICIENTE MÍNIMA

Até o momento, encontramos estatísticas suficientes para os modelos considerados. Entretanto, em geral, há diferentes estatísticas suficientes para um mesmo parâmetro. Por exemplo, se $T'(\mathbf{X})$ é suficiente para θ e r é uma função bijetiva, então $T(\mathbf{X}) = r(T'(\mathbf{X}))$ também é suficiente para θ . Pelo Teorema da Fatoração, existem g_{θ} e h tais que

$$f(\mathbf{x}; \theta) = g_{\theta}(T'(\mathbf{x})) h(\mathbf{x}) = g_{\theta}(r^{-1}(T(\mathbf{x}))) h(\mathbf{x}).$$

Definindo $g'_{\theta}(t) = g_{\theta}(r^{-1}(t))$, vemos que

$$f(\mathbf{x}; \theta) = g'_{\theta}(T(\mathbf{x})) h(\mathbf{x}).$$

Logo, $T(\mathbf{X})$ é estatística suficiente.

Uma vez que podem existir inúmeras estatísticas suficientes para θ , surge a questão de identificar, entre elas, aquelas que não podem ser reduzidas sem perder a suficiência para θ .

Definição 3.1. Uma estatística suficiente $T(\mathbf{X})$ para θ é dita suficiente mínima se, para toda estatística suficiente $T'(\mathbf{X})$ para θ , existe uma função mensurável r tal que

$$T(\mathbf{X}) = r(T'(\mathbf{X})) \quad \text{quase certamente.}$$

Embora a definição de suficiência mínima seja conceitualmente clara, sua verificação direta pode ser difícil, pois exige considerar toda estatística suficiente para θ .

Teorema 3.1. Seja $\mathcal{P} = \{\mathbb{P}_\theta : \theta \in \Theta\}$ uma família dominada com densidade $f(\mathbf{x}; \theta) = g_\theta(T(\mathbf{x}))h(\mathbf{x})$. Suponha que existe uma estatística $T(\mathbf{X})$ tal que para todo $\mathbf{x}$ e $\mathbf{y}$:

$$f(\mathbf{x}; \theta) = c(\mathbf{x}, \mathbf{y}) f(\mathbf{y}; \theta) \iff T(\mathbf{x}) = T(\mathbf{y})$$

para todo θ e algum $c(\mathbf{x}, \mathbf{y})$. Então, $T(\mathbf{X})$ é estatística suficiente mínima.

Exemplo 3.1. Retomando o caso em que as variáveis aleatórias $X_1, \dots, X_n$ são *i.i.d.* com distribuição $N(\mu, \sigma^2)$, com μ e σ^2 desconhecidos. Desejamos verificar se $T(\mathbf{X}) = (\bar{X}, S^2)$ é estatística suficiente mínima para (μ, σ^2) .

Considere dois possíveis valores $\mathbf{x}$ e $\mathbf{y}$ da amostra. A densidade conjunta pode ser escrita como

$$f(\mathbf{x}; \mu, \sigma^2) = (2\pi\sigma^2)^{-n/2} \exp \left\{ -\frac{(n-1)s_x^2 + n(\bar{x} - \mu)^2}{2\sigma^2} \right\}.$$

($\Rightarrow$)

Suponha que, para algum $c(\mathbf{x}, \mathbf{y}) > 0$ que não depende de (μ, σ^2) , $f(\mathbf{x}; \mu, \sigma^2) = c(\mathbf{x}, \mathbf{y})f(\mathbf{y}; \mu, \sigma^2)$ para todo (μ, σ^2) . Equivalentemente,

$$\begin{aligned} c(\mathbf{x}, \mathbf{y}) &= \frac{f(\mathbf{x}; \mu, \sigma^2)}{f(\mathbf{y}; \mu, \sigma^2)} \\ &= \exp \left\{ -\frac{n(\bar{x}^2 - \bar{y}^2) - 2n\mu(\bar{x} - \bar{y}) + (n-1)(s_x^2 - s_y^2)}{2\sigma^2} \right\}. \end{aligned}$$

Como $c(\mathbf{x}, \mathbf{y})$ não depende de (μ, σ^2) , necessariamente $\bar{x} = \bar{y}$ e $s_x^2 = s_y^2$. Logo, $T(\mathbf{x}) = T(\mathbf{y})$.

($\Leftarrow$)

Se $T(\mathbf{x}) = T(\mathbf{y})$, isto é, $(\bar{x}, s_x^2) = (\bar{y}, s_y^2)$, então $f(\mathbf{x}; \mu, \sigma^2) = f(\mathbf{y}; \mu, \sigma^2)$ para todo (μ, σ^2) . Portanto, podemos tomar $c(\mathbf{x}, \mathbf{y}) = 1$.

Assim, pelo critério de suficiência mínima, $T(\mathbf{X}) = (\bar{X}, S^2)$ é estatística suficiente mínima para (μ, σ^2) .

Exemplo 3.2. Sejam $X_1, \dots, X_n$ variáveis aleatórias *i.i.d.* com distribuição $\text{Unif}(\theta, \theta + 1)$, $\theta \in \mathbb{R}$. Desejamos encontrar a estatística suficiente mínima para θ .

Considere dois possíveis valores $\mathbf{x}$ e $\mathbf{y}$ da amostra. A f.d.p. conjunta de $\mathbf{X}$ é

$$\begin{aligned} f(\mathbf{x}; \theta) &= \prod_{i=1}^n \mathbb{1}(\theta < x_i < \theta + 1) \\ &= \mathbb{1}(x_{(n)} - 1 < \theta < x_{(1)}). \end{aligned}$$

($\Rightarrow$)

Suponha que, para algum $c(\mathbf{x}, \mathbf{y}) > 0$ que não depende de θ , $f(\mathbf{x}; \theta) = c(\mathbf{x}, \mathbf{y})f(\mathbf{y}; \theta)$ para todo θ . Então, $f(\mathbf{x}; \theta) > 0 \iff f(\mathbf{y}; \theta) > 0$. Logo, os conjuntos de valores de θ para os quais ambas as densidades são positivas devem coincidir. Portanto, $(x_{(n)} - 1, x_{(1)}) = (y_{(n)} - 1, y_{(1)})$, o que implica $x_{(1)} = y_{(1)}$ e $x_{(n)} = y_{(n)}$. Assim, $T(\mathbf{x}) = T(\mathbf{y})$, onde $T(\mathbf{x}) = (x_{(1)}, x_{(n)})$.

($\Leftarrow$)

Se $T(\mathbf{x}) = T(\mathbf{y})$, então $(x_{(1)}, x_{(n)}) = (y_{(1)}, y_{(n)})$ e, portanto, $f(\mathbf{x}; \theta) = f(\mathbf{y}; \theta)$ para todo θ . Logo, podemos tomar $c(\mathbf{x}, \mathbf{y}) = 1$.

Portanto, pelo critério de suficiência mínima, $T(\mathbf{X}) = (X_{(1)}, X_{(n)})$ é estatística suficiente mínima para θ .

EXERCÍCIOS

1. Mostre que se $X_1, X_2, \dots, X_n \sim \mathbb{P}_\theta$ é uma amostra aleatória de uma família paramétrica qualquer, então

$$T(X_1, X_2, \dots, X_n) = (X_{(1)}, X_{(2)}, \dots, X_{(n)})$$

é suficiente para θ .

2. Sejam $X_1, X_2, \dots, X_n \stackrel{i.i.d.}{\sim} \mathbb{P}_\theta$ uma amostra aleatória e $x_1, x_2, \dots, x_n$ os valores observados. Para cada um dos modelos abaixo, apresente uma estatística suficiente para $\theta = (\theta_1, \theta_2)$:

(a) (Gama)

$$f(x; \theta_1, \theta_2) = \frac{\theta_2^{\theta_1}}{\Gamma(\theta_1)} x^{\theta_1-1} \exp\{-\theta_2 x\} \mathbb{1}(x \in (0, +\infty)), \theta_1, \theta_2 > 0;$$

(b) (Weibull)

$$f(x; \theta_1, \theta_2) = \theta_1 \theta_2 x^{\theta_2-1} \exp\{-\theta_1 x^{-\theta_2}\} \mathbb{1}(x \in (0, +\infty)), \theta_1, \theta_2 > 0;$$

(c) (Pareto)

$$f(x; \theta_1, \theta_2) = \theta_1 \theta_2^{\theta_1} x^{-(\theta_1+1)} \mathbb{1}(x \in (\theta_2, +\infty)), \theta_1, \theta_2 > 0.$$

(d) (Binomial negativa)

$$p(x; \theta_1, \theta_2) = \binom{x + \theta_1 - 1}{x} (1 - \theta_2)^x \theta_2^{\theta_1}, \theta_1 \in \{1, 2, \dots\}, \theta_2 \in (0, 1).$$

3. Dizemos que uma amostra aleatória tem distribuição gaussiana inversa se a densidade comum vale

$$f(x; \theta_1, \theta_2) = \sqrt{\frac{\theta_1}{2\pi x^3}} \exp\left\{-\frac{\theta_1(x - \theta_2)^2}{2\theta_2^2 x}\right\} \mathbb{1}(x \in (0, +\infty)), \theta_1, \theta_2 > 0.$$

Encontre uma estatística suficiente nos seguintes casos:

(a) $g(\theta) = \theta_1$ e θ_2 é conhecido;

(b) $g(\theta) = \theta_2$ e θ_1 é conhecido;

(c) $g(\theta) = (\theta_1, \theta_2)$, isto é, ambos são desconhecidos.

4. Seja X uma variável aleatória com distribuição $N(0, \sigma^2)$. A estatística $T(X) = |X|$ é suficiente?

5. Sejam $X_1, X_2, \dots, X_n$ variáveis aleatórias com uma distribuição discreta comum arbitrária $\mathbb{P}$ em $\{1, 2, 3\}$. Encontre uma estatística suficiente bidimensional.

6. Seja $X_1, X_2, \dots, X_n \sim \mathbb{P}_\theta$ uma amostra aleatória de uma distribuição absolutamente contínua com densidade

$$f(x; \theta) = \begin{cases} 2x/\theta^2, & x \in (0, \theta); \\ 0, & \text{caso contrário.} \end{cases}$$

(a) Encontre uma estatística suficiente T unidimensional;

(b) Determine a densidade de T .

7. Seja f uma função positiva e integrável em $(0, \infty)$. Defina $c(\theta) = (\int_{\theta}^{\infty} f(x) dx)^{-1}$ e considere $p(x; \theta) = c(\theta)f(x)$, para $x > \theta$ e $p(x; \theta) = 0$ para $x \leq \theta$. Sejam $X_1, \dots, X_n$ variáveis aleatórias *i.i.d.* com densidade comum $p(\cdot; \theta)$.

- (a) Mostre que $T(\mathbf{X}) = X_{(1)}$ é suficiente.
- (b) Mostre que $T(\mathbf{X}) = X_{(1)}$ é suficiente mínima.

8. Sejam $X_1, \dots, X_{n_1}$ e $Y_1, \dots, Y_{n_2}$ duas amostras aleatórias independentes, com distribuições $N(\mu, \sigma_x^2)$ e $N(\mu, \sigma_y^2)$, respectivamente. Seja $\mathbb{P}_{\theta}$ a distribuição conjunta dessas $n_1 + n_2$ variáveis, com $\theta = (\mu, \sigma_x^2, \sigma_y^2)$. Encontre uma estatística suficiente mínima para essa família de distribuições.

9. Sejam Z_1 e Z_2 variáveis aleatórias normais padrão independentes, com densidade comum $f(z) = \frac{\exp(-z^2/2)}{\sqrt{2\pi}}$. Suponha que X e Y estejam relacionadas a essas variáveis por $X = Z_1$ e $Y = (X + Z_2)\theta$ em que $\theta > 0$ é um parâmetro desconhecido.

- (a) Encontre a densidade conjunta de X e Y .
- (b) Suponha que $(X_1, Y_1), \dots, (X_n, Y_n)$ sejam vetores aleatórios *i.i.d.*, com distribuição comum igual à distribuição de (X, Y) obtida na parte (a), isto é,

$$\begin{pmatrix} X_i \\ Y_i \end{pmatrix} \sim \begin{pmatrix} X \\ Y \end{pmatrix}, \quad i = 1, \dots, n.$$

Encontre uma estatística suficiente mínima.