

1. INTRODUÇÃO

Definição 1.1. Um modelo estatístico $\mathcal{P} = \{\mathbb{P}_\theta : \theta \in \Theta\}$ constitui uma família exponencial s -paramétrica se cada $\mathbb{P}_\theta$ possui função de massa de probabilidade ou densidade da forma

$$p(x; \theta) = \exp \left\{ \sum_{i=1}^s \eta_i(\theta) T_i(x) - B(\theta) \right\} h(x),$$

onde $\eta_i(\theta) \in \mathbb{R}$ são denominados parâmetros naturais, $T_i(x) \in \mathbb{R}$ são estatísticas suficientes (Neyman–Fisher), $h(x)$ é denominada medida base e $B(\theta)$ é a função log-partição dada por

$$B(\theta) = \log \left[\int \exp \left\{ \sum_{i=1}^s \eta_i(\theta) T_i(x) \right\} h(x) d\mu(x) \right];$$

Famílias exponenciais desempenham um papel importante na inferência estatística. Muitas distribuições usuais, como a Normal, a Binomial e a Poisson, pertencem a essa classe. Além disso, as famílias exponenciais estão intimamente relacionadas ao conceito de suficiência e ao problema de redução de dados.

Exemplo 1.1. Considere uma variável aleatória X com distribuição de Poisson com parâmetro $\lambda > 0$, isto é,

$$p(x; \lambda) = \frac{\exp(-\lambda) \lambda^x}{x!}, \quad x \in \{0, 1, 2, \dots\}.$$

Podemos reescrever sua função de probabilidade como

$$p(x; \lambda) = \exp \{x \log(\lambda) - \lambda\} \frac{1}{x!}.$$

Portanto, a distribuição de Poisson pertence a uma família exponencial de dimensão 1, com $\eta(\lambda) = \log(\lambda)$, $T(x) = x$, $B(\lambda) = \lambda$ e $h(x) = 1/x!$.

Definição 1.2. Uma família exponencial está na forma canônica quando sua f.m.p. ou f.d.p. pode ser escrita como

$$p(x; \boldsymbol{\eta}) = \exp \left\{ \sum_{i=1}^s \eta_i T_i(x) - A(\boldsymbol{\eta}) \right\} h(x), \quad \boldsymbol{\eta} \in \mathcal{N},$$

em que $\boldsymbol{\eta} = (\eta_1, \dots, \eta_s)^\top$ é o vetor de parâmetros naturais e o espaço paramétrico natural é dado por $\mathcal{N} = \{\boldsymbol{\eta} \in \mathbb{R}^s : \int \exp \{\sum_{i=1}^s \eta_i T_i(x)\} h(x) d\mu(x) < \infty\} \subseteq \mathbb{R}^s$. A função log-partição é dada por

$$A(\boldsymbol{\eta}) = \log \left[\int \exp \left\{ \sum_{i=1}^s \eta_i T_i(x) \right\} h(x) d\mu(x) \right],$$

de modo que $\int p(x; \boldsymbol{\eta}) d\mu(x) = 1$.

A forma canônica parametriza diretamente a distribuição em termos dos parâmetros naturais $\boldsymbol{\eta}$, em vez dos parâmetros originais θ .

Exemplo 1.2 (Continuação). Para a distribuição de Poisson, temos $\eta = \log(\lambda)$. Como $\lambda = \exp(\eta)$, sua função de probabilidade pode ser escrita em termos do parâmetro natural como

$$p(x; \eta) = \exp \{ \eta x - \exp(\eta) \} \frac{1}{x!}, \quad x \in \{0, 1, 2, \dots\}.$$

Portanto, na forma canônica, $T(x) = x$, $A(\eta) = \exp(\eta)$ e $h(x) = \frac{1}{x!}$.

2. REDUÇÃO DE DIMENSÃO

Uma representação de uma família exponencial pode conter redundâncias, de modo que seja possível representá-la com um número menor de estatísticas e de parâmetros naturais. Essas redundâncias podem surgir de relações afins entre as estatísticas ou entre os parâmetros naturais. Quando nenhuma dessas formas de redução é possível, dizemos que a representação da família exponencial é minimal.

Definição 2.1. Uma família exponencial na forma canônica $\mathcal{P} = \{\mathbb{P}_\eta : \eta \in \mathcal{H}\}$, $\mathcal{H} \subseteq \mathcal{N}$, é denominada minimal se

- $\sum_{i=1}^s \lambda_i T_i(x) = \lambda_0$ para todo x implica que $\lambda_0 = \lambda_1 = \dots = \lambda_s = 0$;
- $\sum_{i=1}^s \lambda_i \eta_i = \lambda_0$ para todo $\eta \in \mathcal{H}$ implica que $\lambda_0 = \lambda_1 = \dots = \lambda_s = 0$.

Portanto, em uma família exponencial minimal não existem restrições afins não triviais entre as estatísticas suficientes nem entre os parâmetros naturais.

Definição 2.2. Considere uma família exponencial s -paramétrica minimal, $\mathcal{P} = \{\mathbb{P}_\eta : \eta \in \mathcal{H}\}$. Se $\mathcal{H}$ tem dimensão s , isto é, contém um conjunto aberto de dimensão s , então $\mathcal{P}$ é denominada família exponencial de posto completo. Caso contrário, $\mathcal{P}$ é denominada família exponencial curva (*curved*).

Em uma família exponencial minimal curva, os parâmetros naturais não variam livremente em s dimensões. Tipicamente, estão relacionados por uma ou mais restrições não lineares.

Exemplo 2.1. Considere $X \sim N(\mu, \sigma^2)$. Sua função densidade pode ser escrita como

$$f(x; \mu, \sigma^2) = \exp \left\{ -\frac{1}{2\sigma^2} x^2 + \frac{\mu}{\sigma^2} x - \frac{\mu^2}{2\sigma^2} - \frac{1}{2} \log(2\pi\sigma^2) \right\}.$$

Portanto, podemos considerar $(\eta_1, \eta_2) = (1/2\sigma^2, \mu/\sigma^2)$ e $T(X) = (T_1(X), T_2(X)) = (-x^2, x)$. Podemos distinguir três situações:

- Não minimal: se $\mu = \sigma^2$, então $\eta_2 = 1$, de modo que os parâmetros naturais satisfazem uma restrição afim. Portanto, a dimensão da família pode ser reduzida.
- Minimal e curva: se $\mu = \sqrt{\sigma^2}$, então $\eta_2^2 = 2\eta_1$. A relação entre os parâmetros naturais é não linear. A família é, portanto, minimal, mas curva.
- Minimal e de posto completo: se não há restrições adicionais sobre μ e σ^2 , o espaço dos parâmetros naturais é $\mathcal{H} = (0, \infty) \times \mathbb{R}$. A família é minimal e de posto completo.

Os conceitos de família exponencial minimal e estatística suficiente mínima estão relacionados. Em particular, para uma família exponencial minimal, a estatística suficiente é mínima.

Considere uma família exponencial minimal. Se $X_1, \dots, X_n$ são variáveis aleatórias *i.i.d.* com distribuição pertencente a essa família, então a função de probabilidade ou densidade conjunta da amostra pode ser escrita como

$$p(\mathbf{x}; \boldsymbol{\eta}) = \exp \left\{ \sum_{j=1}^s \eta_j \sum_{i=1}^n T_j(x_i) - nA(\boldsymbol{\eta}) \right\} \prod_{i=1}^n h(x_i).$$

Tome duas realizações $\mathbf{x}$ e $\mathbf{y}$. A razão entre suas funções de probabilidade ou densidade é

$$\frac{p(\mathbf{x}; \boldsymbol{\eta})}{p(\mathbf{y}; \boldsymbol{\eta})} = \frac{\prod_{i=1}^n h(x_i)}{\prod_{i=1}^n h(y_i)} \exp \left\{ \sum_{j=1}^s \eta_j \left[\sum_{i=1}^n T_j(x_i) - \sum_{i=1}^n T_j(y_i) \right] \right\}.$$

Se a expressão no expoente é constante em $\boldsymbol{\eta}$, então, pela minimalidade da família,

$$\sum_{i=1}^n T_j(x_i) - \sum_{i=1}^n T_j(y_i) = 0, \quad j = 1, \dots, s.$$

A recíproca é imediata. Portanto, a razão acima é independente de $\boldsymbol{\eta}$ se, e somente se,

$$\sum_{i=1}^n T_j(x_i) = \sum_{i=1}^n T_j(y_i), \quad j = 1, \dots, s.$$

Logo, $T(\mathbf{X}) = (\sum_{i=1}^n T_1(X_i), \dots, \sum_{i=1}^n T_s(X_i))$ é estatística suficiente mínima.

3. IDENTIDADES DIFERENCIAIS

Considerando uma família exponencial na forma canônica, temos que

$$(1) \quad \exp\{A(\boldsymbol{\eta})\} = \int \exp \left\{ \sum_{i=1}^s \eta_i T_i(x) \right\} h(x) d\mu(x).$$

Para $\boldsymbol{\eta}$ no interior do espaço paramétrico natural, podemos obter importantes propriedades da família exponencial diferenciando (1) sob o sinal de integração.

Esperança de $T(\mathbf{X})$. Diferenciando (1) em relação a η_j , $j = 1, 2, \dots, s$, temos

$$\begin{aligned} \frac{\partial}{\partial \eta_j} \exp\{A(\boldsymbol{\eta})\} &= \frac{\partial}{\partial \eta_j} \int \exp \left\{ \sum_{i=1}^s \eta_i T_i(x) \right\} h(x) d\mu(x) \\ &= \int \frac{\partial}{\partial \eta_j} \exp \left\{ \sum_{i=1}^s \eta_i T_i(x) \right\} h(x) d\mu(x) \quad (\text{Teorema 2.4 Keener}) \\ &= \int T_j(x) \exp \left\{ \sum_{i=1}^s \eta_i T_i(x) \right\} h(x) d\mu(x). \end{aligned}$$

Por outro lado,

$$\frac{\partial}{\partial \eta_j} \exp\{A(\boldsymbol{\eta})\} = \exp\{A(\boldsymbol{\eta})\} \frac{\partial A(\boldsymbol{\eta})}{\partial \eta_j}.$$

Portanto,

$$\begin{aligned} \frac{\partial A(\boldsymbol{\eta})}{\partial \eta_j} &= \int T_j(x) \exp \left\{ \sum_{i=1}^s \eta_i T_i(x) - A(\boldsymbol{\eta}) \right\} h(x) d\mu(x) \\ &= E_{\boldsymbol{\eta}} [T_j(X)]. \end{aligned}$$

Em forma vetorial,

$$\boxed{\nabla A(\boldsymbol{\eta}) = \mathbf{E}_{\boldsymbol{\eta}} [T(X)] .}$$

Variância de $T(\mathbf{X})$. Diferenciando novamente em relação a η_k , $k = 1, 2, \dots, s$, obtemos

$$\frac{\partial^2}{\partial \eta_j \partial \eta_k} \exp\{A(\boldsymbol{\eta})\} = \int T_j(x) T_k(x) \exp\left\{\sum_{i=1}^s \eta_i T_i(x)\right\} h(x) d\mu(x).$$

Por outro lado,

$$\frac{\partial^2}{\partial \eta_j \partial \eta_k} \exp\{A(\boldsymbol{\eta})\} = \exp\{A(\boldsymbol{\eta})\} \left[\frac{\partial^2 A(\boldsymbol{\eta})}{\partial \eta_j \partial \eta_k} + \frac{\partial A(\boldsymbol{\eta})}{\partial \eta_j} \frac{\partial A(\boldsymbol{\eta})}{\partial \eta_k} \right].$$

Portanto,

$$\begin{aligned} \frac{\partial^2 A(\boldsymbol{\eta})}{\partial \eta_j \partial \eta_k} + \mathbf{E}_{\boldsymbol{\eta}} [T_j(X)] \mathbf{E}_{\boldsymbol{\eta}} [T_k(X)] &= \int T_j(x) T_k(x) \exp\left\{\sum_{i=1}^s \eta_i T_i(x) - A(\boldsymbol{\eta})\right\} h(x) d\mu(x) \\ \frac{\partial^2 A(\boldsymbol{\eta})}{\partial \eta_j \partial \eta_k} &= \text{Cov}_{\boldsymbol{\eta}} (T_j(X), T_k(X)). \end{aligned}$$

Em forma matricial,

$$\boxed{\nabla^2 A(\boldsymbol{\eta}) = \text{Var}_{\boldsymbol{\eta}} [T(X)] .}$$

Exemplo 3.1. Retomando o exemplo da distribuição de Poisson, temos, na forma canônica, que $T(X) = X$, $\eta = \log(\lambda)$ e $A(\eta) = \exp(\eta)$. Assim, $\mathbf{E}_{\eta}[X] = A'(\eta) = \exp(\eta) = \lambda$ e $\text{Var}_{\eta}(X) = A''(\eta) = \exp(\eta) = \lambda$.

Função Geradora de Momentos e Função Geradora de Cumulantes. Na família exponencial, a função geradora de momentos de $T(X)$ (para $X \sim \mathbb{P}_{\eta}$) é dada por

$$\begin{aligned} M_{\boldsymbol{\eta}}^{T(X)}(\mathbf{u}) &= \mathbf{E}_{\boldsymbol{\eta}} [\exp\{\mathbf{u}^{\top} T(X)\}] \\ &= \int \exp\{\mathbf{u}^{\top} T(x)\} \exp\{\boldsymbol{\eta}^{\top} T(x) - A(\boldsymbol{\eta})\} h(x) d\mu(x) \\ &= \exp\{-A(\boldsymbol{\eta})\} \int \exp\{(\boldsymbol{\eta} + \mathbf{u})^{\top} T(x)\} h(x) d\mu(x) \\ &= \exp\{A(\boldsymbol{\eta} + \mathbf{u}) - A(\boldsymbol{\eta})\}. \end{aligned}$$

Portanto,

$$\boxed{M_{\boldsymbol{\eta}}^{T(X)}(\mathbf{u}) = \exp\{A(\boldsymbol{\eta} + \mathbf{u}) - A(\boldsymbol{\eta})\} .}$$

Consequentemente, a função geradora de cumulantes é dada por

$$K_{\boldsymbol{\eta}}^{T(X)}(\mathbf{u}) = \log M_{\boldsymbol{\eta}}^{T(X)}(\mathbf{u}) = A(\boldsymbol{\eta} + \mathbf{u}) - A(\boldsymbol{\eta}).$$

As derivadas de $K_{\boldsymbol{\eta}}^{T(X)}(\mathbf{u})$ avaliadas em $\mathbf{u} = \mathbf{0}$ fornecem os cumulantes de $T(X)$. Em particular, os dois primeiros cumulantes correspondem à esperança e à matriz de variâncias e covariâncias. Como

$$\left. \frac{\partial}{\partial u_j} K_{\boldsymbol{\eta}}^{T(X)}(\mathbf{u}) \right|_{\mathbf{u}=\mathbf{0}} = \frac{\partial}{\partial \eta_j} A(\boldsymbol{\eta}),$$

essa relação explica por que os cumulantes de $T(X)$ sob $\mathbb{P}_{\boldsymbol{\eta}}$ podem ser obtidos diferenciando a função log-partição $A(\boldsymbol{\eta})$.

EXERCÍCIOS

1. Considere ensaios de Bernoulli independentes com probabilidade de sucesso θ e X o número de fracassos antes do primeiro sucesso. Então, $\mathbb{P}_\theta(X = x) = \theta(1 - \theta)^x$, para $x = 0, 1, \dots$, e X possui distribuição Geométrica com parâmetro θ .

- (a) Mostre que as distribuições Geométricas formam uma família exponencial.
- (b) Escreva as funções de probabilidade da família na forma canônica, identificando o parâmetro natural η e a função $A(\eta)$.
- (c) Encontre a esperança da distribuição Geométrica utilizando uma identidade diferencial.
- (d) Suponha que $X_1, \dots, X_n$ sejam variáveis aleatórias *i.i.d.* com distribuição Geométrica. Mostre que as distribuições conjuntas formam uma família exponencial e encontre a esperança e a variância de T .

2. Encontre o espaço paramétrico natural $\mathcal{N}$ e as densidades f_η da família exponencial canônica uniparamétrica, com μ sendo a medida de Lebesgue em $\mathbb{R}$, $T_1(x) = \log x$ e $h(x) = (1 - x)^2$, $x \in (0, 1)$, e $h(x) = 0$, $x \notin (0, 1)$.

3. Encontre o espaço paramétrico natural $\mathcal{N}$ e as densidades f_η da família exponencial canônica uniparamétrica, com μ sendo a medida de Lebesgue em $\mathbb{R}$, $T_1(x) = -x$ e $h(x) = e^{-2\sqrt{x}}/\sqrt{x}$, $x > 0$, e $h(x) = 0$, $x \leq 0$. Determine também a esperança e a variância de uma variável aleatória X com essa densidade.

Dica: após uma mudança de variável, as integrais relevantes terão a forma de integrais em relação a uma densidade Normal. A resposta pode ser expressa em termos de Φ , a função de distribuição acumulada da Normal padrão.

4. Considere uma família exponencial na forma canônica $p(x; \boldsymbol{\eta}) = \exp \{ \boldsymbol{\eta}^\top T(x) - A(\boldsymbol{\eta}) \} h(x)$ com espaço paramétrico natural

$$\mathcal{N} = \left\{ \boldsymbol{\eta} \in \mathbb{R}^s : \int \exp \{ \boldsymbol{\eta}^\top T(x) \} h(x) d\mu(x) < \infty \right\}.$$

Utilizando a desigualdade de Hölder, mostre que $\mathcal{N}$ é um conjunto convexo.

5. (Truncamento). Considere uma família exponencial de densidades $\{p(\cdot; \theta) : \theta \in \Theta\}$ com respeito a uma medida μ , em que

$$p(x; \theta) = h(x) \exp \left\{ \sum_{i=1}^s \eta_i(\theta) T_i(x) - B(\theta) \right\}.$$

Em algumas situações, uma observação potencial X , com densidade $p(x; \theta)$, somente pode ser observada se pertencer a uma determinada região S . Assuma que $\Lambda(\theta) = \mathbb{P}_\theta(X \in S) > 0$. Nesse caso, a distribuição apropriada para a variável observada Y é definida por

$$\mathbb{P}_\theta(Y \in B) = \mathbb{P}_\theta(X \in B \mid X \in S), \quad B \in \mathcal{B}.$$

Essa distribuição é denominada truncamento da distribuição de X ao conjunto S .

- (a) Mostre que Y possui densidade com respeito a μ e obtenha uma expressão para sua densidade $q(\cdot; \theta)$.
- (b) Mostre que a família de densidades $\{q(\cdot; \theta) : \theta \in \Theta\}$ constitui uma família exponencial.

6. Um modelo clássico em genética é o modelo multinomial de ligação genética. Considere

$$(X_1, X_2, X_3, X_4) \sim \text{Multinomial} \left(n; \frac{1}{2} + \frac{\theta}{4}, \frac{1}{4}(1 - \theta), \frac{1}{4}(1 - \theta), \frac{\theta}{4} \right), \quad 0 < \theta < 1.$$

Mostre que esse modelo constitui uma família exponencial curva.

7. Para uma família exponencial na forma canônica, temos $E_\eta[T_j(X)] = \partial A(\boldsymbol{\eta}) / \partial \eta_j$ ou, em forma vetorial, $E_\eta[T(X)] = \nabla A(\boldsymbol{\eta})$. Obtenha uma identidade diferencial análoga para $E_\theta[T(X)]$ no caso de uma família exponencial s -paramétrica que não esteja na forma canônica. Suponha que o espaço paramétrico de θ tenha dimensão s .

Dica: a diferenciação sob o sinal de integração deve produzir um sistema de equações lineares. Escreva esse sistema em forma matricial.

8. Seja $Z \sim N(0, 1)$. Encontre os dois primeiros cumulantes de Z^2 . *Dica:* Considere a família exponencial $N(0, \sigma^2)$.

9. Sejam X e Y variáveis aleatórias independentes com distribuição Normal padrão. Encontre os dois primeiros cumulantes de $T = XY$.