

1. ESTATÍSTICA ANCILAR

Vimos que uma estatística suficiente permite reduzir os dados sem perda de informação sobre o parâmetro de interesse. A noção de suficiência mínima formaliza a maior redução possível nesse sentido.

Porém, suficiência e suficiência mínima implicam necessariamente uma redução significativa dos dados? Há casos em que mesmo uma estatística suficiente mínima preserva grande parte dos dados originais?

Exemplo 1.1. Considere $X_1, \dots, X_n \stackrel{i.i.d.}{\sim} \text{Laplace}(\theta, 1)$, $\theta \in \mathbb{R}$. A densidade conjunta da amostra é dada por

$$f(\mathbf{x}; \theta) = \frac{1}{2^n} \exp \left\{ - \sum_{i=1}^n |x_i - \theta| \right\}.$$

Como a soma é invariante a permutações dos elementos da amostra, podemos escrever

$$f(\mathbf{x}; \theta) = \frac{1}{2^n} \exp \left\{ - \sum_{i=1}^n |x_{(i)} - \theta| \right\}.$$

Portanto, pelo Teorema da Fatoração de Neyman–Fisher, $T(\mathbf{X}) = (X_{(1)}, \dots, X_{(n)})$ é uma estatística suficiente para θ .

Para verificar que $T(\mathbf{X})$ é suficiente mínima, considere duas realizações $\mathbf{x}$ e $\mathbf{y}$. Logo,

$$\frac{f(\mathbf{x}; \theta)}{f(\mathbf{y}; \theta)} = \exp\{-G_{\mathbf{x}}(\theta) + G_{\mathbf{y}}(\theta)\},$$

onde $G_{\mathbf{x}}(\theta) = \sum_{i=1}^n |x_{(i)} - \theta|$ e $G_{\mathbf{y}}(\theta) = \sum_{i=1}^n |y_{(i)} - \theta|$
($\Rightarrow$)

Suponha que a razão acima não dependa de θ . Então, $G_{\mathbf{x}}(\theta) - G_{\mathbf{y}}(\theta) = c(\mathbf{x}, \mathbf{y})$ e, consequentemente, $G'_{\mathbf{x}}(\theta) = G'_{\mathbf{y}}(\theta)$ em todos os pontos em que as derivadas existem. Logo, os pontos de mudança de inclinação de $G_{\mathbf{x}}(\theta)$ e $G_{\mathbf{y}}(\theta)$ são os mesmos, com os mesmos saltos. Como esses pontos são exatamente os valores x_i e y_i , então $\mathbf{x}$ e $\mathbf{y}$ possuem os mesmos valores. Consequentemente, $T(\mathbf{x}) = T(\mathbf{y})$.

($\Leftarrow$)

Se $T(\mathbf{x}) = T(\mathbf{y})$, então $\mathbf{x}$ e $\mathbf{y}$ possuem exatamente os mesmos valores, considerando multiplicidades, podendo diferir apenas na ordem. Portanto,

$$\sum_{i=1}^n |x_i - \theta| = \sum_{i=1}^n |y_i - \theta| \quad \forall \theta \Rightarrow f(\mathbf{x}; \theta) = f(\mathbf{y}; \theta) \quad \forall \theta.$$

Pelo critério de suficiência mínima, $T(\mathbf{X}) = (X_{(1)}, \dots, X_{(n)})$ é estatística suficiente mínima para θ .

Neste caso, como podemos entender essa capacidade limitada de redução dos dados? Uma possível explicação está relacionada à presença de informação ancilar na própria estatística suficiente mínima.

Definição 1.1. Uma estatística $S(\mathbf{X})$ é denominada ancilar se sua distribuição não depende de θ .

Exemplo 1.2 (Continuação). Para o caso $X_1, \dots, X_n \stackrel{i.i.d.}{\sim} \text{Laplace}(\theta, 1)$, $\theta \in \mathbb{R}$, considere

$$S(\mathbf{X}) = X_{(n)} - X_{(1)}.$$

Como a distribuição de Laplace é uma família de locação, podemos escrever

$$X_i = \theta + Z_i,$$

onde $Z_1, \dots, Z_n \stackrel{i.i.d.}{\sim} \text{Laplace}(0, 1)$. Consequentemente,

$$\begin{aligned} S(\mathbf{X}) &= X_{(n)} - X_{(1)} \\ &= (\theta + Z_{(n)}) - (\theta + Z_{(1)}) \\ &= Z_{(n)} - Z_{(1)}. \end{aligned}$$

Portanto, a distribuição de $S(\mathbf{X})$ não depende de θ e, consequentemente, $S(\mathbf{X})$ é uma estatística ancilar para θ .

A definição estabelece que a distribuição de uma estatística ancilar não depende do parâmetro de interesse. Isso significa que, considerada isoladamente, uma estatística ancilar não fornece informação sobre o parâmetro. Entretanto, quando considerada em conjunto com outras estatísticas, seu valor observado pode desempenhar um papel relevante na inferência, como ilustra o exemplo a seguir.

Exemplo 1.3. Considere X_1 e X_2 variáveis aleatórias *i.i.d.* com $\mathbb{P}_\theta(X_i = \theta) = \mathbb{P}_\theta(X_i = \theta + 1) = \mathbb{P}_\theta(X_i = \theta + 2) = 1/3$, onde $\theta \in \mathbb{Z}$. Sejam $X_{(1)} \leq X_{(2)}$ as estatísticas de ordem da amostra e considere

$$R = X_{(2)} - X_{(1)} \quad \text{e} \quad M = \frac{X_{(1)} + X_{(2)}}{2}.$$

Como esse modelo constitui uma família de locação, podemos escrever $X_i = \theta + Z_i$, onde Z_i assume os valores 0, 1 e 2, cada um com probabilidade 1/3. Consequentemente,

$$R = X_{(2)} - X_{(1)} = Z_{(2)} - Z_{(1)}.$$

Logo, a distribuição de R não depende de θ e, portanto, R é uma estatística ancilar.

Embora R , isoladamente, não forneça informação sobre θ , seu valor observado pode ser informativo quando considerado em conjunto com outras estatísticas.

Suponha, por exemplo, que $M = m$, onde $m \in \mathbb{Z}$. Então, $\theta \in \{m, m-1, m-2\}$. Adicionalmente, suponha que observamos $R = 2$. Nesse caso, necessariamente

$$X_{(1)} = \theta \quad \text{e} \quad X_{(2)} = \theta + 2.$$

Consequentemente, $m = \theta + 1$ e $\theta = m - 1$.

Portanto, embora a distribuição marginal de R não dependa de θ , o conhecimento de seu valor, quando combinado com M , pode fornecer informação adicional sobre θ .

2. COMPLETUDE

Como vimos, uma estatística suficiente mínima pode ainda conter funções ancilares não triviais. A completude é uma condição adicional que, quando combinada à suficiência, confere propriedades mais fortes à estatística suficiente.

Definição 2.1. Uma estatística $T(X)$ é completa para uma família $\mathcal{P} = \{\mathbb{P}_\theta : \theta \in \Theta\}$ se $\mathbb{E}_\theta[h(T(X))] = c$ para todo $\theta \in \Theta$ implica que $h(T(X)) = c$, $\mathbb{P}_\theta$ -q.c., para todo $\theta \in \Theta$.

Exemplo 2.1. Considere $X_1, \dots, X_n \stackrel{i.i.d.}{\sim} \text{Unif}(0, \theta)$, $\theta > 0$. Vimos, anteriormente, que $T(\mathbf{X}) = X_{(n)}$ é uma estatística suficiente para θ . Desejamos verificar se $T(\mathbf{X})$ é completa. A densidade de $T(\mathbf{X})$ é dada por

$$g(t; \theta) = \frac{nt^{n-1}}{\theta^n} \mathbb{1}(0 < t < \theta).$$

Suponha que, para alguma função h , $E_\theta[h(T(\mathbf{X}))] = c$ para todo $\theta > 0$. Então,

$$\int_0^\theta h(t) \frac{nt^{n-1}}{\theta^n} dt = c \quad \Rightarrow \quad \int_0^\theta h(t) nt^{n-1} dt = c\theta^n.$$

Derivando ambos os lados em relação a θ , obtemos

$$h(\theta)n\theta^{n-1} = cn\theta^{n-1}$$

para quase todo $\theta > 0$. Portanto, $h(\theta) = c$ para quase todo $\theta > 0$, o que implica que $h(T(\mathbf{X})) = c$, $\mathbb{P}_\theta$ -q.c., para todo $\theta > 0$. Logo, $T(\mathbf{X}) = X_{(n)}$ é uma estatística completa para θ .

Teorema 2.1. Se a estatística $T(X)$ é suficiente e completa, então $T(X)$ é suficiente mínima.

Como $T(\mathbf{X}) = X_{(n)}$ é suficiente e completa para θ , segue do Teorema anterior que $T(\mathbf{X})$ é também suficiente mínima.

O teorema a seguir formaliza a relação entre suficiência, completude e ancilaridade.

Teorema 2.2 (Teorema de Basu). Se a estatística $T(X)$ é suficiente e completa para $\mathcal{P} = \{\mathbb{P}_\theta : \theta \in \Theta\}$ e $S(X)$ é ancilar, então $T(X)$ e $S(X)$ são independentes sob $\mathbb{P}_\theta$ para todo $\theta \in \Theta$.

Exemplo 2.2. Considere novamente $X_1, \dots, X_n \stackrel{i.i.d.}{\sim} \text{Unif}(0, \theta)$, $\theta > 0$. Como vimos, $T(\mathbf{X}) = X_{(n)}$ é uma estatística suficiente e completa para θ .

Considere agora $S(\mathbf{X}) = X_{(1)}/X_{(n)}$. Como podemos escrever $X_i = \theta U_i$, onde $U_1, \dots, U_n \stackrel{i.i.d.}{\sim} \text{Unif}(0, 1)$, temos que

$$S(\mathbf{X}) = \frac{\theta U_{(1)}}{\theta U_{(n)}} = \frac{U_{(1)}}{U_{(n)}}.$$

Portanto, a distribuição de $S(\mathbf{X})$ não depende de θ , de modo que $S(\mathbf{X})$ é uma estatística ancilar. Pelo Teorema de Basu, como $T(\mathbf{X}) = X_{(n)}$ é suficiente e completa e $S(\mathbf{X})$ é ancilar, segue que

$$X_{(n)} \quad \text{e} \quad \frac{X_{(1)}}{X_{(n)}}$$

são independentes.

O Teorema de Basu é útil por permitir deduzir a independência entre duas estatísticas sem que seja necessário encontrar sua distribuição conjunta. Para utilizar o Teorema de Basu, contudo, precisamos mostrar que uma estatística é completa, o que, por vezes, pode ser relativamente difícil. Felizmente, boa parte dos modelos de nosso interesse é contemplada pelo teorema a seguir.

Teorema 2.3. Em uma família exponencial de posto completo, a estatística suficiente $T(X)$ é completa.

Exemplo 2.3. Considere $X_1, \dots, X_n \stackrel{i.i.d.}{\sim} N(\mu, \sigma^2)$, com σ^2 conhecida. A densidade conjunta da amostra pode ser escrita como

$$f(\mathbf{x}; \mu) = (2\pi\sigma^2)^{-n/2} \exp \left\{ \frac{\mu}{\sigma^2} \sum_{i=1}^n x_i - \frac{1}{2\sigma^2} \sum_{i=1}^n x_i^2 - \frac{n\mu^2}{2\sigma^2} \right\}.$$

Portanto, pelo Teorema da Fatoração de Neyman–Fisher, $T(\mathbf{X}) = \sum_{i=1}^n X_i$, ou equivalentemente $T(\mathbf{X}) = \bar{X}$, é uma estatística suficiente para μ .

Além disso, a família é exponencial com parâmetro natural $\eta = \mu/\sigma^2$ e o espaço dos parâmetros naturais é $\mathcal{H} = \mathbb{R}$. Logo, a família exponencial é de posto completo e, conseqüentemente, $\bar{X}$ é uma estatística completa para μ .

Por outro lado, vimos que

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2,$$

de modo que a distribuição de S^2 não depende de μ . Portanto, S^2 é uma estatística ancilar para μ .

Como $\bar{X}$ é suficiente e completa para μ e S^2 é ancilar, segue do Teorema de Basu que $\bar{X} \perp S^2$.

EXERCÍCIOS

1. Uma possível estatística ancilar, na maioria dos problemas, é o tamanho da amostra. Por exemplo, seja N uma variável aleatória que assume os valores $1, 2, \dots$ com probabilidades conhecidas $p_1, p_2, \dots$, onde $\sum p_i = 1$. Uma vez que $N = n$ é observado, realizam-se n ensaios de Bernoulli com probabilidade θ e obtêm-se X sucessos. Prove que o par (X, N) é estatística suficiente mínima e que N é ancilar para θ .

2. Suponha que X_1 e X_2 sejam variáveis aleatórias *i.i.d.* com f.d.p. $f(x; \alpha) = \alpha x^{\alpha-1} \exp^{-x^\alpha}$, $x > 0$, $\alpha > 0$. Mostre que $\log X_1 / \log X_2$ é uma estatística ancilar.

3. Sejam $X_1, \dots, X_n$ variáveis aleatórias com distribuição na família de locação. Mostre que $M - \bar{X}$ é uma estatística ancilar, onde M é a mediana amostral.

4. Sejam $X_1, \dots, X_n$ variáveis aleatórias *i.i.d.* com distribuição absolutamente contínua com densidade

$$f(x; \theta) = \begin{cases} 2x/\theta^2, & x \in (0, \theta); \\ 0, & \text{caso contrário.} \end{cases}$$

(a) Encontre uma estatística suficiente unidimensional $T(X)$.

(b) Determine a densidade de $T(X)$.

(c) Mostre diretamente que $T(X)$ é completa.

5. Considere o caso $X_1, \dots, X_n \stackrel{i.i.d.}{\sim} \text{Exp}(\lambda)$.

(a) Encontre a densidade de $Y = \lambda X$.

(b) Mostre que $\bar{X} = \sum_{i=1}^n X_i/n$ e $(\sum_{i=1}^n X_i^2)/\bar{X}^2$ são independentes.

6. Sejam X e Y variáveis aleatórias independentes com distribuição de Poisson com médias θ e θ^2 ($\theta > 0$), respectivamente.

(a) Encontre uma estatística suficiente mínima para a família de distribuições conjuntas.

(b) A estatística encontrada no item (a) é completa? Explique.

7. Sejam $(X_1, Y_1), \dots, (X_n, Y_n)$ *i.i.d.* e absolutamente contínuas com densidade

$$f(x, y; \theta) = \begin{cases} 2/\theta^2, & x > 0, y > 0, x + y < \theta; \\ 0, & \text{caso contrário.} \end{cases}$$

(a) Encontre uma estatística suficiente mínima para a família de distribuições conjuntas.

(b) Determine a densidade da estatística suficiente mínima encontrada no item (a).

(c) A estatística encontrada no item (a) é completa?

8. Sejam $X_1, \dots, X_n$ variáveis aleatórias *i.i.d.* e absolutamente contínuas com densidade

$$f(x; \theta) = \begin{cases} \theta e^{-\theta x}, & x > 0; \\ 0, & \text{caso contrário,} \end{cases}$$

onde $\theta > 0$ é um parâmetro desconhecido.

(a) Encontre a densidade de θX_i .

(b) Sejam $X_{(1)} \leq \dots \leq X_{(n)}$ estatísticas de ordem e $\bar{X} = \sum_{i=1}^n X_i/n$ a média amostral. Mostre que $\bar{X}$ e $X_{(1)}/X_{(n)}$ são independentes.

9. Considere o caso $X_1, \dots, X_n \stackrel{i.i.d.}{\sim} \text{Unif}(-\theta, \theta)$, onde $\theta > 0$ é um parâmetro desconhecido.

(a) Encontre uma estatística suficiente mínima $T(\mathbf{X})$.

(b) Defina $V(\mathbf{X}) = \bar{X}/(X_{(n)} - X_{(1)})$, onde $\bar{X} = \sum_{i=1}^n X_i/n$ a média amostral. Mostre que $T(\mathbf{X})$ e $V(\mathbf{X})$ são independentes.