

1. INTRODUÇÃO

Suponha um modelo estatístico paramétrico $\mathcal{P} = \{\mathbb{P}_\theta : \theta \in \Theta\}$ e assumamos que uma amostra aleatória $\mathbf{X} = (X_1, \dots, X_n)$ possui distribuição $\mathbb{P}_\theta$, para algum parâmetro desconhecido $\theta \in \Theta$. A partir de agora, veremos como utilizar os dados observados para realizar inferência sobre θ , ou sobre alguma função de θ , e como os conceitos de redução de dados estudados anteriormente estão conectados aos procedimentos de inferência. Para tal, trataremos o problema de inferência estatística como um problema de decisão.

Um procedimento de decisão é uma função que associa a cada possível realização da amostra uma decisão $d \in \mathcal{D}$, i.e.,

$$\delta : \mathbb{R}^n \longrightarrow \mathcal{D},$$

onde $\mathcal{D}$ é denominado espaço de decisões. Em particular, no problema de estimação pontual, a decisão consiste em escolher um valor para representar o parâmetro desconhecido θ . Nesse caso, o procedimento de decisão δ é denominado estimador de θ .

Exemplo 1.1. Considere $X_1, \dots, X_n \stackrel{i.i.d.}{\sim} \text{Bernoulli}(\theta)$, onde $\theta \in [0, 1]$ representa a probabilidade de sucesso. Suponha que nosso interesse seja estimar θ .

Neste caso, o espaço de decisões é $\mathcal{D} = [0, 1]$. Um possível estimador para θ é a média amostral,

$$\delta(\mathbf{X}) = \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i,$$

de modo que $\delta : \{0, 1\}^n \rightarrow [0, 1]$.

2. FUNÇÃO DE PERDA E RISCO

Para comparar diferentes procedimentos de decisão, precisamos estabelecer um critério que quantifique as consequências das decisões tomadas. Uma função de perda é um mapa $L : \Theta \times \mathcal{D} \rightarrow \mathbb{R}_+$, onde $L(\theta, d)$ representa a perda associada à decisão d quando θ é o verdadeiro valor do parâmetro.

Exemplo 2.1 (Perda quadrática). Para estimar um parâmetro real θ , com espaço de decisões $\mathcal{D} = \mathbb{R}$, uma função de perda comumente utilizada é a perda quadrática, definida por

$$L(\theta, d) = (\theta - d)^2, \quad d \in \mathbb{R}.$$

Note que um procedimento de decisão $\delta(\mathbf{X})$ depende da amostra observada e, portanto, é uma variável aleatória. Para avaliá-lo, consideramos a perda esperada associada à sua utilização. A função de risco de um procedimento de decisão δ é definida por

$$R(\theta, \delta) = \mathbb{E}_\theta [L(\theta, \delta(\mathbf{X}))], \quad \theta \in \Theta.$$

Assim, para cada valor de θ , $R(\theta, \delta)$ representa a perda média associada à utilização do procedimento δ quando os dados são gerados segundo $\mathbb{P}_\theta$.

A função de risco fornece, portanto, um critério para comparar diferentes procedimentos de decisão. Dizemos que um procedimento δ_1 domina um procedimento δ_2 se

$$R(\theta, \delta_1) \leq R(\theta, \delta_2), \quad \forall \theta \in \Theta,$$

com desigualdade estrita para pelo menos um valor $\theta_0 \in \Theta$. Nesse caso, δ_2 é denominado inadmissível.

Exemplo 2.2. Considere $X_1, X_2 \stackrel{i.i.d.}{\sim} \text{Bernoulli}(\theta)$, $\theta \in [0, 1]$, e suponha que nosso interesse seja estimar θ .

Sob uma função de perda quadrática, $L(\theta, d) = (\theta - d)^2$, note que para n ensaios de Bernoulli independentes com probabilidade de sucesso θ , considerando $\delta_n(\mathbf{X}) = \bar{X} = \sum_{i=1}^n X_i/n$, temos que

$$R(\theta, \delta_n) = \frac{\theta(1 - \theta)}{n}.$$

Assumindo um estimador que utiliza apenas a primeira observação, $\delta_1(\mathbf{X}) = X_1$, e outro que utiliza as duas observações disponíveis, $\delta_2(\mathbf{X}) = (X_1 + X_2)/2$, temos que

$$R(\theta, \delta_1) = \theta(1 - \theta) \text{ e } R(\theta, \delta_2) = [\theta(1 - \theta)]/2.$$

Logo, $R(\theta, \delta_2) \leq R(\theta, \delta_1)$, $\forall \theta \in [0, 1]$, com desigualdade estrita para $\theta \in (0, 1)$. Consequentemente, δ_2 domina δ_1 e δ_1 é inadmissível.

Considere, entretanto, o estimador constante $\delta_0(\mathbf{X}) = 1/2$, para o qual $R(\theta, \delta_0) = (\theta - 1/2)^2$. Como $R(\theta, \delta_0) = 0$ quando $\theta = 1/2$, δ_0 é admissível. Assim, apesar de δ_0 não utilizar qualquer informação da amostra, nenhum procedimento pode apresentar risco estritamente menor que o de δ_0 quando $\theta = 1/2$.

O exemplo anterior mostra que, ao considerarmos a classe de todos os procedimentos de decisão, podemos obter procedimentos com propriedades pouco desejáveis, como um estimador que não utiliza os dados observados. Uma possibilidade consiste, então, em restringir a classe de procedimentos considerados por meio de critérios adicionais. No contexto de estimação pontual, um critério comumente adotado é o de não vies.

Dizemos que um estimador δ de $g(\theta)$ é não viesado se $\mathbb{E}_\theta[\delta(\mathbf{X})] = g(\theta)$, $\forall \theta \in \Theta$.

3. TEOREMA DE RAO-BLACKWELL

Teorema 3.1 (Teorema de Rao-Blackwell). Sejam $T(\mathbf{X})$ uma estatística suficiente para $\mathcal{P} = \{\mathbb{P}_\theta : \theta \in \Theta\}$ e $\delta(\mathbf{X})$ um estimador de $g(\theta)$, defina $\eta(T(\mathbf{X})) = \mathbb{E}[\delta(\mathbf{X})|T(\mathbf{X})]$. Se $\theta \in \Theta$, $R(\theta, \delta) < \infty$ e $L(\theta, \cdot)$ é convexa, então

$$R(\theta, \eta) \leq R(\theta, \delta).$$

Se $L(\theta, \cdot)$ é estritamente convexa, a desigualdade é estrita a menos que $\delta(\mathbf{X}) = \eta(T(\mathbf{X}))$ ($\mathbb{P}_\theta$ -q.c.)

Como $T(\mathbf{X})$ é suficiente, a distribuição condicional de $\mathbf{X}$ dado $T(\mathbf{X})$ não depende de θ . Portanto, $\eta(T(\mathbf{X}))$ é uma função de $T(\mathbf{X})$ que não depende do parâmetro desconhecido e constitui, de fato, um estimador.

Exemplo 3.1. Considere $X_1, \dots, X_n \stackrel{i.i.d.}{\sim} \text{Bernoulli}(\theta)$, $\theta \in (0, 1)$, e a função perda $L(\theta, d) = (\theta - d)^2$. Suponha que desejamos estimar θ através do estimador $\delta(\mathbf{X}) = X_1$. Vimos anteriormente

que $T(\mathbf{X}) = \sum_{i=1}^n X_i/n$ é uma estatística suficiente para θ , então aplicaremos o Teorema de Rao–Blackwell para “melhorar” o estimador $\delta(\mathbf{X})$:

$$\begin{aligned}\eta(T(\mathbf{X})) &= \mathbb{E}[\delta(\mathbf{X})|T(\mathbf{X})] \\ &= \frac{1}{n} \sum_{i=1}^n \mathbb{E}[X_i|\bar{X}] \\ &= \frac{1}{n} \sum_{i=1}^n \mathbb{E}[X_i|\bar{X}] \\ &= \mathbb{E}[\bar{X}|\bar{X}] = \bar{X}.\end{aligned}$$

Como visto no Exemplo 2.2, temos que

$$R(\theta, \eta) = \frac{\theta(1-\theta)}{n} < \theta(1-\theta) = R(\theta, \delta).$$

Se adicionarmos ao Teorema de Rao–Blackwell a hipótese de que $\delta(\mathbf{X})$ é um estimador não-viesado de $g(\theta)$, temos que

$$\mathbb{E}_\theta[\eta(T(\mathbf{X}))] = \mathbb{E}_\theta[\mathbb{E}[\delta(\mathbf{X})|T(\mathbf{X})]] = \mathbb{E}_\theta[\delta(\mathbf{X})] = g(\theta).$$

Além disso,

$$\begin{aligned}\text{Var}_\theta(\delta(\mathbf{X})) &= \text{Var}_\theta(\mathbb{E}[\delta(\mathbf{X})|T(\mathbf{X})]) + \mathbb{E}_\theta[\text{Var}(\delta(\mathbf{X})|T(\mathbf{X}))] \\ &= \text{Var}_\theta(\eta(T(\mathbf{X}))) + \mathbb{E}_\theta[\text{Var}(\delta(\mathbf{X})|T(\mathbf{X}))] \\ &\geq \text{Var}_\theta(\eta(T(\mathbf{X}))).\end{aligned}$$

Tais resultados nos levam à seguinte forma do Teorema de Rao–Blackwell.

Teorema 3.2 (Teorema de Rao–Blackwell). Sejam $T(\mathbf{X})$ uma estatística suficiente para θ e $\delta(\mathbf{X})$ um estimador não viesado de $g(\theta)$ com variância finita. Então, $\eta(T(\mathbf{X})) = \mathbb{E}[\delta(\mathbf{X})|T(\mathbf{X})]$ é também um estimador não viesado de $g(\theta)$ e

$$\text{Var}_\theta(\eta(T(\mathbf{X}))) \leq \text{Var}_\theta(\delta(\mathbf{X})), \quad \forall \theta \in \Theta.$$

4. TEOREMA DE LEHMANN–SCHEFFE

Embora o Teorema de Rao–Blackwell permita “aprimorar” um estimador fixado, reduzindo seu risco sob uma função de perda convexa, não há um sentido de otimalidade (uniforme). Apesar de, em geral, não existir um estimador uniformemente ótimo, é frequentemente possível encontrar um estimador não viesado com risco uniformemente mínimo. Isto é, um estimador não viesado δ tal que

$$R(\theta, \delta) \leq R(\theta, \delta'), \quad \forall \theta \in \Theta,$$

para qualquer outro estimador não viesado δ' . Um estimador com essa propriedade é denominado estimador não viesado de risco uniformemente mínimo (UMRUE).

Sob a função de perda quadrática, $L(\theta, d) = (\theta - d)^2$, o risco de um estimador não viesado coincide com sua variância. Portanto, nesse caso, um estimador UMRUE é denominado estimador não viesado de variância uniformemente mínima (UMVUE). Isto é, um estimador não viesado δ tal que

$$\text{Var}_\theta(\delta) \leq \text{Var}_\theta(\delta'), \quad \forall \theta \in \Theta,$$

para qualquer outro estimador não viesado δ' .

Teorema 4.1 (Teorema de Lehmann–Scheffé). Se $T(\mathbf{X})$ é uma estatística suficiente e completa, e $\mathbb{E}_\theta[h(T(\mathbf{X}))] = g(\theta)$, isto é, $h(T(\mathbf{X}))$ é um estimador não viesado de $g(\theta)$, então $h(T(\mathbf{X}))$ é

- (1) a única função de $T(\mathbf{X})$ que é não viesada para $g(\theta)$;
- (2) um UMRUE sob qualquer função de perda convexa;
- (3) o único UMRUE, a menos de um conjunto de probabilidade zero, sob qualquer função de perda estritamente convexa;
- (4) o único UMVUE, a menos de um conjunto de probabilidade zero.

Exemplo 4.1. Considere $X_1, \dots, X_n \stackrel{i.i.d.}{\sim} \text{Bernoulli}(\theta)$, $\theta \in (0, 1)$, e suponha que nosso interesse seja estimar θ .

A função massa de probabilidade conjunta pode ser escrita como

$$p(\mathbf{x}; \theta) = \prod_{i=1}^n \theta^{x_i} (1 - \theta)^{1-x_i} = \exp \left\{ \log \left(\frac{\theta}{1 - \theta} \right) \sum_{i=1}^n x_i + n \log(1 - \theta) \right\}.$$

Portanto, trata-se de uma família exponencial com estatística suficiente $T(\mathbf{X}) = \sum_{i=1}^n X_i$ e parâmetro natural

$$\eta(\theta) = \log \left(\frac{\theta}{1 - \theta} \right).$$

Como θ percorre $(0, 1)$, o parâmetro natural $\eta(\theta)$ percorre $\mathbb{R}$. Logo, a família exponencial é de posto completo. Além disso,

$$\mathbb{E}_\theta \left[\frac{T(\mathbf{X})}{n} \right] = \frac{1}{n} \sum_{i=1}^n \mathbb{E}_\theta[X_i] = \theta.$$

Assim, a média amostral é uma função não viesada da estatística suficiente e completa $T(\mathbf{X})$. Pelo Teorema de Lehmann–Scheffé, $\bar{X}$ é um UMRUE de θ sob qualquer função de perda convexa e, em particular, o UMVUE de θ sob perda quadrática.

EXERCÍCIOS

1. Suponha que temos uma amostra aleatória $\mathbf{X} = (X_1, X_2, \dots, X_n)$ de uma distribuição Normal com média μ e variância σ^2 , ambas desconhecidas. Para $c > 0$, considere estimadores da forma

$$\delta_c(\mathbf{X}) = c \sum_{i=1}^n (X_i - \bar{X})^2$$

para σ^2 .

- (a) Encontre o erro quadrático médio desta classe de estimadores em função de c .
- (b) Encontre c^* de modo que $\delta_{c^*}(\mathbf{X})$ seja admissível.
- (c) $\delta_{c^*}(\mathbf{X})$ é não viesado?

2. Considere o problema de estimar a probabilidade de sucesso θ sob perda quadrática no caso em que $X \sim \text{Binomial}(n, \theta)$. Defina $\delta_{a,b}$ da seguinte forma:

$$\delta_{a,b}(X) = a \frac{X}{n} + (1 - a)b.$$

O estimador $\delta_{a,b}$ é chamado linear por ser uma função linear de X .

- (a) Encontre o viés e a variância de $\delta_{a,b}$.
- (b) Para $a > 1$, mostre que $\delta_{a,b}$ é inadmissível, encontrando um estimador linear que o domine. *Dica:* sob perda quadrática, o risco é dado por $R(\theta, \delta) = \text{Var}_\theta(\delta(X)) + (\mathbb{E}[\delta(\mathbf{X})] - \theta)^2$. Encontre um estimador não viesado com menor variância.

- (c) Para $a \in [0, 1)$ e $b < 0$ ou $b > 1$, mostre que $\delta_{a,b}$ é inadmissível, encontrando um estimador linear de menor risco. *Dica:* Encontre um estimador com a mesma variância, mas com menor viés.
- (d) Para $a < 0$, encontre um estimador linear com menor risco que $\delta_{a,b}(X)$.
3. Sejam T_1 uma estatística suficiente, T_2 uma estatística suficiente mínima e δ um estimador não viesado para θ . Defina $U_1 = \mathbb{E}(U|T_1)$ e $U_2 = \mathbb{E}(U|T_2)$
- (a) Mostre que $U_2 = \mathbb{E}(U_1|T_2)$.
- (b) Aplique a identidade da variância condicional ($\text{Var}(X) = \mathbb{E}[\text{Var}(X|Y)] + \text{Var}(\mathbb{E}[X|Y])$) para mostrar que $\text{Var}(U_2) \leq \text{Var}(U_1)$.
4. Sejam $X_1, \dots, X_m$ e $Y_1, \dots, Y_n$ variáveis aleatórias independentes, em que $(X_i)_{i=1}^m$ é uma amostra aleatória de uma distribuição Exponencial com taxa λ_x e $(Y_j)_{j=1}^n$ é uma amostra aleatória de uma distribuição Exponencial com taxa λ_y .
- (a) Determine o estimador não viesado de variância uniformemente mínima (UMVUE) de λ_x/λ_y .
- (b) Sob perda quadrática, encontre o melhor estimador de λ_x/λ_y da forma $\delta = c\bar{Y}/\bar{X}$.
- (c) Determine o UMVUE de $e^{-\lambda_x} = \mathbb{P}(X_1 > 1)$.
5. Sejam $X_1, \dots, X_n$ variáveis aleatórias *i.i.d.* com distribuição P_θ e $\bar{X} = \sum_{i=1}^n X_i/n$ a média amostral.
- (a) Mostre que $S^2 = \sum_{i=1}^n (X_i - \bar{X})^2/(n-1)$ é um estimador não viesado de $\sigma^2 = \text{Var}_\theta(X_i)$.
- (b) No caso em que P_θ é a distribuição de Bernoulli com probabilidade de sucesso θ , mostre que S^2 é UMVUE.
6. Seja X uma variável aleatória com distribuição Exponencial com taxa θ , cuja densidade é dada por $f(x; \theta) = \theta e^{-\theta x}$, $x > 0$. Encontre o UMVUE de $1/(1 + \theta)$.
7. Sejam X_1, X_2, X_3 variáveis aleatórias *i.i.d.* com distribuição Geométrica, cuja função massa de probabilidade é dada por $p(x; \theta) = \theta(1 - \theta)^x$, $x = 0, 1, 2, \dots$. Encontre o UMVUE de θ^2 .
8. Seja $X \sim \text{Binomial}(n, \theta)$, $\theta \in (0, 1)$. Para $m \leq n$, encontre o UMVUE de θ^m .