

1. FUNÇÃO DE VEROSSIMILHANÇA

Diversas formas têm sido propostas para determinar quais aspectos dos dados observados são relevantes para a inferência sobre um parâmetro desconhecido. Como vimos anteriormente, o conceito de suficiência fornece um princípio de redução de dados, permitindo identificar estatísticas que preservam toda a informação da amostra sobre o parâmetro. Outra perspectiva consiste em considerar, para os dados efetivamente observados, quão compatíveis são os diferentes valores possíveis do parâmetro. Essa é a informação fornecida pela função de verossimilhança.

Definição 1.1. Seja $\mathbf{X} = (X_1, \dots, X_n)$ um vetor aleatório cuja distribuição depende de um parâmetro $\theta \in \Theta$. Para uma realização observada $\mathbf{X} = \mathbf{x}$, a função de verossimilhança de θ é definida por

$$L(\theta; \mathbf{x}) = p(\mathbf{x}; \theta),$$

onde $p(\mathbf{x}; \theta)$ é a função massa de probabilidade (f.m.p.) conjunta ou densidade de probabilidade (f.d.p.) conjunta de $\mathbf{X}$, avaliada no valor observado $\mathbf{x}$.

Pela definição, a função de verossimilhança parece ser exatamente a f.m.p. ou a f.d.p. A distinção entre as funções está na quantidade considerada fixa e na quantidade considerada variável. No caso da f.m.p. ou da f.d.p. $p(\mathbf{x}; \theta)$, estamos considerando θ fixo e $\mathbf{x}$ variável. No caso da função de verossimilhança $L(\theta; \mathbf{x})$, os dados observados $\mathbf{x}$ são mantidos fixos e o parâmetro varia em Θ . Em particular, $L(\theta; \mathbf{x})$, como função de θ , não é uma distribuição de probabilidade sobre Θ .

No caso em que $\mathbf{X}$ é um vetor aleatório discreto, $L(\theta; \mathbf{x}) = P_\theta(\mathbf{X} = \mathbf{x})$. Assim, ao compararmos a função de verossimilhança para dois parâmetros fixados, temos

$$P_{\theta_1}(\mathbf{X} = \mathbf{x}) = L(\theta_1; \mathbf{x}) > L(\theta_2; \mathbf{x}) = P_{\theta_2}(\mathbf{X} = \mathbf{x}).$$

Dessa forma, podemos dizer ser mais plausível que a amostra observada tenha sido gerada por $\theta = \theta_1$ que por $\theta = \theta_2$. Isto significa dizer que θ_1 é um valor mais plausível para o verdadeiro valor de θ que θ_2 .

No caso contínuo, consideramos a probabilidade de observar um valor em um pequeno intervalo à direita de x , $P_\theta(x < X \leq x + \Delta x) = F_\theta(x + \Delta x) - F_\theta(x)$. Pela definição de densidade,

$$f(x; \theta) = \lim_{\Delta x \rightarrow 0} \frac{F_\theta(x + \Delta x) - F_\theta(x)}{\Delta x} = \lim_{\Delta x \rightarrow 0} \frac{P_\theta(x < X \leq x + \Delta x)}{\Delta x}.$$

Portanto, para Δx suficientemente pequeno,

$$\frac{P_{\theta_1}(x < X \leq x + \Delta x)}{P_{\theta_2}(x < X \leq x + \Delta x)} \approx \frac{L(\theta_1; x)}{L(\theta_2; x)}.$$

Exemplo 1.1. Seja X uma variável aleatória com distribuição Binomial Negativa com $r = 3$ e probabilidade de sucesso θ . Se observamos $X = 2$, então a função de verossimilhança é dada por

$$L(\theta; 2) = P_\theta(X = 2) = \binom{4}{2} \theta^3 (1 - \theta)^2, \quad 0 < \theta < 1.$$

Assim, $L(\theta; 2)$ é um polinômio de grau 5 em θ . De forma mais geral, se $X = x$ é observado, então a função de verossimilhança é

$$L(\theta; x) = \binom{3 + x - 1}{x} \theta^3 (1 - \theta)^x, \quad 0 < \theta < 1,$$

que é um polinômio de grau $3 + x$ em θ .

A seguir, formalizamos a ideia de que a informação fornecida pelos dados sobre θ é determinada pela forma da função de verossimilhança.

PRINCÍPIO DA VEROSSIMILHANÇA: Se $\mathbf{x}$ e $\mathbf{y}$ são realizações observadas tais que $L(\theta; \mathbf{x})$ é proporcional a $L(\theta; \mathbf{y})$, isto é, existe uma constante $c(\mathbf{x}, \mathbf{y})$ tal que

$$L(\theta; \mathbf{x}) = c(\mathbf{x}, \mathbf{y}) L(\theta; \mathbf{y}), \quad \forall \theta \in \Theta,$$

então $\mathbf{x}$ e $\mathbf{y}$ fornecem a mesma informação sobre θ .

O Princípio da Verossimilhança estabelece, portanto, que toda a informação fornecida pelos dados observados acerca de θ está contida na função de verossimilhança, a menos de uma constante multiplicativa que não dependa de θ . A mesma ideia pode ser estendida à comparação de resultados provenientes de experimentos distintos: se eles produzem funções de verossimilhança proporcionais em θ , devem fornecer a mesma informação sobre θ .

Exemplo 1.2. Considere dois experimentos envolvendo uma sequência de ensaios de Bernoulli independentes, com probabilidade de sucesso θ . No primeiro experimento, fixa-se previamente o número de sucessos r e os ensaios são realizados até a ocorrência do r -ésimo sucesso. Seja X o número de fracassos observados até o momento. Então, se são observados $X = x$ fracassos, a função de verossimilhança é

$$L_1(\theta; x) = \binom{x+r-1}{x} \theta^r (1-\theta)^x.$$

Considere agora um segundo experimento no qual o número total de ensaios é fixado em $n = r+x$. Seja Y o número de sucessos nesses n ensaios. Então, se são observados $Y = r$ sucessos, a função de verossimilhança é

$$L_2(\theta; r) = \binom{r+x}{r} \theta^r (1-\theta)^x.$$

Portanto,

$$\begin{aligned} L_1(\theta; x) &= \frac{\binom{x+r-1}{x}}{\binom{r+x}{r}} L_2(\theta; r) \\ &= \frac{r}{r+x} L_2(\theta; r). \end{aligned}$$

De acordo com o Princípio da Verossimilhança, os dois resultados fornecem a mesma informação sobre θ .

Pelo Teorema da Fatoração de Neyman–Fisher, o valor de uma estatística suficiente contém informação suficiente para determinar a forma da função de verossimilhança, considerando que duas funções possuem a mesma forma quando são proporcionais como funções de θ .

O Teorema 3.1 da Aula 02 permite tornar essa relação mais precisa: uma estatística suficiente é mínima quando a forma da função de verossimilhança também determina o valor da estatística.

Teorema. Seja $\mathcal{P} = \{\mathbb{P}_\theta : \theta \in \Theta\}$ uma família dominada com densidade $f(\mathbf{x}; \theta) = g_\theta(T(\mathbf{x}))h(\mathbf{x})$. Suponha que, para quaisquer $\mathbf{x}$ e $\mathbf{y}$, se existe uma constante $c(\mathbf{x}, \mathbf{y}) > 0$, que não depende de θ , tal que

$$f(\mathbf{x}; \theta) = c(\mathbf{x}, \mathbf{y})f(\mathbf{y}; \theta), \quad \forall \theta \in \Theta,$$

então $T(\mathbf{x}) = T(\mathbf{y})$. Nesse caso, $T(\mathbf{X})$ é uma estatística suficiente mínima.

Em essência, esse resultado estabelece que a forma da função de verossimilhança é suficiente mínima. Consequentemente, para famílias dominadas, existe uma estatística suficiente mínima, entendida, de maneira mais geral, como a estatística que identifica as classes de realizações amostrais que produzem funções de verossimilhança proporcionais.

2. INFORMAÇÃO DE FISHER E DESIGUALDADE DE CRAMÉR-RAO

Na aula anterior, vimos que, entre estimadores não viesados, podemos comparar sua eficiência por meio de suas variâncias, sendo mais eficiente aquele que possui menor variância. Vimos também o conceito de estimador não viesado de variância uniformemente mínima. Podemos então nos perguntar se é possível estabelecer uma cota inferior para a variância de um estimador.

Para obter uma cota inferior para a variância, podemos partir da desigualdade de Cauchy–Schwarz. Para quaisquer variáveis aleatórias X e Y ,

$$[\text{Cov}(X, Y)]^2 \leq \text{Var}(X)\text{Var}(Y).$$

Equivalentemente,

$$\text{Var}(X) \geq \frac{[\text{Cov}(X, Y)]^2}{\text{Var}(Y)}.$$

Neste sentido, tomamos X como um estimador $\delta(\mathbf{X})$ e Y como a quantidade $U(\theta; \mathbf{X}) = \frac{\partial}{\partial \theta} \ell(\theta; \mathbf{X})$, onde $\ell(\theta; \mathbf{X}) = \log L(\theta; \mathbf{X})$. As quantidades $U(\theta; \mathbf{X})$ e $\ell(\theta; \mathbf{X})$ são denominadas função escore e função de log-verossimilhança, respectivamente. Neste caso, temos

$$\text{Cov}_\theta(\delta(\mathbf{X}), U(\theta; \mathbf{X})) = \mathbb{E}_\theta [\delta(\mathbf{X}) U(\theta; \mathbf{X})] - \mathbb{E}_\theta [\delta(\mathbf{X})] \mathbb{E}_\theta [U(\theta; \mathbf{X})].$$

Analisando $\mathbb{E}_\theta [\delta(\mathbf{X}) U(\theta; \mathbf{X})]$, sob condições de regularidade que permitem a diferenciação sob o sinal da integral, temos

$$\begin{aligned} \mathbb{E}_\theta [\delta(\mathbf{X}) U(\theta; \mathbf{X})] &= \mathbb{E}_\theta \left[\delta(\mathbf{X}) \frac{\frac{\partial}{\partial \theta} f(\mathbf{X}; \theta)}{f(\mathbf{X}; \theta)} \right] \\ &= \int \delta(\mathbf{x}) \frac{\partial}{\partial \theta} f(\mathbf{x}; \theta) d\mathbf{x} \\ &= \frac{\partial}{\partial \theta} \mathbb{E}_\theta [\delta(\mathbf{X})]. \end{aligned}$$

Analisando $\mathbb{E}_\theta [U(\theta; \mathbf{X})]$, temos

$$\begin{aligned}\mathbb{E}_\theta [U(\theta; \mathbf{X})] &= \int U(\theta; \mathbf{x}) f(\mathbf{x}; \theta) d\mathbf{x} \\ &= \int \frac{\partial}{\partial \theta} f(\mathbf{x}; \theta) d\mathbf{x} \\ &= \frac{\partial}{\partial \theta} \int f(\mathbf{x}; \theta) d\mathbf{x} \\ &= \frac{\partial}{\partial \theta} 1 = 0.\end{aligned}$$

Portanto, $\text{Cov}_\theta(\delta(\mathbf{X}), U(\theta; \mathbf{X})) = \mathbb{E}_\theta [\delta(\mathbf{X}) U(\theta; \mathbf{X})] = \frac{\partial}{\partial \theta} \mathbb{E}_\theta [\delta(\mathbf{X})]$. Além disso, como o escore possui esperança zero, $I_{\mathbf{X}}(\theta) = \mathbb{E}_\theta [U(\theta; \mathbf{X})^2] = \text{Var}_\theta [U(\theta; \mathbf{X})]$. Esta quantidade é denominada Informação de Fisher. Por fim, aplicando a desigualdade de Cauchy–Schwarz a $\delta(\mathbf{X})$ e $U(\theta; \mathbf{X})$, obtemos

$$\text{Var}_\theta [\delta(\mathbf{X})] \geq \frac{\left[\frac{d}{d\theta} \mathbb{E}_\theta [\delta(\mathbf{X})] \right]^2}{I_{\mathbf{X}}(\theta)}.$$

Teorema 2.1 (Desigualdade de Cramér–Rao). Seja $\mathcal{P} = \{P_\theta : \theta \in \Theta\}$ uma família dominada, com Θ um conjunto aberto em $\mathbb{R}$ e densidades $f(\mathbf{x}; \theta)$ diferenciáveis em relação a θ . Seja $\delta(\mathbf{X})$ um estimador de $g(\theta)$, defina $r(\theta) = \mathbb{E}_\theta [\delta(\mathbf{X})]$. Se $\mathbb{E}_\theta [U(\theta; \mathbf{X})] = 0$, $\mathbb{E}_\theta [\delta(\mathbf{X})^2] < \infty$ e $r'(\theta) = \mathbb{E}_\theta [\delta(\mathbf{X}) U(\theta; \mathbf{X})]$ para todo $\theta \in \Theta$, então

$$\text{Var}_\theta [\delta(\mathbf{X})] \geq \frac{[r'(\theta)]^2}{I_{\mathbf{X}}(\theta)}.$$

OBSERVAÇÃO: Nos casos em que $\delta(\mathbf{X})$ é um estimador não viesado de $g(\theta)$, $r(\theta) = g(\theta)$, então $\text{Var}_\theta [\delta(\mathbf{X})] \geq [g'(\theta)]^2 / I_{\mathbf{X}}(\theta)$. Se $g(\theta) = \theta$, obtemos $\text{Var}_\theta [\delta(\mathbf{X})] \geq 1 / I_{\mathbf{X}}(\theta)$. Um estimador não viesado $\delta(\mathbf{X})$ que atinge a cota de Cramér–Rao para todo $\theta \in \Theta$ é denominado eficiente no sentido de Cramér–Rao.

Adicionando a hipótese de que $X_1, \dots, X_n$ são variáveis aleatórias *i.i.d.*, temos que

$$\begin{aligned}I_{\mathbf{X}}(\theta) &= \text{Var}_\theta \left[\frac{\partial}{\partial \theta} \ell(\theta; \mathbf{X}) \right] \\ &= \text{Var}_\theta \left[\frac{\partial}{\partial \theta} \sum_{i=1}^n \log L(\theta; X_i) \right] \\ &= \text{Var}_\theta \left[\sum_{i=1}^n U(\theta; X_i) \right] \\ &= n \text{Var}_\theta [U(\theta; X_1)].\end{aligned}$$

Logo, $\text{Var}_\theta [\delta(\mathbf{X})] \geq [r'(\theta)]^2 / [n I_{X_1}(\theta)]$. Note que, no caso *i.i.d.*, a Informação de Fisher cresce linearmente com n . Portanto, à medida que o tamanho da amostra aumenta, obtemos mais informação sobre θ e a cota de Cramér–Rao para a variância do estimador decresce.

Sob condições de regularidade que permitem a diferenciação sob o sinal da integral, podemos obter uma expressão alternativa para a Informação de Fisher:

$$\begin{aligned}
\frac{\partial}{\partial \theta} \mathbb{E}_\theta[U(\theta; \mathbf{X})] &= \frac{\partial}{\partial \theta} \int U(\theta; \mathbf{x}) f(\mathbf{x}; \theta) d\mathbf{x} \\
&= \frac{\partial}{\partial \theta} \int \left(\frac{\partial}{\partial \theta} \ell(\theta; \mathbf{x}) \right) f(\mathbf{x}; \theta) d\mathbf{x} \\
&= \int \left(\frac{\partial^2}{\partial \theta^2} \ell(\theta; \mathbf{x}) \right) f(\mathbf{x}; \theta) d\mathbf{x} + \int \left(\frac{\partial}{\partial \theta} \ell(\theta; \mathbf{x}) \right) \frac{\partial}{\partial \theta} f(\mathbf{x}; \theta) d\mathbf{x} \\
&= \mathbb{E}_\theta \left[\frac{\partial^2}{\partial \theta^2} \ell(\theta; \mathbf{X}) \right] + \mathbb{E}_\theta [U(\theta; \mathbf{X})^2]
\end{aligned}$$

Como $\mathbb{E}_\theta[U(\theta; \mathbf{X})] = 0$, temos

$$I_{\mathbf{X}}(\theta) = -\mathbb{E}_\theta \left[\frac{\partial^2}{\partial \theta^2} \ell(\theta; \mathbf{X}) \right].$$

Essa representação pode ser particularmente conveniente para o cálculo da Informação de Fisher.

Considere uma família dominada $\mathcal{P} = \{\mathbb{P}_\theta : \theta \in \Theta\}$, com densidades $f(\mathbf{x}; \theta)$ e Informação de Fisher $I_{\mathbf{X}}(\theta)$. Se h é uma função um a um de Ξ em Θ , podemos reparametrizar a família $\mathcal{P}$ por $\tilde{\mathcal{P}} = \{Q_\xi : \xi \in \Xi\}$ com a identificação $Q_\xi = \mathbb{P}_{h(\xi)}$. Como Q_ξ tem densidade $q(\cdot; \xi) = f(\cdot; h(\xi))$, tomando $\theta = h(\xi)$, pela regra da cadeia, a informação de Fisher $\tilde{I}_{\mathbf{X}}(\xi)$ da família reparametrizada $\tilde{\mathcal{P}}$ é dada por

$$\begin{aligned}
\tilde{I}_{\mathbf{X}}(\xi) &= \mathbb{E}_\xi \left[\left(\frac{\partial}{\partial \xi} \log q(\mathbf{X}; \xi) \right)^2 \right] \\
&= \mathbb{E}_\xi \left[\left(\frac{\partial}{\partial \xi} \log f(\mathbf{X}; h(\xi)) \right)^2 \right] \\
&= [h'(\xi)]^2 I_{\mathbf{X}}(h(\xi)).
\end{aligned}$$

Exemplo 2.1 (Família Exponencial). Seja $\mathcal{P}$ uma família exponencial uniparamétrica na forma canônica, com densidade $f(\mathbf{x}; \eta) = \exp \{ \eta T(\mathbf{x}) - A(\eta) \} h(\mathbf{x})$. Neste caso, temos que

$$\frac{\partial}{\partial \eta} \log f(\mathbf{X}; \eta) = T(\mathbf{X}) - A'(\eta).$$

Logo, $I_{\mathbf{X}}(\eta) = \text{Var}_\eta [T(\mathbf{X}) - A'(\eta)] = \text{Var}_\eta [T(\mathbf{X})] = A''(\eta)$.

Considerando a parametrização pela média $\mu = \mathbb{E}_\eta [T(\mathbf{X})] = A'(\eta)$, como

$$\frac{d\mu}{d\eta} = A''(\eta),$$

pela regra de transformação da Informação de Fisher,

$$I_{\mathbf{X}}(\eta) = [A''(\eta)]^2 I_{\mathbf{X}}(\mu) \Rightarrow A''(\eta) = I_{\mathbf{X}}(\mu) [A''(\eta)]^2.$$

Portanto, como $A''(\eta) = \text{Var}_\eta [T(\mathbf{X})]$, segue que

$$I_{\mathbf{X}}(\mu) = \frac{1}{\text{Var}_\mu [T(\mathbf{X})]}.$$

Como $T(\mathbf{X})$ é um estimador não viesado de μ , $T(\mathbf{X})$ atinge a cota de Cramér–Rao e, portanto, é eficiente no sentido de Cramér–Rao. Além disso, como a cota de Cramér–Rao é uma cota inferior para a variância de qualquer estimador não viesado de μ , $T(\mathbf{X})$ é também um estimador não viesado de variância uniformemente mínima (UMVUE) de μ .

Por fim, como a desigualdade de Cramér–Rao é obtida a partir da desigualdade de Cauchy–Schwarz, podemos caracterizar quando a cota é atingida pela condição de igualdade em Cauchy–Schwarz. Se $\delta(\mathbf{X})$ é um estimador não viesado de $g(\theta)$, então $\delta(\mathbf{X})$ atinge a cota de Cramér–Rao se, e somente se, para alguma função $a(\theta)$,

$$U(\theta; \mathbf{X}) = a(\theta) [\delta(\mathbf{X}) - g(\theta)].$$

Portanto, a cota de Cramér–Rao não é necessariamente atingível; para que isso ocorra, o escore deve ser proporcional ao erro de estimação $\delta(\mathbf{X}) - g(\theta)$. No Exemplo 2.1, temos

$$U(\eta; \mathbf{X}) = T(\mathbf{X}) - A'(\eta) = T(\mathbf{X}) - \mu,$$

de modo que a condição de igualdade é satisfeita com $\delta(\mathbf{X}) = T(\mathbf{X})$, $g(\eta) = A'(\eta) = \mu$ e $a(\eta) = 1$.

3. MATRIZ DE INFORMAÇÃO DE FISHER

Os resultados anteriores podem ser estendidos ao caso em que o parâmetro é um vetor. Considere uma família $\mathcal{P} = \{P_{\boldsymbol{\theta}} : \boldsymbol{\theta} \in \Theta\}$, onde $\Theta \subset \mathbb{R}^p$. O vetor escore é definido por

$$U(\boldsymbol{\theta}; \mathbf{X}) = \nabla_{\boldsymbol{\theta}} \ell(\boldsymbol{\theta}; \mathbf{X}) = \left(\frac{\partial}{\partial \theta_1} \ell(\boldsymbol{\theta}; \mathbf{X}), \dots, \frac{\partial}{\partial \theta_p} \ell(\boldsymbol{\theta}; \mathbf{X}) \right)^{\top},$$

onde $\nabla_{\boldsymbol{\theta}}$ é o gradiente com respeito a $\boldsymbol{\theta}$. Sob condições de regularidade, $\mathbb{E}_{\boldsymbol{\theta}} [U(\boldsymbol{\theta}; \mathbf{X})] = \mathbf{0}$, e a matriz de Informação de Fisher é dada por

$$\begin{aligned} I_{\mathbf{X}}(\boldsymbol{\theta}) &= \mathbb{E}_{\boldsymbol{\theta}} [U(\boldsymbol{\theta}; \mathbf{X}) U(\boldsymbol{\theta}; \mathbf{X})^{\top}] \\ &= \text{Cov}_{\boldsymbol{\theta}} [U(\boldsymbol{\theta}; \mathbf{X})] \\ &= -\mathbb{E}_{\boldsymbol{\theta}} [\nabla_{\boldsymbol{\theta}}^2 \ell(\boldsymbol{\theta}; \mathbf{X})], \end{aligned}$$

onde $\nabla_{\boldsymbol{\theta}}^2$ é a matriz Hessiana das segundas derivadas. Equivalentemente, a entrada (j, k) da matriz de Informação de Fisher é dado por

$$\begin{aligned} [I_{\mathbf{X}}(\boldsymbol{\theta})]_{j,k} &= \mathbb{E}_{\boldsymbol{\theta}} \left[\frac{\partial}{\partial \theta_j} \ell(\boldsymbol{\theta}; \mathbf{X}) \frac{\partial}{\partial \theta_k} \ell(\boldsymbol{\theta}; \mathbf{X}) \right] \\ &= -\mathbb{E}_{\boldsymbol{\theta}} \left[\frac{\partial^2}{\partial \theta_j \partial \theta_k} \ell(\boldsymbol{\theta}; \mathbf{X}) \right]. \end{aligned}$$

Analogamente, a desigualdade de Cramér–Rao também pode ser estendida. Seja $\delta(\mathbf{X})$ um estimador de $g(\boldsymbol{\theta})$, onde $g : \Theta \rightarrow \mathbb{R}$, e defina $r(\boldsymbol{\theta}) = \mathbb{E}_{\boldsymbol{\theta}} [\delta(\mathbf{X})]$. Sob condições de regularidade, temos $\text{Cov}_{\boldsymbol{\theta}} [\delta(\mathbf{X}), U(\boldsymbol{\theta}; \mathbf{X})] = \nabla_{\boldsymbol{\theta}} r(\boldsymbol{\theta})$. Então, se $I_{\mathbf{X}}(\boldsymbol{\theta})$ é não singular,

$$\text{Var}_{\boldsymbol{\theta}} [\delta(\mathbf{X})] \geq \nabla_{\boldsymbol{\theta}} r(\boldsymbol{\theta})^{\top} I_{\mathbf{X}}(\boldsymbol{\theta})^{-1} \nabla_{\boldsymbol{\theta}} r(\boldsymbol{\theta}).$$

Em particular, se $\delta(\mathbf{X})$ é um estimador não viesado de $g(\boldsymbol{\theta})$, então $r(\boldsymbol{\theta}) = g(\boldsymbol{\theta})$ e, portanto,

$$\text{Var}_{\boldsymbol{\theta}} [\delta(\mathbf{X})] \geq \nabla_{\boldsymbol{\theta}} g(\boldsymbol{\theta})^{\top} I_{\mathbf{X}}(\boldsymbol{\theta})^{-1} \nabla_{\boldsymbol{\theta}} g(\boldsymbol{\theta}).$$

Exemplo 3.1 (Família Exponencial). Seja $\mathcal{P}$ uma família exponencial com p parâmetros na forma canônica com densidade $f(\mathbf{x}; \boldsymbol{\eta}) = \exp \{ \boldsymbol{\eta}^{\top} T(\mathbf{x}) - A(\boldsymbol{\eta}) \} h(\mathbf{x})$, então

$$\frac{\partial^2}{\partial \eta_j \partial \eta_k} \log f(\mathbf{X}; \boldsymbol{\eta}) = -\frac{\partial^2}{\partial \eta_j \partial \eta_k} A(\boldsymbol{\eta}).$$

Portanto,

$$[I_{\mathbf{X}}(\boldsymbol{\eta})]_{j,k} = \frac{\partial^2}{\partial \eta_j \partial \eta_k} A(\boldsymbol{\eta}).$$

Em forma matricial, temos

$$I_{\mathbf{X}}(\boldsymbol{\eta}) = \nabla_{\boldsymbol{\eta}}^2 A(\boldsymbol{\eta}).$$

Considere agora uma família paramétrica dominada $\mathcal{P} = \{P_{\boldsymbol{\theta}} : \boldsymbol{\theta} \in \Theta\}$ com densidades $f(\mathbf{x}; \boldsymbol{\theta})$ e matriz de Informação de Fisher $I_{\mathbf{X}}(\boldsymbol{\theta})$. Seja $h : \Xi \rightarrow \Theta$ uma função um a um e diferenciável, onde $\Xi \subset \mathbb{R}^p$. Podemos reparametrizar a família $\mathcal{P}$ por $\tilde{\mathcal{P}} = \{Q_{\boldsymbol{\xi}} : \boldsymbol{\xi} \in \Xi\}$, com a identificação $Q_{\boldsymbol{\xi}} = P_{h(\boldsymbol{\xi})}$. Como $Q_{\boldsymbol{\xi}}$ possui densidade $q(\mathbf{x}; \boldsymbol{\xi}) = f(\mathbf{x}; h(\boldsymbol{\xi}))$, tomando $\boldsymbol{\theta} = h(\boldsymbol{\xi})$, pela regra da cadeia,

$$\frac{\partial \log q(\mathbf{x}; \boldsymbol{\xi})}{\partial \xi_i} = \sum_j \frac{\partial \log f(\mathbf{x}; \boldsymbol{\theta})}{\partial \theta_j} \frac{\partial h_j(\boldsymbol{\xi})}{\partial \xi_i}.$$

Se Dh denota a matriz Jacobiana de derivadas parciais de h com as entradas dadas por $[Dh(\boldsymbol{\xi})]_{i,j} = \partial h_i(\boldsymbol{\xi}) / \partial \xi_j$, então $\partial \log q(\mathbf{x}; \boldsymbol{\xi}) / \partial \xi_i$ corresponde à i -ésima entrada de $Dh(\boldsymbol{\xi})^\top U(\boldsymbol{\theta}; \mathbf{X})$. Portanto,

$$U(\boldsymbol{\xi}; \mathbf{X}) = Dh(\boldsymbol{\xi})^\top U(\boldsymbol{\theta}; \mathbf{X})$$

e

$$\begin{aligned} \tilde{I}_{\mathbf{X}}(\boldsymbol{\xi}) &= \mathbb{E}_{\boldsymbol{\xi}} [U(\boldsymbol{\xi}; \mathbf{X}) U(\boldsymbol{\xi}; \mathbf{X})^\top] \\ &= \mathbb{E}_{\boldsymbol{\xi}} [Dh(\boldsymbol{\xi})^\top U(\boldsymbol{\theta}; \mathbf{X}) U(\boldsymbol{\theta}; \mathbf{X})^\top Dh(\boldsymbol{\xi})] \\ &= Dh(\boldsymbol{\xi})^\top I_{\mathbf{X}}(h(\boldsymbol{\xi})) Dh(\boldsymbol{\xi}). \end{aligned}$$

EXERCÍCIOS

1. Seja $X_1, X_2, \dots$ uma sequência de variáveis aleatórias cujo modelo conjunto depende de um parâmetro θ , e denote por $I_n(\theta)$ a Informação de Fisher contida em $\mathbf{X}_n = (X_1, \dots, X_n)$. Sob condições de regularidade, mostre que

$$I_{n+1}(\theta) \geq I_n(\theta).$$

2. (KN, Ex.:4.32) Suponha que X tenha distribuição de Poisson com média θ^2 , $\theta > 0$, de modo que θ seja a raiz quadrada do parâmetro usual $\lambda = \mathbb{E}[X]$. Mostre que a Informação de Fisher $I(\theta)$ é constante.

3. (KN, Ex.: 4.40) Seja X uma variável aleatória com distribuição geométrica de parâmetro θ , com

$$P_{\theta}(X = x) = \theta(1 - \theta)^x, \quad x = 0, 1, \dots,$$

Determine a menor variância possível de um estimador não viesado de θ e compare-a com a cota de Cramér–Rao.

4. (CB, Ex.: 7.44) Sejam $X_1, \dots, X_n$ variáveis aleatórias *i.i.d.* com distribuição $N(\theta, 1)$. Mostre que o melhor estimador não viesado de θ^2 é $\bar{X}^2 - 1/n$. Calcule sua variância (use a identidade de Stein) e mostre que ela é maior que a cota de Cramér–Rao.

5. (KN, Ex.:4.30) Sejam $X_1, \dots, X_n$ variáveis aleatórias independentes, com $X_i \sim N(\alpha + \beta t_i, 1)$, onde $t_1, \dots, t_n$ são constantes conhecidas e $\boldsymbol{\theta} = (\alpha, \beta)$.

(a) Determine a matriz de Informação de Fisher $I_{\mathbf{X}}(\alpha, \beta)$.

(b) Obtenha uma cota inferior para a variância de um estimador não viesado de α .

(c) Suponha que β seja conhecido. Obtenha uma cota inferior para a variância de um estimador não viesado de α .

- (d) Compare as cotas obtidas nos itens (b) e (c). Quando elas coincidem? Se forem diferentes, qual delas é maior?
- (e) Obtenha uma cota inferior para a variância de um estimador não viesado de $\alpha\beta$.

6. (KN, Ex.: 4.34) Considere um modelo autorregressivo em que $X_1 \sim N(\theta, \sigma^2/(1 - \rho^2))$ e a distribuição condicional de X_{j+1} , dados $X_1 = x_1, \dots, X_j = x_j$, é $X_{j+1} | X_1 = x_1, \dots, X_j = x_j \sim N(\theta + \rho(x_j - \theta), \sigma^2)$, $j = 1, \dots, n - 1$.

- (a) Determine a matriz de Informação de Fisher $I_{\mathbf{X}}(\theta, \sigma)$.
- (b) Obtenha uma cota inferior para a variância de um estimador não viesado de θ .
- (c) Mostre que a média amostral $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ é um estimador não viesado de θ . Calcule sua variância e compare-a com a cota inferior obtida no item (b).

7. (KN, Ex.: 4.37) Suponha que X tenha distribuição de Poisson com média λ e que, condicionalmente a $X = n$, Y tenha distribuição de Poisson com média $n\theta$.

- (a) Determine a matriz de Informação de Fisher $I_{(X,Y)}(\lambda, \theta)$.
- (b) Obtenha uma expressão para $\mu_Y = \mathbb{E}[Y]$.
- (c) Obtenha uma cota inferior para a variância de um estimador não viesado de μ_Y .
- (d) Compare a cota obtida no item (c) com $\text{Var}(Y)$.

8. (KN, Ex.: 4.41) Sejam $X_1, \dots, X_n$ variáveis aleatórias *i.i.d.* com distribuição de von Mises com densidade

$$p_{\boldsymbol{\theta}}(x) = \frac{\exp\{\theta_1 \sin x + \theta_2 \cos x\}}{2\pi I_0(\|\boldsymbol{\theta}\|)}, \quad x \in (0, 2\pi),$$

e $p_{\boldsymbol{\theta}}(x) = 0$ caso contrário, onde $\boldsymbol{\theta} = (\theta_1, \theta_2)^\top$, $\|\boldsymbol{\theta}\| = (\theta_1^2 + \theta_2^2)^{1/2}$, e I_0 é uma função de Bessel modificada.

- (a) Determine a matriz de Informação de Fisher, expressando-a em termos de I_0 e de suas derivadas.
- (b) Obtenha uma cota inferior para a variância de um estimador não viesado de $\|\boldsymbol{\theta}\|$.

9. (KN, Ex.: 4.42) Seja $\boldsymbol{\theta} = (\alpha, \lambda)$ e considere a distribuição Gamma com parâmetro de forma α e escala $1/\lambda$, cuja densidade é dada por

$$p_{\boldsymbol{\theta}}(x) = \frac{\lambda^\alpha x^{\alpha-1} e^{-\lambda x}}{\Gamma(\alpha)}, \quad x > 0,$$

e $p_{\boldsymbol{\theta}}(x) = 0$ caso contrário.

- (a) Determine a matriz de Informação de Fisher $I(\boldsymbol{\theta})$, expressando-a em termos da função $\psi(\alpha) = \Gamma'(\alpha)/\Gamma(\alpha)$ e de suas derivadas.
- (b) Determine a cota inferior de Cramér–Rao para a variância de um estimador não viesado de $\alpha + \lambda$.
- (c) Determine a média μ e a variância σ^2 da distribuição e mostre que há uma correspondência um a um entre $\boldsymbol{\theta} = (\alpha, \lambda)$ e (μ, σ^2) .
- (d) Determine a matriz de Informação de Fisher quando a família de distribuições Gamma é parametrizada por (μ, σ^2) em vez de $\boldsymbol{\theta}$.