

1. CONSISTÊNCIA

Definição 1.1. Uma sequência de estimadores $\delta_n = \delta_n(X_1, \dots, X_n)$ é dita uma sequência consistente de estimadores do parâmetro θ se, para todo $\varepsilon > 0$ e todo $\theta \in \Theta$,

$$\lim_{n \rightarrow \infty} \mathbb{P}_\theta (|\delta_n - \theta| < \varepsilon) = 1.$$

A definição de consistência está diretamente relacionada à definição de convergência em probabilidade. De fato, uma sequência consistente de estimadores converge em probabilidade para o parâmetro que está sendo estimado. A diferença é que, na definição usual de convergência em probabilidade, considera-se uma única estrutura de probabilidade, enquanto, no contexto de estimação, temos uma família de distribuições indexada por θ . Assim, para cada $\theta \in \Theta$, a distribuição de δ_n pode ser diferente, e a consistência requer que, sob $\mathbb{P}_\theta$, a sequência δ_n convirja em probabilidade para o respectivo valor de θ .

Exemplo 1.1. Sejam $X_1, X_2, \dots$ variáveis aleatórias *i.i.d.* com distribuição $N(\theta, 1)$. Considere a sequência de estimadores

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i.$$

Vimos anteriormente que $\bar{X}_n \sim N(\theta, 1/n)$. Logo, para qualquer $\varepsilon > 0$, temos

$$\begin{aligned} \mathbb{P}_\theta (|\bar{X}_n - \theta| < \varepsilon) &= \mathbb{P}_\theta (-\varepsilon < \bar{X}_n - \theta < \varepsilon) \\ &= \mathbb{P}_\theta (-\varepsilon\sqrt{n} < \sqrt{n}(\bar{X}_n - \theta) < \varepsilon\sqrt{n}) \\ &= \mathbb{P} (-\varepsilon\sqrt{n} < Z < \varepsilon\sqrt{n}). \end{aligned} \quad (Z \sim N(0, 1))$$

Para $n \rightarrow \infty$, $-\varepsilon\sqrt{n} \rightarrow -\infty$ e $\varepsilon\sqrt{n} \rightarrow \infty$. Portanto,

$$\lim_{n \rightarrow \infty} \mathbb{P}_\theta (|\bar{X}_n - \theta| < \varepsilon) = 1.$$

Consequentemente, $\bar{X}_n$ é uma sequência consistente de estimadores de θ .

Em geral, não é necessário verificar consistência a partir da definição. A partir da desigualdade de Chebyshev temos que

$$\mathbb{P}_\theta (|\delta_n - \theta| \geq \varepsilon) \leq \frac{\mathbb{E}_\theta [(\delta_n - \theta)^2]}{\varepsilon^2}.$$

Assim, se para todo $\theta \in \Theta$, $\lim_{n \rightarrow \infty} \mathbb{E}_\theta [(\delta_n - \theta)^2] = 0$, então a sequência de estimadores é consistente para θ . Como

$$\mathbb{E}_\theta [(\delta_n - \theta)^2] = \text{Var}_\theta(\delta_n) + \text{Viés}_\theta^2(\delta_n),$$

podemos enunciar o seguinte teorema.

Teorema 1.1. Seja δ_n uma sequência de estimadores do parâmetro θ tal que $\lim_{n \rightarrow \infty} \text{Var}_\theta(\delta_n) = 0$ e $\lim_{n \rightarrow \infty} \text{Viés}_\theta(\delta_n) = 0$ para todo $\theta \in \Theta$. Então δ_n é uma sequência consistente de estimadores de θ .

Exemplo 1.2. Retomando o Exemplo 1.1, como

$$E_{\theta}(\bar{X}_n) = \theta \quad \text{e} \quad \text{Var}_{\theta}(\bar{X}_n) = \frac{1}{n},$$

as condições do teorema anterior são satisfeitas e, portanto, $\bar{X}_n$ é consistente. Além disso, se $X_1, \dots, X_n$ constituem uma amostra aleatória *i.i.d.* de uma população com média θ , então $\bar{X}_n$ é consistente para θ , desde que a população tenha variância finita.

O teorema a seguir estabelece a existência de inúmeras sequências consistentes de estimadores.

Teorema 1.2. Seja δ_n uma sequência consistente de estimadores do parâmetro θ . Sejam $a_1, a_2, \dots$ e $b_1, b_2, \dots$ sequências de constantes tais que $\lim_{n \rightarrow \infty} a_n = 1$ e $\lim_{n \rightarrow \infty} b_n = 0$. Então a sequência $\delta'_n = a_n \delta_n + b_n$ é uma sequência consistente de estimadores de θ .

Como podem existir inúmeras sequências consistentes de estimadores para um mesmo parâmetro, torna-se natural buscar uma descrição mais refinada de seu comportamento assintótico.

2. MÉTODO DELTA

A consistência estabelece que o erro $\delta_n - \theta$ converge em probabilidade para zero, mas não fornece, por si só, informações sobre a taxa dessa convergência. Para tal, suponha que exista uma sequência de constantes positivas $a_n \rightarrow \infty$ tal que

$$a_n(\delta_n - \theta) \xrightarrow{d} W,$$

onde W possui distribuição não degenerada. A sequência a_n determina a escala em que as flutuações de δ_n em torno de θ permanecem não degeneradas, o que permite caracterizar a taxa de convergência do estimador.

Teorema 2.1 (Teorema de Slutsky). Sejam X_n , Y_n e X variáveis aleatórias tais que $X_n \xrightarrow{d} X$ e $Y_n \xrightarrow{\mathbb{P}} c$, onde c é uma constante. Então,

$$(1) \quad X_n + Y_n \xrightarrow{d} X + c;$$

$$(2) \quad X_n Y_n \xrightarrow{d} cX.$$

Em muitas situações, no entanto, o interesse não está diretamente no parâmetro θ , mas em uma função $g(\theta)$ na qual g é diferenciável em θ . Nesse caso, consideramos $g(\delta_n)$ como um estimador de $g(\theta)$.

Por uma expansão de Taylor de primeira ordem de $g(\delta_n)$ em torno de θ , temos

$$g(\delta_n) = g(\theta) + g'(\theta)(\delta_n - \theta) + r_n \Rightarrow a_n [g(\delta_n) - g(\theta)] = g'(\theta)a_n(\delta_n - \theta) + a_n r_n.$$

Como

$$a_n r_n = \frac{r_n}{\delta_n - \theta} a_n(\delta_n - \theta), \quad \frac{r_n}{\delta_n - \theta} \xrightarrow{\mathbb{P}} 0 \quad \text{e} \quad a_n(\delta_n - \theta) \xrightarrow{d} W,$$

pelo Teorema de Slutsky, $a_n r_n \xrightarrow{d} 0$. Visto que $X_n \xrightarrow{d} c \iff X_n \xrightarrow{\mathbb{P}} c$, então $a_n r_n \xrightarrow{\mathbb{P}} 0$. Além disso, $g'(\theta)a_n(\delta_n - \theta) \xrightarrow{d} g'(\theta)W$. Logo, aplicando novamente o Teorema de Slutsky, obtemos

$$a_n [g(\delta_n) - g(\theta)] \xrightarrow{d} g'(\theta)W.$$

Teorema 2.2 (Método Delta). Seja Y_n uma sequência de variáveis aleatórias tal que, para alguma sequência de constantes positivas $a_n \rightarrow \infty$, $a_n(Y_n - \theta) \xrightarrow{d} W$. Se g é diferenciável em θ e $g'(\theta) \neq 0$, então

$$a_n [g(Y_n) - g(\theta)] \xrightarrow{d} g'(\theta)W.$$

Em particular, se $a_n = \sqrt{n}$ e $W \sim N(0, V(\theta))$, então $\sqrt{n} [g(Y_n) - g(\theta)] \xrightarrow{d} N(0, [g'(\theta)]^2 V(\theta))$.

Teorema 2.3 (Teorema do Mapeamento Contínuo). Sejam $(X_n)_n$ e X variáveis aleatórias e $g : \mathbb{R} \rightarrow \mathbb{R}$ uma função mensurável. Suponha que g seja contínua em todos os pontos de algum conjunto $C \in \mathcal{B}$ tal que $\mathbb{P}(X \in C) = 1$. Se $X_n \xrightarrow{d} X$, então $g(X_n) \xrightarrow{d} g(X)$.

Nos casos em que $g'(\theta) = 0$, adicionamos um termo à expansão de Taylor. Suponha que g seja duas vezes continuamente diferenciável em uma vizinhança de θ . Então,

$$g(\delta_n) = g(\theta) + g'(\theta)(\delta_n - \theta) + \frac{1}{2}g''(\theta)(\delta_n - \theta)^2 + r_n.$$

Considerando $g'(\theta) = 0$ e multiplicando ambos os lados por a_n^2 , obtemos

$$a_n^2 [g(\delta_n) - g(\theta)] = \frac{1}{2}g''(\theta) [a_n(\delta_n - \theta)]^2 + a_n^2 r_n.$$

Como

$$a_n^2 r_n = \frac{r_n}{(\delta_n - \theta)^2} a_n^2 (\delta_n - \theta)^2, \quad \frac{r_n}{(\delta_n - \theta)^2} \xrightarrow{\mathbb{P}} 0 \quad \text{e} \quad a_n(\delta_n - \theta) \xrightarrow{d} W \Rightarrow [a_n(\delta_n - \theta)]^2 \xrightarrow{d} W^2,$$

pelo Teorema de Slutsky, $a_n^2 r_n \xrightarrow{d} 0$. Consequentemente, $a_n^2 r_n \xrightarrow{\mathbb{P}} 0$. Além disso, $1/2 g''(\theta) [a_n(\delta_n - \theta)]^2 \xrightarrow{d} 1/2 g''(\theta) W^2$. Logo, aplicando novamente o Teorema de Slutsky, obtemos

$$a_n^2 [g(\delta_n) - g(\theta)] \xrightarrow{d} \frac{1}{2}g''(\theta)W^2.$$

Teorema 2.4 (Método Delta de Segunda Ordem). Seja Y_n uma sequência de variáveis aleatórias tal que, para alguma sequência de constantes positivas $a_n \rightarrow \infty$, $a_n(Y_n - \theta) \xrightarrow{d} W$. Se g é duas vezes continuamente diferenciável em uma vizinhança de θ , $g'(\theta) = 0$ e $g''(\theta) \neq 0$, então

$$a_n^2 [g(Y_n) - g(\theta)] \xrightarrow{d} \frac{1}{2}g''(\theta)W^2.$$

Em particular, se $a_n = \sqrt{n}$ e $W \sim N(0, V(\theta))$, temos

$$n [g(Y_n) - g(\theta)] \xrightarrow{d} \frac{V(\theta)g''(\theta)}{2} \chi_1^2.$$

O método delta pode ser estendido naturalmente ao caso em que o parâmetro de interesse é um vetor. Nesse contexto, consideramos uma sequência de estimadores δ_n de um parâmetro $\theta \in \mathbb{R}^p$ e uma função $g : \mathbb{R}^p \rightarrow \mathbb{R}^q$. A expansão de Taylor de primeira ordem é então determinada pela matriz Jacobiana de g , conduzindo à versão multivariada do método delta.

Teorema 2.5 (Método Delta Multivariado). Seja δ_n uma sequência de estimadores de $\theta \in \mathbb{R}^p$ tal que, para alguma sequência de constantes positivas $a_n \rightarrow \infty$,

$$a_n(\delta_n - \theta) \xrightarrow{d} \mathbf{W}.$$

Seja $g : \mathbb{R}^p \rightarrow \mathbb{R}^q$ diferenciável em θ , com matriz Jacobiana

$$Dg(\theta) = \left[\frac{\partial g_i(\theta)}{\partial \theta_j} \right]_{\substack{i=1,\dots,q \\ j=1,\dots,p}}.$$

Então,

$$a_n [g(\delta_n) - g(\theta)] \xrightarrow{d} Dg(\theta) \mathbf{W}.$$

Em particular, se $\sqrt{n}(\delta_n - \theta) \xrightarrow{d} N_p(\mathbf{0}, \Sigma)$, temos $\sqrt{n} [g(\delta_n) - g(\theta)] \xrightarrow{d} N_q(\mathbf{0}, Dg(\theta) \Sigma Dg(\theta)^\top)$.

3. EFICIÊNCIA RELATIVA ASSINTÓTICA

Uma forma natural de comparar dois estimadores com a mesma taxa de convergência é comparar suas variâncias assintóticas. Em particular, considere δ_{1n} e δ_{2n} duas sequências de estimadores do parâmetro θ tais que

$$a_n(\delta_{1n} - \theta) \xrightarrow{d} N(0, V_1(\theta)) \quad \text{e} \quad a_n(\delta_{2n} - \theta) \xrightarrow{d} N(0, V_2(\theta)).$$

As quantidades $V_1(\theta)$ e $V_2(\theta)$ são denominadas variâncias assintóticas de δ_{1n} e δ_{2n} , respectivamente. Se $V_1(\theta) < V_2(\theta)$, dizemos que δ_{1n} é assintoticamente mais eficiente do que δ_{2n} .

Uma medida da eficiência relativa entre os dois estimadores é dada pela eficiência relativa assintótica de δ_{1n} em relação a δ_{2n} , definida por

$$\text{ARE}_\theta(\delta_{1n}, \delta_{2n}) = \frac{V_2(\theta)}{V_1(\theta)}.$$

Assim, $\text{ARE}_\theta(\delta_{1n}, \delta_{2n}) > 1$ indica que δ_{1n} é assintoticamente mais eficiente do que δ_{2n} .

Exemplo 3.1. Considere $X_1, \dots, X_n \stackrel{i.i.d.}{\sim} N(\theta, 1)$ e suponha que nosso interesse seja estimar

$$p = \mathbb{P}_\theta(X_i \leq a) = \Phi(a - \theta),$$

onde a é uma constante conhecida e Φ denota a função de distribuição acumulada da normal padrão.

Um possível estimador de p é obtido substituindo θ por $\bar{X}_n$: $\hat{p}_n = \Phi(a - \bar{X}_n)$. Uma possibilidade alternativa é utilizar diretamente a proporção de observações da amostra menores ou iguais a a ,

$$\tilde{p}_n = \frac{1}{n} \sum_{i=1}^n \mathbb{1}(X_i \leq a).$$

Como $\mathbb{1}(X_i \leq a)$ possui distribuição Bernoulli com parâmetro $p = \Phi(a - \theta)$, pelo Teorema do Limite Central,

$$\sqrt{n}(\tilde{p}_n - p) \xrightarrow{d} N(0, \Phi(a - \theta) [1 - \Phi(a - \theta)]).$$

Por outro lado, pelo Teorema do Limite Central,

$$\sqrt{n}(\bar{X}_n - \theta) \xrightarrow{d} N(0, 1).$$

Definindo $g(x) = \Phi(a - x)$, temos que $g'(x) = -\phi(a - x)$, onde ϕ denota a densidade da normal padrão. Assim, pelo Método Delta,

$$\sqrt{n}(\hat{p}_n - p) = \sqrt{n} [g(\bar{X}_n) - g(\theta)] \xrightarrow{d} N(0, \phi^2(a - \theta)).$$

Portanto, a eficiência relativa assintótica de $\hat{p}_n$ em relação a $\tilde{p}_n$ é

$$\text{ARE}_\theta(\hat{p}_n, \tilde{p}_n) = \frac{\Phi(a - \theta) [1 - \Phi(a - \theta)]}{\phi^2(a - \theta)}.$$

Em particular, quando $\theta = a$,

$$\text{ARE}_\theta(\hat{p}_n, \tilde{p}_n) = \frac{(1/2)(1/2)}{(1/\sqrt{2\pi})^2} = \frac{\pi}{2}.$$

Logo, nesse caso, $\hat{p}_n$ é assintoticamente mais eficiente do que $\tilde{p}_n$.

OBSERVAÇÃO. A eficiência relativa assintótica depende do valor de θ e, neste exemplo, aumenta à medida que $|a - \theta|$ cresce. Entretanto, essa maior eficiência de $\hat{p}_n$ depende da especificação correta do modelo normal. O estimador $\tilde{p}_n$, por outro lado, corresponde à proporção amostral de observações menores ou iguais a a e continua sendo um estimador natural de $\mathbb{P}(X_i \leq a)$ mesmo quando a distribuição da população não é normal. Assim, o ganho de eficiência de $\hat{p}_n$ deve ser considerado em conjunto com sua maior dependência da especificação do modelo.

EXERCÍCIOS

1. Sejam $X_1, \dots, X_n$ variáveis aleatórias *i.i.d.* com distribuição exponencial com taxa λ e $X_{(n)} = \max\{X_1, \dots, X_n\}$. Verifique se $\log(n)/X_{(n)}$ é um estimador consistente de λ .
2. Sejam $X_1, \dots, X_n$ variáveis aleatórias *i.i.d.* com densidade $f_\theta(x) = (x - \theta)_+ e^{\theta - x}$, onde $(x - \theta)_+ = \max\{x - \theta, 0\}$. Mostre que $X_{(1)} = \min\{X_1, \dots, X_n\}$ é um estimador consistente de θ e determine a distribuição limite de $\sqrt{n}(X_{(1)} - \theta)$.
3. Sejam $X_1, X_2, \dots$ variáveis aleatórias independentes com distribuição Bernoulli(p) e $\bar{X}_n = \sum_{i=1}^n X_i/n$.
 - (a) Mostre que $\sqrt{n}(\bar{X}_n - p) \xrightarrow{d} N(0, p(1 - p))$.
 - (b) Mostre que, para $p \neq 1/2$, $\sqrt{n}[\bar{X}_n(1 - \bar{X}_n) - p(1 - p)] \xrightarrow{d} N(0, (1 - 2p)^2 p(1 - p))$.
 - (c) Mostre que, para $p = 1/2$, $n[\bar{X}_n(1 - \bar{X}_n) - 1/4] \xrightarrow{d} -1/4\chi_1^2$.
4. Sejam $X_1, \dots, X_n$ variáveis aleatórias *i.i.d.* com distribuição exponencial com taxa θ . Considere os estimadores $\hat{p}_n = \#\{i \leq n : X_i \geq 1\}/n$ e $\bar{X}_n = \sum_{i=1}^n X_i/n$. Determine a eficiência relativa assintótica de $-\log(\hat{p}_n)$ em relação a $1/\bar{X}_n$.
5. Sejam $X_1, \dots, X_n$ variáveis aleatórias *i.i.d.* com distribuição $N(\theta, \theta)$, onde $\theta > 0$. Desejamos estimar $\theta(\theta + 1)$. Determine a eficiência relativa assintótica de $\bar{X}_n(\bar{X}_n + 1)$ em relação a $\sum_{i=1}^n X_i^2/n$.
6. Sejam $X_1, \dots, X_n$ variáveis aleatórias *i.i.d.* com distribuição $N(\theta, \theta)$, onde $\theta > 0$. Considere dois estimadores naturais de θ : a média amostral $\bar{X}_n$ e a variância amostral S_n^2 . Determine a eficiência relativa assintótica de S_n^2 em relação a $\bar{X}_n$.