

1. INTRODUÇÃO

Seja $\mathbf{X} = (X_1, \dots, X_n)$ um vetor aleatório cuja distribuição depende de um parâmetro $\theta \in \Theta$. Vimos anteriormente que, por meio da função de verossimilhança, podemos comparar diferentes valores do parâmetro à luz da amostra observada. Em particular, para uma realização $\mathbf{X} = \mathbf{x}$ e dois valores fixados $\theta_1, \theta_2 \in \Theta$, podemos comparar $L(\theta_1; \mathbf{x})$ e $L(\theta_2; \mathbf{x})$ e determinar qual deles torna os dados observados mais plausíveis.

Essa ideia sugere naturalmente um procedimento para estimar o parâmetro desconhecido. Para cada possível realização $\mathbf{x}$ de $\mathbf{X}$, podemos procurar um valor $\hat{\theta}(\mathbf{x}) \in \Theta$ para o qual a função de verossimilhança $L(\theta; \mathbf{x})$ atinja seu máximo. Dessa forma, $\hat{\theta}(\mathbf{X})$ define um estimador de θ , denominado estimador de máxima verossimilhança (EMV).

Um possível problema de natureza analítica associado à definição do estimador de máxima verossimilhança é garantir que o máximo da função de verossimilhança exista em Θ e que o valor encontrado corresponda, de fato, a um máximo global. Em particular, encontrar uma solução da equação de verossimilhança não é suficiente para garantir que seja um estimador de máxima verossimilhança.

Quando a função de verossimilhança é diferenciável em θ , possíveis candidatos a estimador de máxima verossimilhança são os valores de θ que satisfazem

$$\frac{\partial}{\partial \theta} L(\theta; \mathbf{x}) = 0.$$

Note que as soluções dessa equação são apenas candidatos possíveis, uma vez que a condição de primeira ordem é necessária, mas não suficiente, para caracterizar um máximo interior. Além disso, a condição de primeira ordem permite localizar apenas possíveis pontos de máximo no interior do domínio da função. Caso o máximo ocorra na fronteira do domínio, a primeira derivada pode não ser nula.

Em muitos casos, especialmente quando recorremos à diferenciação, será mais simples trabalhar com a função log-verossimilhança. Como a função logarítmica é estritamente crescente, maximizar a função de verossimilhança equivale a maximizar a log-verossimilhança. Assim, quando $\ell(\theta; \mathbf{x})$ é diferenciável e o máximo ocorre em um ponto interior de Θ , possíveis candidatos a EMV satisfazem a equação de score

$$U(\theta; \mathbf{x}) = \frac{\partial}{\partial \theta} \ell(\theta; \mathbf{x}) = 0.$$

Exemplo 1.1. Sejam $X_1, \dots, X_n$ variáveis aleatórias *i.i.d.* com $X_i \sim N(\theta, 1)$, $\theta \in \mathbb{R}$. A função de verossimilhança é dada por

$$L(\theta; \mathbf{x}) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}} \exp \left\{ -\frac{1}{2}(x_i - \theta)^2 \right\} = (2\pi)^{-n/2} \exp \left\{ -\frac{1}{2} \sum_{i=1}^n (x_i - \theta)^2 \right\}.$$

Logo, a função log-verossimilhança e a função score são dadas respectivamente por

$$\ell(\theta; \mathbf{x}) = -\frac{n}{2} \log(2\pi) - \frac{1}{2} \sum_{i=1}^n (x_i - \theta)^2 \quad \text{e} \quad U(\theta; \mathbf{x}) = \frac{\partial}{\partial \theta} \ell(\theta; \mathbf{x}) = \sum_{i=1}^n (x_i - \theta).$$

Igualando a função score a zero, obtemos $\sum_{i=1}^n (x_i - \theta) = 0$ e, portanto,

$$\hat{\theta}(\mathbf{x}) = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}.$$

Como a segunda derivada da log-verossimilhança é constante e negativa,

$$\frac{\partial^2}{\partial \theta^2} \ell(\theta; \mathbf{x}) = -n < 0, \quad \forall \theta \in \mathbb{R},$$

a log-verossimilhança é estritamente côncava em $\Theta = \mathbb{R}$. Como Θ é convexo, segue que qualquer ponto crítico é um máximo global; logo, $\bar{x}$ é o único ponto de máximo global de $\ell(\theta; \mathbf{x})$.

Exemplo 1.2. Sejam $X_1, \dots, X_n$ variáveis aleatórias *i.i.d.* com $X_i \sim \text{Uniforme}(0, \theta)$, $\theta > 0$. A função de verossimilhança é dada por

$$L(\theta; \mathbf{x}) = \prod_{i=1}^n \frac{1}{\theta} \mathbb{1}(0 < x_i < \theta) = \frac{1}{\theta^n} \mathbb{1}(0 < x_{(1)}) \mathbb{1}(x_{(n)} < \theta).$$

Diferentemente do exemplo anterior, a função de verossimilhança não é diferenciável em $\theta = x_{(n)}$ e, na região em que $L(\theta; \mathbf{x}) > 0$, temos

$$\frac{\partial}{\partial \theta} L(\theta; \mathbf{x}) = -\frac{n}{\theta^{n+1}} < 0, \quad \forall \theta > x_{(n)}.$$

Ou seja, a equação de verossimilhança $\partial L(\theta; \mathbf{x}) / \partial \theta = 0$ não possui solução: $L(\theta; \mathbf{x})$ é estritamente decrescente em θ em toda a região onde está definida e é positiva. Como $L(\theta; \mathbf{x})$ é decrescente para $\theta > x_{(n)}$ e nula para $\theta \leq x_{(n)}$, o máximo é atingido no ponto de fronteira dessa região, isto é, em $\theta = x_{(n)}$. Consequentemente, o estimador de máxima verossimilhança de θ é

$$\hat{\theta}(\mathbf{X}) = X_{(n)} = \max_{1 \leq i \leq n} X_i.$$

Outra possível questão relativa aos estimadores de máxima verossimilhança é de natureza numérica: mesmo quando o máximo existe [e é único], é importante investigar a estabilidade da solução, uma vez que pequenas alterações nos dados observados podem produzir grandes alterações no valor que maximiza a função de verossimilhança.

Exemplo 1.3. Sejam $X_1, \dots, X_n$ variáveis aleatórias *i.i.d.* com $X_i \sim \text{Binomial}(k, p)$, em que $k \in \mathbb{N}$ e $p \in (0, 1)$ são desconhecidos. A função de verossimilhança é dada por

$$L(k, p; \mathbf{x}) = \prod_{i=1}^n \binom{k}{x_i} p^{x_i} (1-p)^{k-x_i} = \left\{ \prod_{i=1}^n \binom{k}{x_i} \right\} p^{n\bar{x}} (1-p)^{nk-n\bar{x}},$$

para $k \geq x_{(n)} = \max\{x_1, \dots, x_n\}$.

Para um valor fixado de k , a log-verossimilhança, como função de p , é

$$\ell(k, p; \mathbf{x}) = \sum_{i=1}^n \log \binom{k}{x_i} + n\bar{x} \log p + n(k - \bar{x}) \log(1-p),$$

e a equação de score para p ,

$$\frac{\partial}{\partial p} \ell(k, p; \mathbf{x}) = \frac{n\bar{x}}{p} - \frac{n(k - \bar{x})}{1-p} = 0,$$

fornece o EMV condicional de p dado k : $\hat{p}_k = \bar{x}/k$.

Substituindo $\hat{p}_k$ de volta na verossimilhança, obtemos a verossimilhança perfilada em k ,

$$L(k; \mathbf{x}, p) = \left\{ \prod_{i=1}^n \binom{k}{x_i} \right\} \left(\frac{\bar{x}}{k} \right)^{n\bar{x}} \left(1 - \frac{\bar{x}}{k} \right)^{n(k-\bar{x})}, \quad k = x_{(n)}, x_{(n)} + 1, \dots$$

Como k assume apenas valores inteiros, não há uma fórmula fechada para o valor que maximiza $L(k; \mathbf{x}, p)$: o EMV

$$\hat{k} = \arg \max_{k \geq x_{(n)}} L(k; \mathbf{x}, p), \quad \hat{p} = \frac{\bar{x}}{\hat{k}},$$

precisa ser obtido por busca numérica direta entre os inteiros $k \geq x_{(n)}$.

Considere agora a realização $\mathbf{x} = (16, 18, 22, 25, 27)$. Neste caso, $\bar{x} = 21.6$ e $x_{(n)} = 27$. A maximização de $L(k; \mathbf{x}, p)$ sobre $k = 27, 28, \dots$ fornece

$$\hat{k} = 99, \quad \text{e} \quad \hat{p} = \frac{21.6}{99} \approx 0.218.$$

Considere, entretanto, uma pequena alteração na realização observada, substituindo a última observação, 27, por 28: $\mathbf{x}' = (16, 18, 22, 25, 28)$. Agora, $\bar{x}' = 21.8$ e $x'_{(n)} = 28$, e a maximização de $L(k; \mathbf{x}', p)$ fornece

$$\hat{k} = 191, \quad \text{e} \quad \hat{p} = \frac{21.8}{191} \approx 0.114.$$

Portanto, a alteração de apenas uma observação, de 27 para 28, produz uma mudança substancial nas estimativas de máxima verossimilhança:

$$(\hat{k}, \hat{p}): (99, 0.218) \longrightarrow (191, 0.114).$$

Embora a média amostral sofra apenas uma pequena alteração, de 21.6 para 21.8, a estimativa de k passa de 99 para 191 e a estimativa de p passa de aproximadamente 0.218 para 0.114.

2. PROPRIEDADES

2.1. Invariância. Uma propriedade importante do estimador de máxima verossimilhança é sua invariância sob reparametrizações: se $\hat{\theta}$ é o EMV de θ , então o EMV de qualquer função $g(\theta)$ é simplesmente $g(\hat{\theta})$, mesmo quando g não é injetiva.

Teorema 2.1 (Princípio da Invariância). Seja $\hat{\theta}$ o estimador de máxima verossimilhança de θ e seja $g: \Theta \rightarrow \Lambda$ uma função qualquer (não necessariamente injetiva). Então o estimador de máxima verossimilhança de $\lambda = g(\theta)$ é

$$\hat{\lambda} = g(\hat{\theta}).$$

Demonstração. Para $\lambda \in \Lambda$, seja $\Theta_\lambda = g^{-1}(\{\lambda\}) = \{\theta \in \Theta : g(\theta) = \lambda\}$, definimos a verossimilhança induzida

$$L^*(\lambda; \mathbf{x}) = \sup_{\theta \in \Theta_\lambda} L(\theta; \mathbf{x}),$$

com a convenção $L^*(\lambda; \mathbf{x}) = 0$ se $\Theta_\lambda = \emptyset$ (i.e., se $\lambda \notin g(\Theta)$). Dizemos que $\hat{\lambda}$ é o estimador de máxima verossimilhança de $\lambda = g(\theta)$ se $\hat{\lambda}$ maximiza $L^*(\cdot; \mathbf{x})$ sobre Λ .

Como $\{\Theta_\lambda\}_{\lambda \in \Lambda}$ particiona Θ , temos que

$$(1) \quad \sup_{\lambda \in \Lambda} L^*(\lambda; \mathbf{x}) = \sup_{\lambda \in \Lambda} \sup_{\theta \in \Theta_\lambda} L(\theta; \mathbf{x}) = \sup_{\theta \in \Theta} L(\theta; \mathbf{x}) = L(\hat{\theta}; \mathbf{x}).$$

Como $\hat{\theta}$ maximiza $L(\theta; \mathbf{x})$ sobre todo Θ e $\hat{\theta} \in \Theta_{g(\hat{\theta})}$, segue que $\hat{\theta}$ também maximiza $L(\theta; \mathbf{x})$ sobre $\Theta_{g(\hat{\theta})}$, isto é,

$$(2) \quad L^*(g(\hat{\theta}); \mathbf{x}) = \sup_{\theta \in \Theta_{g(\hat{\theta})}} L(\theta; \mathbf{x}) = L(\hat{\theta}; \mathbf{x}).$$

Como consequência de (1) e (2), concluímos que

$$L^*(g(\hat{\theta}); \mathbf{x}) = L(\hat{\theta}; \mathbf{x}) = \sup_{\lambda \in \Lambda} L^*(\lambda; \mathbf{x}),$$

ou seja, $g(\hat{\theta})$ maximiza $L^*(\cdot; \mathbf{x})$ sobre Λ . Desta forma, temos que $g(\hat{\theta})$ é o estimador de máxima verossimilhança de $\lambda = g(\theta)$, isto é, $\hat{\lambda} = g(\hat{\theta})$. $\square$

2.2. Consistência. Vimos anteriormente que a consistência funciona como uma validação assintótica de um procedimento de estimação: apesar de não dizer nada sobre o desempenho do estimador para n fixado (pequenas amostras podem produzir estimativas ruins mesmo com um estimador consistente), garante que, ao menos no limite, o procedimento converge para a quantidade de interesse. A seguir, verificamos se essa propriedade se aplica ao estimador de máxima verossimilhança.

Teorema 2.2 (Consistência do EMV). Sejam $X_1, \dots, X_n$ variáveis aleatórias *i.i.d.* com densidade $f(\cdot; \theta)$, $\theta \in \Theta$, e seja $\theta_0 \in \Theta$ o verdadeiro valor do parâmetro. Suponha:

- (A1) (*Identificabilidade*) Se $\theta_1 \neq \theta_2$, então $\mathbb{P}_{\theta_1} \neq \mathbb{P}_{\theta_2}$;
- (A2) $\mathbb{E}_{\theta_0} [|\log f(X_1; \theta)|] < \infty$ para todo $\theta \in \Theta$;
- (A3) $\Theta \subset \mathbb{R}$ é compacto;
- (A4) $\theta \mapsto f(x; \theta)$ é contínua para quase todo x .

Sob condições adicionais de regularidade, o estimador de máxima verossimilhança $\hat{\theta}_n$ é consistente para θ_0 , isto é,

$$\hat{\theta}_n \xrightarrow{\mathbb{P}} \theta_0.$$

Demonstração. Como $X_1, \dots, X_n$ são variáveis aleatórias *i.i.d.* com densidade $f(\cdot; \theta)$, $\ell(\theta; \mathbf{x}) = \sum_{i=1}^n \ell(\theta; x_i) = \sum_{i=1}^n \log f(x_i; \theta)$, de modo que $\hat{\theta}_n = \arg \max_{\theta \in \Theta} \ell(\theta; \mathbf{X})$. Tomando $M_n(\theta) = \frac{1}{n} \ell(\theta; \mathbf{X})$, temos

$$\hat{\theta}_n = \arg \max_{\theta \in \Theta} \sum_{i=1}^n \ell(\theta; X_i) = \arg \max_{\theta \in \Theta} M_n(\theta).$$

Convergência pontual. Para cada $\theta \in \Theta$ fixado, $\ell(\theta; X_1), \ell(\theta; X_2), \dots$ são *i.i.d.* sob $\mathbb{P}_{\theta_0}$, com $\mathbb{E}_{\theta_0} [|\ell(\theta; X_1)|] < \infty$ por (A2). Pela Lei dos Grandes Números,

$$M_n(\theta) \xrightarrow{\mathbb{P}} M(\theta) := \mathbb{E}_{\theta_0} [\ell(\theta; X_1)].$$

M tem um único máximo em θ_0 . Para qualquer $\theta \in \Theta$,

$$M(\theta_0) - M(\theta) = \mathbb{E}_{\theta_0} \left[\log \frac{f(X_1; \theta_0)}{f(X_1; \theta)} \right] = \text{KL}(\theta_0, \theta),$$

a informação de Kullback–Leibler entre θ_0 e θ . Pela desigualdade de Jensen,

$$-\text{KL}(\theta_0, \theta) = \mathbb{E}_{\theta_0} \left[\log \frac{f(X_1; \theta)}{f(X_1; \theta_0)} \right] \leq \log \mathbb{E}_{\theta_0} \left[\frac{f(X_1; \theta)}{f(X_1; \theta_0)} \right] \leq \log 1 = 0,$$

com igualdade quando $f(\cdot; \theta) = f(\cdot; \theta_0)$ quase certamente, ou seja, $\mathbb{P}_\theta = \mathbb{P}_{\theta_0}$. Portanto, $\text{KL}(\theta_0, \theta) \geq 0$, com igualdade se, e somente se, $\mathbb{P}_\theta = \mathbb{P}_{\theta_0}$.

Por (A1) (identificabilidade), $\mathbb{P}_\theta = \mathbb{P}_{\theta_0}$ se, e somente se, $\theta = \theta_0$. Logo,

$$M(\theta) \leq M(\theta_0), \quad \forall \theta \in \Theta,$$

com igualdade se, e somente se, $\theta = \theta_0$. Ou seja, M possui um único ponto de máximo em Θ , dado por θ_0 .

Consistência do argmax. Para concluirmos, é necessário fortalecer a convergência pontual para uma convergência uniforme em $\theta \in \Theta$, isto é,

$$\sup_{\theta \in \Theta} |M_n(\theta) - M(\theta)| \xrightarrow{\mathbb{P}} 0.$$

Sob as condições (A2)–(A4) (possivelmente fortalecidas por uma condição de integrabilidade uniforme), essa convergência uniforme de fato ocorre (KN, Teorema 9.2). Uma vez estabelecida essa convergência uniforme, um argumento geométrico permite concluir a convergência do argmax (KN, Teorema 9.4).

Aplicando esses dois resultados, com M e M_n como definidos acima, e usando a unicidade do máximo de M em θ_0 estabelecida anteriormente, concluimos que

$$\hat{\theta}_n \xrightarrow{\mathbb{P}} \theta_0,$$

como queríamos demonstrar. $\square$

O resultado de consistência apresentado acima vale, sem qualquer alteração na estrutura da demonstração, para $\boldsymbol{\theta}$, $\boldsymbol{\theta} \in \Theta \subset \mathbb{R}^p$. A hipótese de compacidade de Θ , por outro lado, pode ser relaxada para $\Theta = \mathbb{R}^p$ — o que é relevante, por exemplo, no caso da distribuição Normal, em que $\Theta = \mathbb{R}$ — mas isso exige condições adicionais de regularidade. Para mais detalhes, ver KN, Seções 9.1 e 9.2.

2.3. Eficiência assintótica.

Teorema 2.3 (Normalidade Assintótica do EMV). Sejam $X_1, \dots, X_n$ variáveis aleatórias *i.i.d.* com densidade $f(\cdot; \theta)$, $\theta \in \Theta \subset \mathbb{R}$, e seja θ_0 o verdadeiro valor do parâmetro, no interior de Θ . Suponha:

- (B1) O conjunto $A = \{x : f(x; \theta) > 0\}$ não depende de θ ;
- (B2) Para todo $x \in A$, $\frac{\partial^2}{\partial \theta^2} \log f(x; \theta)$ existe e é contínua em θ ;
- (B3) A informação de Fisher $I(\theta)$ de uma única observação é finita e estritamente positiva, para todo $\theta \in \Theta$;
- (B4) Existe $\epsilon > 0$ tal que

$$\mathbb{E}_{\theta_0} \left[\sup_{|\theta - \theta_0| < \epsilon} \left| \frac{\partial^2}{\partial \theta^2} \log f(X_1; \theta) \right| \right] < \infty;$$

- (B5) O estimador de máxima verossimilhança $\hat{\theta}_n$ é consistente para θ_0 .

Então,

$$\sqrt{n}(\hat{\theta}_n - \theta_0) \xrightarrow{d} N\left(0, \frac{1}{I(\theta_0)}\right).$$

Demonstração. Como $\hat{\theta}_n$ é consistente para θ_0 , por (B5), temos que $\hat{\theta}_n$ pertence ao interior de Θ com probabilidade tendendo a 1. Nesse evento, $\hat{\theta}_n$ satisfaz a equação de score,

$$U(\hat{\theta}_n; \mathbf{X}) = 0,$$

onde $U(\theta; \mathbf{X}) = \sum_{i=1}^n U(\theta; X_i) = \sum_{i=1}^n \frac{\partial}{\partial \theta} \ell(\theta; X_i)$.

Expansão de Taylor. Por (B2), $\theta \mapsto U(\theta; \mathbf{X})$ é diferenciável, logo, pelo Teorema do Valor Médio, existe $\tilde{\theta}_n$ entre $\hat{\theta}_n$ e θ_0 tal que

$$0 = U(\hat{\theta}_n; \mathbf{X}) = U(\theta_0; \mathbf{X}) + U'(\tilde{\theta}_n; \mathbf{X}) (\hat{\theta}_n - \theta_0).$$

Isolando $(\hat{\theta}_n - \theta_0)$ e multiplicando por $\sqrt{n}$,

$$\sqrt{n}(\hat{\theta}_n - \theta_0) = \frac{n^{-1/2} U(\theta_0; \mathbf{X})}{-n^{-1} U'(\tilde{\theta}_n; \mathbf{X})}.$$

Numerador (via TLC). Como $U(\theta_0; X_1), U(\theta_0; X_2), \dots$ são *i.i.d.* sob $\mathbb{P}_{\theta_0}$, com $\mathbb{E}_{\theta_0}[U(\theta_0; X_1)] = 0$ e $\text{Var}_{\theta_0}(U(\theta_0; X_1)) = I(\theta_0)$ (Aula 06), o Teorema Limite Central garante

$$n^{-1/2} U(\theta_0; \mathbf{X}) \xrightarrow{d} N(0, I(\theta_0)).$$

Denominador (via LGN). Como $U'(\theta_0; X_1), U'(\theta_0; X_2), \dots$ são *i.i.d.* sob $\mathbb{P}_{\theta_0}$, com $\mathbb{E}_{\theta_0}[U'(\theta_0; X_1)] = -I(\theta_0)$ (Aula 06), a Lei dos Grandes Números garante

$$-n^{-1} U'(\theta_0; \mathbf{X}) \xrightarrow{\mathbb{P}} I(\theta_0).$$

Resta transferir essa convergência de θ_0 para o ponto aleatório $\tilde{\theta}_n$. Como $\tilde{\theta}_n$ está entre $\hat{\theta}_n$ e θ_0 e $\hat{\theta}_n \xrightarrow{\mathbb{P}} \theta_0$ (B5), segue que $\tilde{\theta}_n \xrightarrow{\mathbb{P}} \theta_0$. A continuidade de $\theta \mapsto \frac{\partial^2}{\partial \theta^2} \ell(\theta; x)$ (B2), junto com a condição de dominação (B4), garante que

$$-n^{-1} U'(\tilde{\theta}_n; \mathbf{X}) - [-n^{-1} U'(\theta_0; \mathbf{X})] \xrightarrow{\mathbb{P}} 0.$$

Consequentemente,

$$-n^{-1} U'(\tilde{\theta}_n; \mathbf{X}) \xrightarrow{\mathbb{P}} I(\theta_0).$$

Conclusão. Combinando a convergência em distribuição do numerador com a convergência em probabilidade do denominador à constante $I(\theta_0) > 0$, o Teorema de Slutsky garante

$$\sqrt{n}(\hat{\theta}_n - \theta_0) = \frac{n^{-1/2} U(\theta_0; \mathbf{X})}{-n^{-1} U'(\tilde{\theta}_n; \mathbf{X})} \xrightarrow{d} \frac{N(0, I(\theta_0))}{I(\theta_0)} = N\left(0, \frac{1}{I(\theta_0)}\right).$$

□

Corolário 2.1 (Normalidade Assintótica de $g(\hat{\theta}_n)$). Sob as condições do Teorema de Normalidade Assintótica do EMV, seja $g : \Theta \rightarrow \mathbb{R}$ diferenciável em θ_0 , com $g'(\theta_0) \neq 0$. Então,

$$\sqrt{n}(g(\hat{\theta}_n) - g(\theta_0)) \xrightarrow{d} N\left(0, \frac{[g'(\theta_0)]^2}{I(\theta_0)}\right).$$

Demonstração. Pelo Teorema de Normalidade Assintótica do EMV,

$$\sqrt{n}(\hat{\theta}_n - \theta_0) \xrightarrow{d} N\left(0, \frac{1}{I(\theta_0)}\right).$$

Como g é diferenciável em θ_0 com $g'(\theta_0) \neq 0$, o Método Delta (Aula 07) garante

$$\sqrt{n}(g(\hat{\theta}_n) - g(\theta_0)) \xrightarrow{d} N\left(0, [g'(\theta_0)]^2 \cdot \frac{1}{I(\theta_0)}\right) = N\left(0, \frac{[g'(\theta_0)]^2}{I(\theta_0)}\right).$$

Pelo Princípio da Invariância, $g(\hat{\theta}_n)$ é o estimador de máxima verossimilhança de $g(\theta)$; portanto, o resultado acima estabelece a normalidade assintótica do EMV de qualquer função diferenciável do parâmetro, com variância assintótica $[g'(\theta_0)]^2/I(\theta_0)$. □

Dado o Corolário anterior, podemos dizer que o estimador de máxima verossimilhança é assintoticamente eficiente, no sentido de que sua variância assintótica coincide com a cota inferior de Cramér–Rao.

3. EXERCÍCIOS

KN, Ch9: 13 (a,b,c); 20 (a); 21 (b); 25 (a,b); 26 (a,b); 29.
CB, Ch7: 19, 20, 21.