1. INTRODUÇÃO

Uma estimativa pontual $\delta = \delta(X)$ de $g(\theta)$, isoladamente, não fornece uma medida da incerteza associada à estimação. Se a distribuição de δ é contínua, então $\P_\theta\big(\delta = g(\theta)\big) = 0$ para todo $\theta \in \Theta$, isto é, a estimativa observada quase certamente não coincide com o valor verdadeiro. Uma alternativa é buscar duas estatísticas $\delta_0 = \delta_0(X)$ e $\delta_1 = \delta_1(X)$ que delimitem $g(\theta)$ com alta probabilidade.

Definição 1.1. Sejam δ_0 e δ_1 estatísticas. O intervalo aleatório (δ_0, δ_1) é dito um intervalo de confiança de nível $1-\alpha$ para $g(\theta)$ se

$$\mathbb{P}_\theta\big(g(\theta) \in (\delta_0, \delta_1)\big) \;\geq\; 1-\alpha,\ \forall \theta \in \Theta.$$

De modo mais geral, um conjunto aleatório $C(X)$ é dito uma região de confiança de nível $1-\alpha$ para $g(\theta)$ se

$$\mathbb{P}_\theta\big(g(\theta) \in C(X)\big) \;\geq\; 1-\alpha,\ \forall \theta \in \Theta.$$

OBSERVAÇÃO: Em $\mathbb{P}_\theta\big(g(\theta) \in (\delta_0, \delta_1)\big)$, a aleatoriedade está no intervalo (δ_0, δ_1), e não o parâmetro, que é fixo (porém desconhecido). A probabilidade é, portanto, uma propriedade do procedimento, calculada antes de se observar os dados. Uma vez observado x, o intervalo $(\delta_0(x), \delta_1(x))$ é um intervalo determinado que contém $g(\theta)$ ou não o contém.

A função de θ que aparece na definição tem um nome próprio.

Definição 1.2. A probabilidade de cobertura de uma região de confiança $C(X)$ para $g(\theta)$ é a função

$$\theta \mapsto \mathbb{P}_\theta\big(g(\theta) \in C(X)\big),\ \theta \in \Theta,$$

e o coeficiente de confiança de $C(X)$ é o seu ínfimo,

$$\inf_{\theta\in\Theta} \mathbb{P}_\theta\big(g(\theta) \in C(X)\big).$$

Assim, $C(X)$ tem nível $1-\alpha$ se e somente se o coeficiente de confiança de $C(X)$ é pelo menos $1-\alpha$.

OBSERVAÇÃO: Em geral, a probabilidade de cobertura depende de θ. Quando ela é constante, o coeficiente de confiança coincide com esse valor. Quando ela varia, o coeficiente de confiança é determinado pela menor cobertura ao longo do espaço paramétrico, e não pela cobertura em um valor particular de θ.

Exemplo 1.1. Sejam $X_1, \ldots, X_n$ variáveis aleatórias *i.i.d.* com distribuição $\text{Unif}(0, \theta)$, $\theta \in (0, \infty)$, e $X_{(n)} = \max\{X_1, \ldots, X_n\}$. Para $0 < y < \theta$,

$$\mathbb{P}_\theta\big(X_{(n)} \leq y\big) = \prod_{i=1}^{n} \mathbb{P}_\theta(X_i \leq y) = \left(\frac{y}{\theta}\right)^n.$$

Como $X_{(n)} \leq \theta$ com probabilidade um, consideramos dois procedimentos de estimação intervalar para θ:

$$C_1 = \big[\, aX_{(n)},\, bX_{(n)} \,\big],\ 1 \leq a < b, \quad \text{e} \quad C_2 = \big[\, X_{(n)} + c,\, X_{(n)} + d \,\big],\ 0 \leq c < d.$$

Intervalo C_1. Temos $\theta \in C_1$ se, e somente se, $\theta/b \leq X_{(n)} \leq \theta/a$. Portanto

$$\mathbb{P}_\theta\big(\theta \in C_1\big) = \mathbb{P}_\theta\left(\frac{\theta}{b} \leq X_{(n)} \leq \frac{\theta}{a}\right) = \left(\frac{1}{a}\right)^n - \left(\frac{1}{b}\right)^n.$$

A probabilidade de cobertura é constante e igual a $a^{-n} - b^{-n}$, que coincide, portanto, com o coeficiente de confiança de C_1. Em particular, C_1 tem nível $1-\alpha$ sempre que $a^{-n} - b^{-n} \geq 1-\alpha$. Por exemplo, $a = 1$ e $b = \alpha^{-1/n}$ produzem probabilidade de cobertura igual a $1-\alpha$ para todo $\theta > 0$.
Intervalo C_2. Agora, $\theta \in C_2$ se, e somente se, $\theta - d \leq X_{(n)} \leq \theta - c$, e

$$\mathbb{P}_\theta\big(\theta \in C_2\big) = \begin{cases} 0, & \theta \leq c, \\ \left(1 - \dfrac{c}{\theta}\right)^n, & c < \theta \leq d, \\ \left(1 - \dfrac{c}{\theta}\right)^n - \left(1 - \dfrac{d}{\theta}\right)^n, & \theta > d. \end{cases}$$

Aqui a cobertura depende de θ. Além disso, para θ grande, $(1-c/\theta)^n - (1-d/\theta)^n \approx n(d-c)/\theta \to 0$ quando $\theta \to \infty$, e então

$$\inf_{\theta>0} \mathbb{P}_\theta\big(\theta \in C_2\big) = 0.$$

Portanto, o coeficiente de confiança de C_2 é zero, embora a sua cobertura seja alta para alguns valores de θ.

2. Quantidades pivotais

Definição 2.1. Uma quantidade pivotal (ou pivô) é uma variável aleatória $Q(X, \theta)$, função dos dados X e do parâmetro θ, cuja distribuição não depende de θ, isto é, é a mesma para todo $\theta \in \Theta$.

Observação: A ideia lembra a de estatística ancilar, cuja distribuição também não depende de θ. Entretanto, diferentemente de uma estatística, uma quantidade pivotal pode depender explicitamente do parâmetro desconhecido. No Exemplo 1.1, $X_{(n)}/\theta$ é um pivô, com função de distribuição $t \mapsto t^n$ em $(0, 1)$.

A construção de regiões de confiança por meio de quantidades pivotais consiste em encontrar um pivô $Q(X, \theta)$ e um conjunto $\mathcal{A}$, que não depende de θ, tais que

$$\mathbb{P}_\theta\big(Q(X, \theta) \in \mathcal{A}\big) \geq 1 - \alpha, \ \forall \theta \in \Theta.$$

Como a distribuição de $Q(X, \theta)$ não depende de θ, o conjunto $\mathcal{A}$ pode ser determinado a partir dessa distribuição. Em geral, escolhemos $\mathcal{A} = [q_1, q_2]$, em que q_1 e q_2 são quantis da distribuição do pivô.
Para cada realização x dos dados, definimos

$$C(x) = \big\{\theta \in \Theta : Q(x, \theta) \in \mathcal{A}\big\}.$$

Assim, $C(X)$ é uma região de confiança de nível $1-\alpha$ para θ, pois

$$\mathbb{P}_\theta\big(\theta \in C(X)\big) = \mathbb{P}_\theta\big(Q(X, \theta) \in \mathcal{A}\big) \geq 1 - \alpha, \ \forall \theta \in \Theta.$$

Quando a probabilidade acima é igual a $1-\alpha$ para todo $\theta \in \Theta$, a região possui probabilidade de cobertura constante e igual a $1-\alpha$.
Na prática, a região $C(x)$ é obtida invertendo a condição $Q(x, \theta) \in \mathcal{A}$ em relação ao parâmetro θ.

NOTAÇÃO: Para uma variável aleatória contínua $Q(X,\theta)$, o quantil de ordem p é o número q_p tal que $\mathbb{P}_\theta(Q(X,\theta) \le q_p) = p$. Escrevemos z_p, $t_{p,\nu}$ e $\chi^2_{p,\nu}$ para os quantis de ordem p das distribuições $\mathrm{N}(0,1)$, t_ν e χ^2_ν, respectivamente.

Exemplo 2.1 (Pivôs em famílias de locação e escala)**.** Sejam $X_1, \ldots, X_n$ *i.i.d.* com densidade de uma das formas da tabela abaixo, onde f é uma densidade contínua conhecida e $\mu \in \mathbb{R}$ e $\sigma > 0$ são parâmetros desconhecidos. Sejam $\bar{X}$ e S a média e o desvio padrão amostrais, com $S^2 = \sum_{i=1}^n (X_i - \bar{X})^2/(n-1)$. Então as quantidades da última coluna são pivôs.

Densidade	**Tipo**	**Parâmetro de interesse**	**Pivotal**
$f(x-\mu)$	locação	μ	$\bar{X} - \mu$
$\frac{1}{\sigma} f\Big(\frac{x}{\sigma}\Big)$	escala	σ	$\frac{X}{\sigma}$
$\frac{1}{\sigma} f\Big(\frac{x-\mu}{\sigma}\Big)$	locação e escala	μ	$\frac{X-\mu}{S}$
$\frac{1}{\sigma} f\Big(\frac{x-\mu}{\sigma}\Big)$	locação e escala	σ	$\frac{S}{\sigma}$

OBSERVAÇÃO: Se X tem densidade $\sigma^{-1} f\big((x-\mu)/\sigma\big)$ e $Z = (X-\mu)/\sigma$, então

$$\mathbb{P}_\theta(Z \le z) = \mathbb{P}_\theta(X \le \mu + \sigma z) = \int_{-\infty}^{\mu+\sigma z} \frac{1}{\sigma} f\left(\frac{x-\mu}{\sigma}\right) dx = \int_{-\infty}^{z} f(u)\, du,$$

isto é, Z tem densidade f, que não depende de $\theta = (\mu, \sigma)$. Logo, podemos escrever $X_i = \mu + \sigma Z_i$, em que $Z_1, \ldots, Z_n$ são *i.i.d.* com densidade f. A família de locação corresponde a $\sigma = 1$ e a de escala, a $\mu = 0$.

Caso 1: família de locação. Aqui $X_i = \mu + Z_i$. Para qualquer estatística $T = T(X)$ equivariante por locação, isto é, tal que $T(x_1 + c, \ldots, x_n + c) = T(x_1, \ldots, x_n) + c$, para todo $c \in \mathbb{R}$, tem-se

$$T(X) - \mu = T(Z),$$

cuja distribuição é determinada apenas por f e n, não dependendo de μ. Logo, $T(X) - \mu$ é um pivô (por exemplo, $\bar{X} - \mu$). Se $a < b$ são tais que $\mathbb{P}(a \le T(Z) \le b) = 1 - \alpha$, então

$$\begin{aligned} 1 - \alpha &= \mathbb{P}_\mu\big(a \le T(X) - \mu \le b\big) \\ &= \mathbb{P}_\mu\big(T(X) - b \le \mu \le T(X) - a\big). \end{aligned}$$

Portanto, $C(X) = [T(X) - b,\, T(X) - a]$ é um intervalo de confiança de nível $1 - \alpha$ para μ.

Por exemplo, sejam $X_1, \ldots, X_n$ *i.i.d.* com distribuição $\mathrm{Unif}(\mu, \mu + 1)$. O máximo $T = X_{(n)}$ satisfaz

$$\mathbb{P}_\mu(T \le t) = (t - \mu)^n, \qquad \mu < t < \mu + 1.$$

Portanto, $T - \mu \sim \mathrm{Beta}(n, 1)$ é uma quantidade pivotal. Como

$$\mathbb{P}_\mu\big(\alpha^{1/n} \le T - \mu \le 1\big) = 1 - \alpha,$$

obtemos, invertendo as desigualdades,

$$\mathbb{P}_\mu\big(T - 1 \le \mu \le T - \alpha^{1/n}\big) = 1 - \alpha.$$

Assim, $C(X) = [T - 1,\, T - \alpha^{1/n}]$ é um intervalo de confiança de nível $1 - \alpha$ para μ.

Caso 2: família de escala. Aqui $X_i = \sigma Z_i$. Para qualquer estatística $T = T(X) > 0$ quase certamente, equivariante por escala, isto é, tal que $T(cx_1, \ldots, cx_n) = cT(x_1, \ldots, x_n)$, para todo $c > 0$, tem-se

$$\frac{T(X)}{\sigma} = T(Z),$$

cuja distribuição não depende de σ. Logo, $T(X)/\sigma$ é um pivô, enquanto $T(X)$, em geral, não é.

Se $0 < a < b$ são tais que $\mathbb{P}(a \leq T(Z) \leq b) = 1 - \alpha$, então

$$\begin{aligned} 1 - \alpha &= \mathbb{P}_\sigma \left(a \leq \frac{T(X)}{\sigma} \leq b \right) \\ &= \mathbb{P}_\sigma \left(\frac{T(X)}{b} \leq \sigma \leq \frac{T(X)}{a} \right). \end{aligned}$$

Portanto,

$$C(X) = \left[\frac{T(X)}{b}, \frac{T(X)}{a} \right]$$

é um intervalo de confiança de nível $1 - \alpha$ para σ.

Por exemplo, sejam $X_1, \ldots, X_n$ *i.i.d.* com distribuição exponencial de média σ. A soma $T = \sum_{i=1}^n X_i$ é uma estatística suficiente, com $T \sim \text{Gama}(n, \sigma)$, na parametrização por forma e escala. Portanto,

$$\frac{2T}{\sigma} \sim \chi^2_{2n}$$

é uma quantidade pivotal. Como

$$\mathbb{P}_\sigma \left(\chi^2_{\alpha/2,2n} \leq \frac{2T}{\sigma} \leq \chi^2_{1-\alpha/2,2n} \right) = 1 - \alpha,$$

obtemos, invertendo as desigualdades,

$$\mathbb{P}_\sigma \left(\frac{2T}{\chi^2_{1-\alpha/2,2n}} \leq \sigma \leq \frac{2T}{\chi^2_{\alpha/2,2n}} \right) = 1 - \alpha.$$

Assim,

$$C(X) = \left[\frac{2T}{\chi^2_{1-\alpha/2,2n}}, \frac{2T}{\chi^2_{\alpha/2,2n}} \right]$$

é um intervalo de confiança de nível $1 - \alpha$ para σ.

Caso 3: família de locação e escala. Aqui $X_i = \mu + \sigma Z_i$. Sejam T_1 e T_2 estatísticas, com $T_2 > 0$ quase certamente, tais que

$$T_1(m + kx) = m + kT_1(x) \quad \text{e} \quad T_2(m + kx) = kT_2(x),$$

para todo $m \in \mathbb{R}$ e $k > 0$, em que $m + kx = (m + kx_1, \ldots, m + kx_n)$.
Então,

$$T_1(X) = \mu + \sigma T_1(Z) \quad \text{e} \quad T_2(X) = \sigma T_2(Z),$$

de modo que

$$\frac{T_1(X) - \mu}{T_2(X)} = \frac{T_1(Z)}{T_2(Z)} \quad \text{e} \quad \frac{T_2(X)}{\sigma} = T_2(Z)$$

são quantidades pivotais, pois suas distribuições dependem apenas de f e n. Por exemplo, podemos tomar $T_1 = \bar{X}$ e $T_2 = S$.
Observe que, nesta família,

$$T_1(X) - \mu = \sigma T_1(Z), \qquad \frac{T_1(X)}{\sigma} = \frac{\mu}{\sigma} + T_1(Z),$$

não são, em geral, pivôs, pois suas distribuições ainda podem depender dos parâmetros desconhecidos. Dividir $T_1(X) - \mu$ por $T_2(X)$ elimina a dependência da distribuição em σ, produzindo uma quantidade pivotal studentizada.
Se $a < b$ e $0 < c < d$ satisfazem

$$\mathbb{P} \left(a \leq \frac{T_1(Z)}{T_2(Z)} \leq b \right) = 1 - \alpha$$

e

$$\mathbb{P}\big(c \leq T_2(Z) \leq d\big) = 1 - \alpha,$$

então

$$\mathbb{P}_{\mu,\sigma}\big(\mu \in [T_1(X) - bT_2(X), T_1(X) - aT_2(X)]\big) = 1 - \alpha,$$
$$\mathbb{P}_{\mu,\sigma}\big(\sigma \in [T_2(X)/d, T_2(X)/c]\big) = 1 - \alpha.$$

Por exemplo, se $X_1, \ldots, X_n$ são *i.i.d.* com distribuição $\mathrm{N}(\mu, \sigma^2)$, podemos tomar $T_1 = \bar{X}$ e $T_2 = S$, obtendo os pivôs

$$\frac{\sqrt{n}(\bar{X} - \mu)}{S} \sim t_{n-1} \quad \text{e} \quad \frac{(n-1)S^2}{\sigma^2} \sim \chi^2_{n-1}.$$

Consequentemente, intervalos de confiança de nível $1 - \alpha$ para μ e σ^2 são, respectivamente,

$$\left[\bar{X} - t_{1-\alpha/2,n-1}\frac{S}{\sqrt{n}}, \bar{X} + t_{1-\alpha/2,n-1}\frac{S}{\sqrt{n}}\right]$$

e

$$\left[\frac{(n-1)S^2}{\chi^2_{1-\alpha/2,n-1}}, \frac{(n-1)S^2}{\chi^2_{\alpha/2,n-1}}\right],$$

em que $t_{\gamma,\nu}$ e $\chi^2_{\gamma,\nu}$ denotam os quantis de ordem γ das distribuições t de Student e qui-quadrado com ν graus de liberdade.

3. Pivoteamento da função de distribuição acumulada

Quando uma estatística $T(\mathbf{X})$ possui distribuição contínua, há sempre uma quantidade pivotal disponível.

Teorema 3.1 (Transformação Integral de Probabilidade)**.** Seja X uma variável aleatória com função de distribuição acumulada contínua F. Então,

$$F(X) \sim \mathrm{Unif}(0, 1).$$

Demonstração. Inicialmente, suponha que F seja estritamente crescente. Para $0 < y < 1$, temos

$$\begin{aligned}\mathbb{P}(F(X) \leq y) &= \mathbb{P}(X \leq F^{-1}(y)) \\ &= F(F^{-1}(y)) \\ &= y.\end{aligned}$$

Além disso,

$$\mathbb{P}(F(X) \leq y) = \begin{cases} 0, & y \leq 0, \\ 1, & y \geq 1. \end{cases}$$

O resultado também vale quando F é apenas contínua e não decrescente. Nesse caso, podemos utilizar a inversa generalizada $F^{-1}(y) = \inf\{x \in \mathbb{R} : F(x) \geq y\}$. Pela continuidade de F, $F(F^{-1}(y)) = y$, para $0 < y < 1$. Além disso, os intervalos em que F é constante possuem probabilidade nula, de modo que

$$\mathbb{P}(F(X) \leq y) = y, \ 0 < y < 1.$$

Portanto, $F(X) \sim \mathrm{Unif}(0, 1)$. □

Considere agora uma estatística $T = T(\mathbf{X})$ com função de distribuição acumulada contínua $F_\theta(T)$. Pelo teorema anterior, $F_\theta(T) \sim \mathrm{Unif}(0, 1)$. Como sua distribuição não depende de θ, $F_\theta(T)$ é uma quantidade pivotal.

3.1. **Caso contínuo.**

Teorema 3.2. Seja $T = T(\mathbf{X})$ uma estatística com função de distribuição acumulada contínua F_θ, em que $\theta \in \Theta \subseteq \mathbb{R}$. Considere $\alpha_1, \alpha_2 > 0$, com $\alpha_1 + \alpha_2 = \alpha$ e $0 < \alpha < 1$, e suponha que, para cada t no espaço amostral de T, seja possível definir $\theta_L(t) < \theta_U(t)$ da seguinte maneira:

(1) Se $F_\theta(t)$ é estritamente decrescente em θ, então $\theta_L(t)$ e $\theta_U(t)$ satisfazem

$$F_{\theta_U(t)}(t) = \alpha_1 \quad \text{e} \quad F_{\theta_L(t)}(t) = 1 - \alpha_2.$$

(2) Se $F_\theta(t)$ é estritamente crescente em θ, então $\theta_L(t)$ e $\theta_U(t)$ satisfazem

$$F_{\theta_L(t)}(t) = \alpha_1 \quad \text{e} \quad F_{\theta_U(t)}T(t) = 1 - \alpha_2.$$

Então, $C(\mathbf{X}) = [\theta_L(T), \theta_U(T)]$ é um intervalo de confiança de nível $1 - \alpha$ para θ.

Demonstração. Pela Transformação Integral de Probabilidade,

$$\mathbb{P}_\theta\left(\alpha_1 \leq F_\theta(T) \leq 1 - \alpha_2\right) = 1 - \alpha.$$

No primeiro caso, como $F_\theta(T)$ é estritamente decrescente em θ, temos

$$\begin{aligned} \alpha_1 \leq F_\theta(T) \leq 1 - \alpha_2 &\iff F_{\theta_U(T)}(T) \leq F_\theta(T) \leq F_{\theta_L(T)}(T) \\ &\iff \theta_L(T) \leq \theta \leq \theta_U(T). \end{aligned}$$

No segundo caso, como $F_\theta(T)$ é estritamente crescente em θ, temos

$$\begin{aligned} \alpha_1 \leq F_\theta(T) \leq 1 - \alpha_2 &\iff F_{\theta_L(T)}(T) \leq F_\theta(T) \leq F_{\theta_U(T)}(T) \\ &\iff \theta_L(T) \leq \theta \leq \theta_U(T). \end{aligned}$$

Consequentemente, em ambos os casos, $\mathbb{P}_\theta\left(\theta_L(T) \leq \theta \leq \theta_U(T)\right) = 1 - \alpha$. □

Exemplo 3.1. Sejam $X_1, \ldots, X_n$ variáveis aleatórias *i.i.d.* com distribuição exponencial de taxa $\theta > 0$. Considerando a estatística $T = \sum_{i=1}^n X_i$, sabemos que $T \sim \text{Gama}(n, \theta)$. Denotando por G_n a função de distribuição acumulada de uma distribuição $\text{Gama}(n, 1)$, temos

$$F_\theta(t) = \mathbb{P}_\theta(T \leq t) = G_n(\theta\, t).$$

Para todo $t > 0$, $F_\theta(t)$ é estritamente crescente em θ. Pela Transformação Integral de Probabilidade, $F_\theta(T) \sim \text{Unif}(0, 1)$. Assim,

$$\mathbb{P}_\theta\left(\frac{\alpha}{2} \leq F_\theta(T) \leq 1 - \frac{\alpha}{2}\right) = 1 - \alpha.$$

Como $2\theta T \sim \chi^2_{2n}$, podemos escrever $F_\theta(t) = F_{\chi^2_{2n}}(2\theta t)$. Os extremos do intervalo satisfazem

$$F_{\chi^2_{2n}}(2t\theta_L(t)) = \frac{\alpha}{2} \quad e \quad F_{\chi^2_{2n}}(2t\theta_U(t)) = 1 - \frac{\alpha}{2}.$$

Denotando por $\chi^2_{k,\gamma}$ o quantil de ordem γ da distribuição qui-quadrado com k graus de liberdade, obtemos

$$\theta_L(t) = \frac{\chi^2_{2n,\alpha/2}}{2t}, \quad e \quad \theta_U(t) = \frac{\chi^2_{2n,1-\alpha/2}}{2t}.$$

Consequentemente,

$$C(\mathbf{X}) = \left[\frac{\chi^2_{2n,\alpha/2}}{2T}, \frac{\chi^2_{2n,1-\alpha/2}}{2T}\right]$$

é um intervalo de confiança de nível $1 - \alpha$ para θ.

3.2. **Caso discreto.** Quando a distribuição de T é discreta, $F_\theta(T)$ não possui, em geral, distribuição uniforme. Entretanto, podemos utilizar desigualdades envolvendo sua função de distribuição acumulada para construir intervalos de confiança.

Proposição 3.1. Seja T uma variável aleatória discreta com função de distribuição acumulada F. Então, para todo $u \in (0,1)$,

$$\mathbb{P}(F(T) \leq u) \leq u \quad \text{e} \quad \mathbb{P}(F(T^-) > u) \leq 1-u,$$

em que $F(t^-) = \mathbb{P}(T < t)$.

Demonstração. Considere $A_u = \{x \in \mathbb{R} : F(x) \leq u\}$ e $a = \sup A_u$. Se $a \in A_u$, temos

$$\mathbb{P}(F(T) \leq u) = \mathbb{P}(T \leq a) = F(a) \leq u.$$

Se $a \notin A_u$, temos

$$\mathbb{P}(F(T) \leq u) = \mathbb{P}(T < a) = F(a^-) \leq u,$$

pois

$$F(a^-) = \sup_{x<a} F(x) \leq u.$$

Os casos em que A_u é vazio ou não possui supremo finito são imediatos.
Para a segunda desigualdade, considere $B_u = \{x \in \mathbb{R} : F(x^-) > u\}$. Como F é não decrescente, B_u é um conjunto superior. Seja $b = \inf B_u$. Pela definição de b,

$$\mathbb{P}(F(T^-) > u) \leq \mathbb{P}(T > b) = 1 - F(b) \leq 1-u.$$

□

Como consequência da proposição anterior, $\mathbb{P}_\theta\left(F_\theta(T) < \alpha_1\right) \leq \alpha_1$ e $\mathbb{P}_\theta\left(F_\theta(T^-) > 1-\alpha_2\right) \leq \alpha_2$. Pela desigualdade da união,

$$\begin{aligned}
\mathbb{P}_\theta\left(F_\theta(T) \geq \alpha_1,\, F_\theta(T^-) \leq 1-\alpha_2\right) &\geq 1 - \mathbb{P}_\theta\left(F_\theta(T) < \alpha_1\right) - \mathbb{P}_\theta\left(F_\theta(T^-) > 1-\alpha_2\right) \\
&\geq 1 - \alpha_1 - \alpha_2 \\
&= 1-\alpha.
\end{aligned}$$

Teorema 3.3. Seja $T = T(\mathbf{X})$ uma estatística discreta cuja distribuição depende de um parâmetro $\theta \in \Theta \subseteq \mathbb{R}$, em que Θ é um intervalo. Denote por $F_\theta(t)$ sua função de distribuição acumulada e por $F_\theta(t^-) = \mathbb{P}_\theta(T < t)$ seu limite à esquerda. Considere $\alpha_1, \alpha_2 > 0$, com $\alpha_1 + \alpha_2 = \alpha$ e $0 < \alpha < 1$, e suponha que, para cada t, a função $F_\theta(t)$ é monótona em θ, sempre no mesmo sentido. Então,

$$C(t) = \left\{\theta \in \Theta : F_\theta(t) \geq \alpha_1,\, F_\theta(t^-) \leq 1-\alpha_2\right\}.$$

é um intervalo, possivelmente vazio ou com extremos abertos, e

$$\mathbb{P}_\theta\left(\theta \in C(T)\right) \geq 1-\alpha,\ \forall \theta \in \Theta.$$

Demonstração. Pelas desigualdades anteriores,

$$\mathbb{P}_\theta\left(F_\theta(T) \geq \alpha_1,\, F_\theta(T^-) \leq 1-\alpha_2\right) \geq 1-\alpha.$$

Pela definição de $C(T)$, esse evento é equivalente a $\{\theta \in C(T)\}$.
Resta verificar se $C(t)$ é um intervalo. Suponha inicialmente que $F_\theta(t)$ é não crescente em θ. Nesse caso, $F_\theta(t) \geq \alpha_1$ define um conjunto inferior de valores de θ, enquanto

$$F_T(t^- \mid \theta) \leq 1-\alpha_2$$

define um conjunto superior. Sua interseção é um intervalo.
Quando $F_T(t \mid \theta)$ é não decrescente em θ, os papéis dos conjuntos inferior e superior são invertidos, e a conclusão permanece válida. □

Exemplo 3.2. Sejam $X_1, \ldots, X_n$ variáveis aleatórias *i.i.d.* com distribuição Bernoulli(θ), $0 < \theta < 1$. Considerando a estatística $T = \sum_{i=1}^{n} X_i$, sabemos que $T \sim \text{Binomial}(n, \theta)$. Sua função de distribuição acumulada, portanto, é dada por

$$F_\theta(t) = \sum_{k=0}^{t} \binom{n}{k} \theta^k (1-\theta)^{n-k}, \ t = 0, \ldots, n.$$

Para cada t, $F_\theta(t)$ é não crescente em θ. Assim, pelo teorema anterior, um intervalo de confiança de nível pelo menos $1-\alpha$ é obtido a partir do conjunto

$$C(t) = \left\{ \theta \in (0,1) : F_\theta(t) \geq \frac{\alpha}{2}, \ F_\theta(t^-) \leq 1 - \frac{\alpha}{2} \right\}.$$

Para $0 < t < n$, os extremos $\theta_L(t)$ e $\theta_U(t)$ satisfazem, respectivamente,

$$F_{\theta_L(t)}(t^-) = 1 - \frac{\alpha}{2} \quad \text{e } F_{\theta_U(t)}(t) = \frac{\alpha}{2}.$$

Como T é discreta,

$$F_\theta(t^-) = \mathbb{P}_\theta(T < t) = F_\theta(t-1).$$

Portanto, os extremos são determinados pelas equações

$$\sum_{k=0}^{t-1} \binom{n}{k} \theta_L(t)^k (1-\theta_L(t))^{n-k} = 1 - \frac{\alpha}{2} \quad \text{e} \quad \sum_{k=0}^{t} \binom{n}{k} \theta_U(t)^k (1-\theta_U(t))^{n-k} = \frac{\alpha}{2}.$$

Essas equações podem ser resolvidas utilizando os quantis da distribuição beta. Denotando por $B_{a,b;\gamma}$ o quantil de ordem γ da distribuição Beta(a, b), obtemos

$$\theta_L(t) = B_{t,n-t+1;\alpha/2} \quad \text{e } \theta_U(t) = B_{t+1,n-t;1-\alpha/2}.$$

Nos casos extremos, adotamos $\theta_L(0) = 0$ e $\theta_U(n) = 1$. Consequentemente, $C(\mathbf{X}) = [\theta_L(T), \theta_U(T)]$ é um intervalo de confiança com probabilidade de cobertura de pelo menos $1-\alpha$ para θ, conhecido como intervalo de Clopper–Pearson.

4. Intervalos de confiança assintóticos

Definição 4.1. Seja $\mathbf{X}_n = (X_1, \ldots, X_n)$ um vetor aleatório cuja distribuição depende de um parâmetro $\theta \in \Theta$, e considere uma função $g : \Theta \to \mathbb{R}^q$. Uma sequência de conjuntos aleatórios $C_n(\mathbf{X}_n) \subseteq \mathbb{R}^q$ é denominada sequência de regiões de confiança assintóticas de nível $1-\alpha$ para $g(\theta)$ se

$$\liminf_{n\to\infty} \mathbb{P}_\theta\big(g(\theta) \in C_n(\mathbf{X}_n)\big) \geq 1 - \alpha, \ \forall\, \theta \in \Theta.$$

Diferentemente das regiões de confiança construídas para amostras finitas, cuja probabilidade de cobertura é garantida para qualquer tamanho amostral, as regiões de confiança assintóticas oferecem uma garantia baseada no comportamento limite da distribuição de uma estatística.

Anteriormente, caracterizamos uma distribuição assintótica geral para estimadores obtidos por máxima verossimilhança. Podemos, portanto, caracterizar também um método geral para construir intervalos de confiança assintóticos. Sejam $X_1, \ldots, X_n$ variáveis aleatórias independentes e identicamente distribuídas com distribuição $\mathbb{P}_\theta$, $\theta \in \Theta \subseteq \mathbb{R}$. Sob condições de regularidade, temos

$$\sqrt{n}(\widehat{\theta}_n - \theta) \xrightarrow{d} N(0, 1/I(\theta)),$$

onde $\hat{\theta}_n$ é o estimador de máxima verossimilhança de θ e $I(\theta)$ é a informação de Fisher associada a uma observação. Equivalentemente,

$$\sqrt{nI(\theta)}(\widehat{\theta}_n - \theta) \xrightarrow{d} N(0,1).$$

Como a distribuição limite não depende do parâmetro desconhecido θ, a quantidade $Q_n(\mathbf{X}_n, \theta) = \sqrt{nI(\theta)}(\widehat{\theta}_n - \theta)$ é denominada quantidade pivotal assintótica (ou quantidade pivotal aproximada).

Observação: Diferentemente de uma quantidade pivotal exata, a distribuição de Q_n pode depender de θ para valores finitos de n. É sua distribuição limite que é independente do parâmetro.

Pela convergência em distribuição,

$$\mathbb{P}_\theta\left(-z_{1-\alpha/2} < \sqrt{nI(\theta)}(\hat{\theta}_n - \theta) < z_{1-\alpha/2}\right) \to 1-\alpha, \tag{1}$$

onde $z_{1-\alpha/2}$ é o quantil de ordem $1-\alpha/2$ da distribuição normal padrão. Definindo o conjunto aleatório $C_n(\mathbf{X}_n) = \{\theta' \in \Theta : \sqrt{nI(\theta')}|\hat{\theta}_n - \theta'| < z_{1-\alpha/2}\}$, $\theta \in C_n(\mathbf{X}_n)$ se, e somente se, $\sqrt{nI(\theta)}|\hat{\theta}_n - \theta| < z_{1-\alpha/2}$. Logo,

$$\mathbb{P}_\theta(\theta \in C_n(\mathbf{X}_n) \to 1-\alpha.$$

Portanto, $C_n(\mathbf{X}_n)$ é uma região de confiança assintótica de nível $1-\alpha$ para θ.

A expressão em (1), contudo, envolve $I(\theta)$, que, em geral, depende do parâmetro desconhecido. Como o EMV é consistente, temos $\hat{\theta}_n \xrightarrow{\mathbb{P}} \theta$. Supondo que $I(\cdot)$ seja contínua em θ e que $I(\theta) > 0$, pelo Teorema do Mapeamento Contínuo, obtemos

$$\sqrt{\frac{I(\hat{\theta}_n)}{I(\theta)}} \xrightarrow{\mathbb{P}} 1.$$

Logo, pelo Teorema de Slutsky, segue que

$$\sqrt{nI(\hat{\theta}_n)}(\hat{\theta}_n - \theta) \xrightarrow{d} N(0,1).$$

Consequentemente,

$$\mathbb{P}_\theta\left(-z_{1-\alpha/2} < \sqrt{nI(\hat{\theta}_n)}(\hat{\theta}_n - \theta) < z_{1-\alpha/2}\right) \to 1-\alpha.$$

Portanto, um intervalo de confiança assintótico de nível $1-\alpha$ para θ é dado por

$$C_n(\mathbf{X}_n) = \left(\hat{\theta}_n - \frac{z_{1-\alpha/2}}{\sqrt{nI(\hat{\theta}_n)}},\ \hat{\theta}_n + \frac{z_{1-\alpha/2}}{\sqrt{nI(\hat{\theta}_n)}}\right). \tag{2}$$

Esse intervalo é conhecido como intervalo de Wald.

4.1. **Informação de Fisher observada.** O intervalo descrito em (2) requer o cálculo da informação de Fisher $I(\theta)$, que envolve uma esperança sobre o modelo estatístico. Uma alternativa consiste em utilizar a informação de Fisher observada, definida por

$$J_n(\theta) = -\ell_n''(\theta),$$

em que $\ell_n(\theta) = \sum_{i=1}^n \log f(X_i;\theta)$ é a função de log-verossimilhança da amostra.

Pela Lei dos Grandes Números,

$$\frac{J_n(\theta)}{n} = -\frac{1}{n}\sum_{i=1}^n \frac{\partial^2}{\partial\theta^2}\log f(X_i;\theta) \xrightarrow{\mathbb{P}} I(\theta).$$

Além disso, sob condições de regularidade e pela consistência do estimador de máxima verossimilhança, essa convergência permanece válida quando θ é substituído por $\hat{\theta}_n$, isto é,

$$\frac{J_n(\hat{\theta}_n)}{n} \xrightarrow{\mathbb{P}} I(\theta).$$

Consequentemente, pelo Teorema do Mapeamento Contínuo,

$$\sqrt{\frac{J_n(\hat{\theta}_n)}{nI(\theta)}} \xrightarrow{\mathbb{P}} 1.$$

Novamente, pelo Teorema de Slutsky, segue que

$$\sqrt{J_n(\hat{\theta}_n)}(\hat{\theta}_n - \theta) \xrightarrow{d} N(0,1).$$

Portanto, um intervalo de confiança assintótico de nível $1-\alpha$ para θ é dado por

$$C_n(\mathbf{X}_n) = \left[\hat{\theta}_n - \frac{z_{1-\alpha/2}}{\sqrt{J_n(\hat{\theta}_n)}},\ \hat{\theta}_n + \frac{z_{1-\alpha/2}}{\sqrt{J_n(\hat{\theta}_n)}}\right].$$

O intervalo acima está definido quando $J_n(\hat{\theta}_n) > 0$, o que ocorre com probabilidade que tende a 1 sob as condições consideradas.

4.2. **Intervalos para funções do parâmetro.** Em muitas aplicações, estamos interessados em uma função $g(\theta)$, em vez do próprio parâmetro θ. Considere $g : \Theta \to \mathbb{R}$ continuamente diferenciável em uma vizinhança de θ, com $g'(\theta) \neq 0$. Pelo método delta, sabemos que

$$\sqrt{n}\left[g(\hat{\theta}_n) - g(\theta)\right] \xrightarrow{d} N\left(0, \frac{[g'(\theta)]^2}{I(\theta)}\right).$$

Como o EMV é consistente, supondo que I seja contínua em θ e que $I(\theta) > 0$, pelo Teorema do Mapeamento Contínuo, temos

$$\frac{[g'(\hat{\theta}_n)]^2}{I(\hat{\theta}_n)} \xrightarrow{\mathbb{P}} \frac{[g'(\theta)]^2}{I(\theta)}.$$

Consequentemente, pelo Teorema de Slutsky,

$$\frac{\sqrt{nI(\hat{\theta}_n)}\left[g(\hat{\theta}_n) - g(\theta)\right]}{|g'(\hat{\theta}_n)|} \xrightarrow{d} N(0,1).$$

Portanto, um intervalo de confiança assintótico de nível $1-\alpha$ para $g(\theta)$ é dado por

$$C_n(\mathbf{X}_n) = \left[g(\hat{\theta}_n) - z_{1-\alpha/2}\frac{|g'(\hat{\theta}_n)|}{\sqrt{nI(\hat{\theta}_n)}},\ g(\hat{\theta}_n) + z_{1-\alpha/2}\frac{|g'(\hat{\theta}_n)|}{\sqrt{nI(\hat{\theta}_n)}}\right].$$

Analogamente, podemos utilizar a informação de Fisher observada $J_n(\hat{\theta}_n)$ em lugar de $nI(\hat{\theta}_n)$, obtendo um intervalo de confiança assintótico com margem de erro $z_{1-\alpha/2}|g'(\hat{\theta}_n)|/\sqrt{J_n(\hat{\theta}_n)}$.